

机器人学的状态估计

状态估计，是根据系统的先验模型和测量序列，对系统内在状态进行重构的问题

一、状态估计机理

第二章 概率论基础

1、概率密度函数

1. 非条件概率密度、条件概率密度、联合概率密度

$$\int_a^b p(x) dx = 1 \quad (\forall y) \quad \int_a^b p(x|y) dx = 1 \quad p(x, y)$$

2. 贝叶斯公式

我们总是可以把一个联合概率密度分解成一个条件概率密度和一个非条件概率密度的乘积^[1]：

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x) \quad (2.7)$$

重新整理一下上面的公式，可以得到贝叶斯公式（Bayes' rule）：

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} \quad (2.8)$$

先验为 $p(x)$ ，后验为 $p(x|y)$ ， $p(y|x)$ 为传感器模型

形象的理解就是已知状态的先验 $p(x)$ （也就是上一时刻的已知状态），还有这一时刻的传感器观测 $p(y|x)$ ，使用这个观测来修正上一时刻的先验状态，得到这一时刻的在当前传感器观测条件下的状态，也就是后验 $p(x|y)$ 。

可以通过如下边缘化（marginalization）方式计算分母 $p(y)$ ^[2]：

$$\begin{aligned} p(y) &= p(y) \underbrace{\int p(x|y) dx}_1 = \int p(x|y)p(y) dx \\ &= \int p(x, y) dx = \int p(y|x)p(x) dx \end{aligned} \quad (2.10)$$

如果我们有了状态的先验（prior）概率密度函数 $p(\mathbf{x})$ 和传感器模型 $p(\mathbf{y}|\mathbf{x})$ ，就可以推断（infer）状态的后验（posterior）概率密度函数^[1]。为此，将分母展开：

$$p(\mathbf{x}|\mathbf{y}) = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y}|\mathbf{x})p(\mathbf{x})d\mathbf{x}} \quad (2.9)$$

3. 矩

用矩来反映概率密度函数的有一些特性，定义如下：

对于连续型随机变量，在存在的前提下，其相对于值 c 的 n 阶矩为：

$$\mu_n = \int_{-\infty}^{\infty} (x - c)^n f(x) dx$$

零阶矩：全事件概率，恒等于1

一阶矩：期望，默认相对于值0

$$\mu = E[x] = \int x p(x) dx$$

二阶矩：协方差矩阵

$$\Sigma = E[(x - \mu)(x - \mu)^T]$$

4. 样本均值和样本方差

对于随机变量 x 以及它的概率密度函数 $p(x)$ ，可以从概率密度函数中进行抽样得到样本，也就是一次测量值，可以根据样本去近似估计随机变量的均值和方差

$$\mu_{\text{meas}} = \frac{1}{N} \sum_{i=1}^N x_{i,\text{meas}}$$

$$\Sigma_{\text{meas}} = \frac{1}{N-1} \sum_{i=1}^N (x_{i,\text{meas}} - \mu_{\text{meas}})(x_{i,\text{meas}} - \mu_{\text{meas}})^T$$

5. 归一化积

归一化积可以用来融合对同一个随机变量的多次估计，比如在观测 y_1 下状态 x 的后验概率为 $p(x|y_1)$ 和在观测 y_2 下状态 x 的后验概率为 $p(x|y_2)$ ，假设 $y_1 y_2$ 是两次独立的观测，可以使用归一化积来融合得到一个总体的概率 $p(x|y_1, y_2)$

$$p(\mathbf{x}|\mathbf{y}_1, \mathbf{y}_2) = \eta p(\mathbf{x}|\mathbf{y}_1)p(\mathbf{x}|\mathbf{y}_2)$$

前面有一个用来满足概率公理的归一化常数，求解如下：

$$\begin{aligned}
 P(x|y_1, y_2) &= \frac{P(y_1, y_2|x) \cdot P(x)}{P(y_1, y_2)} = \frac{P(y_1|x) \cdot P(y_2|x) \cdot P(x)}{P(y_1, y_2)} \\
 &= \frac{P(x|y_1) \cdot P(y_1)}{P(x)} \cdot \frac{P(x|y_2) \cdot P(y_2)}{P(x)} \cdot P(x) \\
 &= \frac{P(y_1) \cdot P(y_2)}{P(y_1, y_2) \cdot P(x)} \cdot P(x|y_1) \cdot P(x|y_2) \\
 &= \prod P(x|y_i) \cdot P(x|y_2)
 \end{aligned}$$

6. 香农和互信息

在估计某一随机变量的概率密度函数时，我们也希望知道对某个量（比如均值）有多么不确定。定量刻画不确定性的一种方法是计算事件的**负熵或香农信息量**

$$H(x) = -E[\ln p(x)] = - \int p(x) \ln p(x) dx$$

另一种是两个随机变量x和y之间的**互信息I(x,y)**

$$I(x, y) = E \left[\ln \left(\frac{p(x, y)}{p(x)p(y)} \right) \right] = \iint p(x, y) \ln \left(\frac{p(x, y)}{p(x)p(y)} \right) dx dy$$

互信息衡量的是已知一个随机变量的信息之后，另一个随机变量不确定性的减少了多少。

当xy相互独立时：

$$\begin{aligned}
 I(x, y) &= \iint p(x, y) \ln \left(\frac{p(x, y)}{p(x)p(y)} \right) dx dy \\
 &= \iint p(x)p(y) \underbrace{\ln(1)}_0 dx dy = 0
 \end{aligned}$$

互信息和香农信息之间换算关系

$$I(x, y) = H(x) + H(y) - H(x, y)$$

7. 克拉美罗下界和费歇尔信息量

假设有一个确定的参数 θ ，它影响着随机变量 x 的概率密度。我们可以用条件概率密度函数对此进行描述：

$$p(x|\theta) \quad (2.30)$$

更进一步，假设我们从 $p(x|\theta)$ 中取一个样本 x_{meas} ：

$$x_{\text{meas}} \leftarrow p(x|\theta) \quad (2.31)$$

这里的 x_{meas} 称为随机变量 x 的一次实现；我们可以把它认为是一个观测值。

那么，克拉美罗下界（Cramér-Rao Lower Bound, CRLB）指出，参数真实值 θ 的任意无偏估计 $\hat{\theta}$ （基于观测值 x_{meas} ）的协方差，可以由费歇尔信息矩阵（Fisher information matrix） $I(x|\theta)$ 来定义边界，即：

$$\text{cov}(\hat{\theta}|x_{\text{meas}}) = E[(\hat{\theta} - \theta)(\hat{\theta} - \theta)^T] \geq I^{-1}(x|\theta) \quad (2.32)$$

其中“无偏”指的是： $E[\hat{\theta} - \theta] = 0$ ，“边界”意味着：

$$\text{cov}(\hat{\theta}|x_{\text{meas}}) - I^{-1}(x|\theta) \geq 0 \quad (2.33)$$

即矩阵半正定。费歇尔信息矩阵为：

$$I(x|\theta) = E \left[\left(\frac{\partial \ln p(x|\theta)}{\partial \theta} \right)^T \left(\frac{\partial \ln p(x|\theta)}{\partial \theta} \right) \right] \quad (2.34)$$

也就是说，克拉美罗下界设定了一个基本界限。它可以明确定义出利用已有观测值估计参数的效果和衡量估计方式好坏的标准。

（无偏估计指的是用样本统计量来估计总体参数时的一种无偏推断。估计量的数学期望等于被估计参数的真实值，则称此估计量为被估计参数的无偏估计，即具有无偏性，是一种用于评价估计量优良性的准则。无偏估计的意义是：在多次重复下，它们的平均数接近所估计的参数真值。）

2、高斯概率密度函数

1. 高斯概率密度函数基本定义

一维情况：

后文很多地方会用到高斯概率密度函数。在一维情况下，高斯概率密度函数表示为：

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}\right) \quad (2.35)$$

其中 μ 称为均值 (mean)， σ^2 为方差 (variance)， σ 称为标准差 (standard deviation)。图 2-2 画出了一维高斯 PDF 的图像。




图 2-2 一维高斯密度函数。高斯分布的一个显著特征为期望和模 (mode, x 最可能的取值) 都是 μ

多维情况：

多维变量的高斯分布是说，随机变量 $\mathbf{x} \in \mathbb{R}^N$ ，服从的分布 $p(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 可以写为：

$$p(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^N \det \boldsymbol{\Sigma}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) \quad (2.36)$$

其中 $\boldsymbol{\mu} \in \mathbb{R}^N$ 是均值， $\boldsymbol{\Sigma} \in \mathbb{R}^{N \times N}$ 是协方差矩阵 (对称正定矩阵)，它们可以通过以下方式计算：

$$\boldsymbol{\mu} = E[\mathbf{x}] = \int_{-\infty}^{\infty} \mathbf{x} \frac{1}{\sqrt{(2\pi)^N \det \boldsymbol{\Sigma}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) d\mathbf{x} \quad (2.37)$$

以及

$$\begin{aligned} \boldsymbol{\Sigma} &= E[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] \\ &= \int_{-\infty}^{\infty} (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T \frac{1}{\sqrt{(2\pi)^N \det \boldsymbol{\Sigma}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) d\mathbf{x} \end{aligned} \quad (2.38)$$

2. Isserlis定理

多变量高斯分布中高阶矩的计算较为复杂。但是在后面的篇幅中，我们需要用到除了期望和方差之外的矩，所以现在加以讨论。为了计算某些高阶矩，我们引入 **Isserlis 定理**。令 $\mathbf{x} = (x_1, x_2, \dots, x_{2M}) \in \mathbb{R}^{2M}$ 为服从高维高斯分布的随机变量，那么有：

$$E[x_1 x_2 x_3 \cdots x_{2M}] = \sum \prod E[x_i x_j] \quad (2.39)$$

这意味着，计算 $2M$ 个变量乘积的期望，可以首先计算所有两两不同的变量乘积的期望，然后把计算出来这些期望做乘积。这样的组合有 $\frac{(2M)!}{(2^M M!)}$ 种，最后将这些乘积的值求和。四个变量的情况如下：

$$E[x_i x_j x_k x_\ell] = E[x_i x_j] E[x_k x_\ell] + E[x_i x_k] E[x_j x_\ell] + E[x_i x_\ell] E[x_j x_k] \quad (2.40)$$

。。。。。。我tm直接看傻了，贴原文吧，记住上面的结论就好

我们可以用这个定理推导出一些有用的结果。

设 $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \Sigma) \in \mathbb{R}^N$ ，有时候我们希望计算下式：

$$E[\mathbf{x}(\mathbf{x}^T \mathbf{x})^p \mathbf{x}^T] \quad (2.41)$$

其中 p 是一个非负整数。当 $p = 0$ 时，我们可以轻易得到 $E[\mathbf{x}\mathbf{x}^T] = \Sigma$ 。当 $p = 1$ 时，我们可以得到^[4]：

$$\begin{aligned} E[\mathbf{x}\mathbf{x}^T \mathbf{x}\mathbf{x}^T] &= E\left[\left[x_i x_j \left(\sum_{k=1}^N x_k^2\right)\right]_{ij}\right] = \left[\sum_{k=1}^N E[x_i x_j x_k^2]\right]_{ij} \\ &= \left[\sum_{k=1}^N (E[x_i x_j] E[x_k^2] + 2E[x_i x_k] E[x_k x_j])\right]_{ij} \\ &= [E[x_i x_j]]_{ij} \sum_{k=1}^N E[x_k^2] + 2 \left[\sum_{k=1}^N E[x_i x_k] E[x_k x_j]\right]_{ij} \\ &= \Sigma \operatorname{tr}(\Sigma) + 2\Sigma^2 \\ &= \Sigma (\operatorname{tr}(\Sigma) \mathbf{1} + 2\Sigma) \end{aligned} \quad (2.42)$$

再来考虑如下情况：

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{12}^T & \Sigma_{22} \end{bmatrix}\right) \quad (2.43)$$

其中 $\dim(\mathbf{x}_1) = N_1$ 和 $\dim(\mathbf{x}_2) = N_2$ 。我们需要计算如下表达式：

$$E[\mathbf{x}(\mathbf{x}_1^T \mathbf{x}_1)^p \mathbf{x}^T] \quad (2.44)$$

其中 p 是非负整数。同样地，当 $p = 0$ 时，有 $E[\mathbf{x}\mathbf{x}^T] = \Sigma$ 。当 $p = 1$ 时，我们有：

$$\begin{aligned} E[\mathbf{x}\mathbf{x}_1^T \mathbf{x}_1 \mathbf{x}^T] &= E\left[\left[x_i x_j \left(\sum_{k=1}^{N_1} x_k^2\right)\right]_{ij}\right] = \left[\sum_{k=1}^{N_1} E[x_i x_j x_k^2]\right]_{ij} \\ &= \left[\sum_{k=1}^{N_1} (E[x_i x_j] E[x_k^2] + 2E[x_i x_k] E[x_k x_j])\right]_{ij} \\ &= [E[x_i x_j]]_{ij} \sum_{k=1}^{N_1} E[x_k^2] + 2 \left[\sum_{k=1}^{N_1} E[x_i x_k] E[x_k x_j]\right]_{ij} \\ &= \Sigma \operatorname{tr}(\Sigma_{11}) + 2 \begin{bmatrix} \Sigma_{11}^2 & \Sigma_{11} \Sigma_{12} \\ \Sigma_{12}^T \Sigma_{11} & \Sigma_{12}^T \Sigma_{12} \end{bmatrix} \\ &= \Sigma \left(\operatorname{tr}(\Sigma_{11}) \mathbf{1} + 2 \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \right) \end{aligned} \quad (2.45)$$

同理可得：

$$\begin{aligned} E[\mathbf{x}\mathbf{x}_2^T \mathbf{x}_2 \mathbf{x}^T] &= \Sigma \operatorname{tr}(\Sigma_{22}) + 2 \begin{bmatrix} \Sigma_{12} \Sigma_{12}^T & \Sigma_{12} \Sigma_{22} \\ \Sigma_{22} \Sigma_{12}^T & \Sigma_{22}^2 \end{bmatrix} \\ &= \Sigma \left(\operatorname{tr}(\Sigma_{22}) \mathbf{1} + 2 \begin{bmatrix} \mathbf{0} & \mathbf{0} \\ \Sigma_{12}^T & \Sigma_{22} \end{bmatrix} \right) \end{aligned} \quad (2.46)$$

可作如下验证：

$$E[\mathbf{x}\mathbf{x}^T \mathbf{x}\mathbf{x}^T] = E[\mathbf{x}(\mathbf{x}_1^T \mathbf{x}_1 + \mathbf{x}_2^T \mathbf{x}_2) \mathbf{x}^T] = E[\mathbf{x}\mathbf{x}_1^T \mathbf{x}_1 \mathbf{x}^T] + E[\mathbf{x}\mathbf{x}_2^T \mathbf{x}_2 \mathbf{x}^T] \quad (2.47)$$

进一步有：

$$\begin{aligned}
 E[\mathbf{x}\mathbf{x}^T \mathbf{A} \mathbf{x}\mathbf{x}^T] &= E\left[\left[x_i x_j \left(\sum_{k=1}^N \sum_{\ell=1}^N x_k a_{k\ell} x_\ell\right)\right]_{ij}\right] \\
 &= \left[\sum_{k=1}^N \sum_{\ell=1}^N a_{k\ell} E[x_i x_j x_k x_\ell]\right]_{ij} \\
 &= \left[\sum_{k=1}^N \sum_{\ell=1}^N a_{k\ell} (E[x_i x_j] E[x_k x_\ell] + E[x_i x_k] E[x_j x_\ell] + E[x_i x_\ell] E[x_j x_k])\right]_{ij} \quad (2.48) \\
 &= [E[x_i x_j]]_{ij} \left(\sum_{k=1}^N \sum_{\ell=1}^N a_{k\ell} E[x_k x_\ell]\right) + \left[\sum_{k=1}^N \sum_{\ell=1}^N E[x_i x_k] a_{k\ell} E[x_\ell x_j]\right]_{ij} \\
 &\quad + \left[\sum_{k=1}^N \sum_{\ell=1}^N E[x_i x_\ell] a_{k\ell} E[x_k x_j]\right]_{ij} \\
 &= \Sigma \operatorname{tr}(\mathbf{A}\Sigma) + \Sigma \mathbf{A}\Sigma + \Sigma \mathbf{A}^T \Sigma \\
 &= \Sigma (\operatorname{tr}(\mathbf{A}\Sigma) \mathbf{1} + \mathbf{A}\Sigma + \mathbf{A}^T \Sigma)
 \end{aligned}$$

其中 $\mathbf{A}$ 为方阵，行数和列数满足矩阵乘法要求。

3. 联合高斯概率密度函数，分解与推断

设我们有一对服从多元正态分布的变量 $(\mathbf{x}, \mathbf{y})$ ，可以写出它们的联合概率密度函数：

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N}\left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}\right)$$

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x}|\mathbf{y})p(\mathbf{y}) \quad (2.53a)$$

$$p(\mathbf{x}|\mathbf{y}) = \mathcal{N}(\mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(\mathbf{y} - \mu_y), \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}) \quad (2.53b)$$

$$p(\mathbf{y}) = \mathcal{N}(\mu_y, \Sigma_{yy}) \quad (2.53c)$$

我们发现一件重要的事情：因子 $p(\mathbf{x}|\mathbf{y})$ 、 $p(\mathbf{y})$ 都是高斯概率密度函数。更进一步，如果我们知道 $\mathbf{y}$ 的值（比如，它的观测值），我们就可以用等式 (2.53b) 通过计算 $p(\mathbf{x}|\mathbf{y})$ 得到在给定 $\mathbf{y}$ 值情况下的 $\mathbf{x}$ 的似然值。

这实际上就是**高斯推断**（Gaussian inference）中最重要的部分：我们从状态的先验概率分布出发，然后基于一些观测值 $\mathbf{y}_{\text{meas}}$ 来缩小这个范围。在式 (2.53b) 中，可以看到均值发生了一些调整，协方差矩阵则变小了一些。

4. 统计独立

$$\Sigma_{xy} = \mathbf{0}$$

5. 高斯分布随机变量的线性变换

针对线性变换 G （或者说单射）和高斯随机变量 $\mathbf{x}$ ，有

$$\mathbf{x} \in \mathbb{R}^N \sim \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$\mathbf{y} = \mathbf{G}\mathbf{x}$$

研究 $\mathbf{y}$ 的统计特性有：

$$\begin{aligned}\boldsymbol{\mu}_y &= E[\mathbf{y}] = E[\mathbf{G}\mathbf{x}] = \mathbf{G}E[\mathbf{x}] = \mathbf{G}\boldsymbol{\mu}_x \\ \boldsymbol{\Sigma}_{yy} &= E[(\mathbf{y} - \boldsymbol{\mu}_y)(\mathbf{y} - \boldsymbol{\mu}_y)^T] \\ &= \mathbf{G}E[(\mathbf{x} - \boldsymbol{\mu}_x)(\mathbf{x} - \boldsymbol{\mu}_x)^T]\mathbf{G}^T = \mathbf{G}\boldsymbol{\Sigma}_{xx}\mathbf{G}^T\end{aligned}$$

6. 高斯概率密度函数的归一化积

结论：K 个高斯概率密度函数的归一化积仍然是高斯概率密度函数

$$\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) \equiv \eta \prod_{k=1}^K \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)\right)$$




图 2-3 两个高斯密度函数做归一化积后，得到一个新的高斯密度函数

7. Sherman-Morrison-Woodbury 等式

矩阵求逆引理：对于可逆矩阵，我们可以将它分解为一个下三角—对角—上三角（lower-diagonal-upper, LDU）形式或上三角—对角—下三角（upper-diagonal-lower, UDL）形式

$$\begin{aligned}& \begin{bmatrix} \mathbf{A}^{-1} & -\mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ \mathbf{C}\mathbf{A} & \mathbf{1} \end{bmatrix} \begin{bmatrix} \mathbf{A}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} + \mathbf{C}\mathbf{A}\mathbf{B} \end{bmatrix} \begin{bmatrix} \mathbf{1} & -\mathbf{A}\mathbf{B} \\ \mathbf{0} & \mathbf{1} \end{bmatrix} \quad (\text{LDU}) \\ &= \begin{bmatrix} \mathbf{1} & -\mathbf{B}\mathbf{D}^{-1} \\ \mathbf{0} & \mathbf{1} \end{bmatrix} \begin{bmatrix} \mathbf{A}^{-1} + \mathbf{B}\mathbf{D}^{-1}\mathbf{C} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ \mathbf{D}^{-1}\mathbf{C} & \mathbf{1} \end{bmatrix} \quad (\text{UDL}) \quad (2.72)\end{aligned}$$

接着对等式两侧求逆。对于 LDU，有：

$$\begin{aligned} & \begin{bmatrix} A^{-1} & -B \\ C & D \end{bmatrix}^{-1} \\ &= \begin{bmatrix} 1 & AB \\ 0 & 1 \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & (D + CAB)^{-1} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -CA & 1 \end{bmatrix} \\ &= \begin{bmatrix} A - AB(D + CAB)^{-1}CA & AB(D + CAB)^{-1} \\ -(D + CAB)^{-1}CA & (D + CAB)^{-1} \end{bmatrix} \end{aligned} \quad (2.73)$$

对于 UDL，有：

$$\begin{aligned} & \begin{bmatrix} A^{-1} & -B \\ C & D \end{bmatrix}^{-1} \\ &= \begin{bmatrix} 1 & 0 \\ -D^{-1}C & 1 \end{bmatrix} \begin{bmatrix} (A^{-1} + BD^{-1}C)^{-1} & 0 \\ 0 & D^{-1} \end{bmatrix} \begin{bmatrix} 1 & BD^{-1} \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} (A^{-1} + BD^{-1}C)^{-1} & (A^{-1} + BD^{-1}C)^{-1}BD^{-1} \\ -D^{-1}C(A^{-1} + BD^{-1}C)^{-1} & D^{-1} - D^{-1}C(A^{-1} + BD^{-1}C)^{-1}BD^{-1} \end{bmatrix} \end{aligned} \quad (2.74)$$

对比等式 (2.73) 和等式 (2.74) 的结果，得到如下恒等式：

$$(A^{-1} + BD^{-1}C)^{-1} \equiv A - AB(D + CAB)^{-1}CA \quad (2.75a)$$

$$(D + CAB)^{-1} \equiv D^{-1} - D^{-1}C(A^{-1} + BD^{-1}C)^{-1}BD^{-1} \quad (2.75b)$$

$$AB(D + CAB)^{-1} \equiv (A^{-1} + BD^{-1}C)^{-1}BD^{-1} \quad (2.75c)$$

$$(D + CAB)^{-1}CA \equiv D^{-1}C(A^{-1} + BD^{-1}C)^{-1} \quad (2.75d)$$

在处理高斯概率密度函数的协方差矩阵时，这些恒等式会被频繁地用到。

8. 高斯分布随机变量的非线性变换

现有一个高斯随机变量 x ，有一个非线性变化 $g()$ ，研究 $y=g(x)$ 的概率密度函数变化，即：

$$p(y) = \int_{-\infty}^{\infty} p(y|x) p(x) dx$$

其中

$$p(y|x) = \mathcal{N}(g(x), R)$$

$$p(x) = \mathcal{N}(\mu_x, \Sigma_{xx})$$

- 如果非线性变化是可逆的（即能够求出 $x=f(y)$ ），那可以直接求解出对应的概率密度函数
- 大多数情况下非线性变化是不可逆的，此时可以将其近似线性化处理：

$$g(\mathbf{x}) \approx \mu_y + G(\mathbf{x} - \mu_x)$$

$$G = \left. \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mu_x}$$

$$\mu_y = g(\mu_x)$$

G 是 $g()$ 关于 x 的雅各比矩阵。线性化之后就可以得到上述问题的闭式解（这是一个近似解）

9. 高斯分布的香农信息

其结果是变量的维度 N 。将这个值代回香农信息的表达式中，就得到：

$$\begin{aligned} H(\mathbf{x}) &= \frac{1}{2} \ln((2\pi)^N \det \Sigma) + \frac{1}{2} E[(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)] \\ &= \frac{1}{2} \ln((2\pi)^N \det \Sigma) + \frac{1}{2} N \\ &= \frac{1}{2} (\ln((2\pi)^N \det \Sigma) + N \ln e) \\ &= \frac{1}{2} \ln((2\pi e)^N \det \Sigma) \end{aligned}$$

10. 联合高斯概率密度函数的互信息

假设随机变量 $\mathbf{x} \in \mathbb{R}^N$ 和 $\mathbf{y} \in \mathbb{R}^M$ 的联合高斯分布如下：

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N}(\mu, \Sigma) = \mathcal{N}\left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}\right)$$

将上面计算的香农信息带入到互信息的计算公式中，可以得到：

$$\begin{aligned} I(\mathbf{x}, \mathbf{y}) &= \frac{1}{2} \ln((2\pi e)^N \det \Sigma_{xx}) + \frac{1}{2} \ln((2\pi e)^M \det \Sigma_{yy}) \\ &\quad - \frac{1}{2} \ln((2\pi e)^{M+N} \det \Sigma) \\ &= -\frac{1}{2} \ln\left(\frac{\det \Sigma}{\det \Sigma_{xx} \det \Sigma_{yy}}\right) \end{aligned}$$

舒尔补拆分：

$$\begin{aligned} \det \Sigma &= \det \Sigma_{xx} \det (\Sigma_{yy} - \Sigma_{yx} \Sigma_{xx}^{-1} \Sigma_{xy}) \\ &= \det \Sigma_{yy} \det (\Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}) \end{aligned}$$

最终结果：

$$I(x, y) = -\frac{1}{2} \ln \det (1 - \Sigma_{xx}^{-1} \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx})$$

$$= -\frac{1}{2} \ln \det (1 - \Sigma_{yy}^{-1} \Sigma_{yx} \Sigma_{xx}^{-1} \Sigma_{xy})$$

11. 高斯概率密度函数的克拉美罗下界


◦ ◦ ◦ ◦ ◦

3、高斯过程

满足高斯分布的变量用于表示离散时间的状态量记为：

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

高斯过程是时间 t 上的连续的状态量，其中每个时刻的均值用均值函数刻画，两个不同时刻的方差用协方差函数刻画



很好地讲解了高斯过程：

https://blog.csdn.net/ting_qifengl/article/details/121535264

- 从一个一维高斯分布开始扩展，概率密度函数为：

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (1)$$

- 到多维的高斯分布，假设各维度之间互相独立，其概率密度函数可以表示为每个维度概率密度函数的乘积：

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i) = \frac{1}{(2\pi)^{\frac{n}{2}} \sigma_1 \sigma_2 \dots \sigma_n} \exp\left(-\frac{1}{2} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} + \dots + \frac{(x_n - \mu_n)^2}{\sigma_n^2} \right]\right) \quad (2)$$

使用向量和矩阵表示：

使用向量和矩阵表示上式，令

$$\vec{x} - \vec{\mu} = [x_1 - \mu_1, x_2 - \mu_2, \dots, x_n - \mu_n]^T \quad (3)$$

$$K = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix} \quad (4)$$

则有

$$\sigma_1 \sigma_2 \dots \sigma_n = |K|^{\frac{1}{2}} \quad (5)$$

$$\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} + \dots + \frac{(x_n - \mu_n)^2}{\sigma_n^2} = (\vec{x} - \vec{\mu})^T K^{-1} (\vec{x} - \vec{\mu}) \quad (6)$$

将公式 (5) 和公式 (6) 代入公式 (2) 可得

$$p(\vec{x}) = (2\pi)^{-\frac{n}{2}} |K|^{-\frac{1}{2}} \exp\left(-\frac{1}{2} (\vec{x} - \vec{\mu})^T K^{-1} (\vec{x} - \vec{\mu})\right) \quad (7)$$

简写为：

$$x \sim N(\vec{\mu}, K) \quad (8)$$

- 再到高斯过程：是多维高斯分布的扩展，假设在连续空间的每一个点都是符合高斯分布的随机变量，所以从一个点或者点集的分布变为了函数的分布，可以说对高斯分布的一个任意的有限采样就是一个多维高斯分布。

一个高斯过程被一个均值函数和协方差函数唯一地定义，并且一个高斯过程的有限维度的子集都服从一个多元高斯分布（为了方便理解，可以想象二元高斯分布两个维度各自都服从一个高斯分布）。

高斯分布，则称 f 是一个高斯过程，表示为：

$$f(\vec{x}) \sim N(\mu(x), K(x, x)) \quad (9)$$

它的协方差函数（表示任意两个点之间的相关程度）就是其核函数

第三章 线性高斯系统的状态估计

1、离散时间的批量估计问题

1. 问题定义

第三章基本只考虑离散时间线性时变的方程，定义运动和观测模型如下：

$$\text{运动方程: } \mathbf{x}_k = \mathbf{A}_{k-1}\mathbf{x}_{k-1} + \mathbf{v}_k + \mathbf{w}_k, \quad k = 1 \dots K$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{C}_k\mathbf{x}_k + \mathbf{n}_k, \quad k = 0 \dots K$$

其中 k 为时间下标，最大值为 K 。各变量的含义如下：

系统状态: $\mathbf{x}_k \in \mathbb{R}^N$

初始状态: $\mathbf{x}_0 \in \mathbb{R}^N \sim \mathcal{N}(\check{\mathbf{x}}_0, \check{\mathbf{P}}_0)$

输入: $\mathbf{v}_k \in \mathbb{R}^N$

过程噪声: $\mathbf{w}_k \in \mathbb{R}^N \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$

测量: $\mathbf{y}_k \in \mathbb{R}^M$

测量噪声: $\mathbf{n}_k \in \mathbb{R}^M \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$

除了输入 $\mathbf{v}_k$ 是确定变量，其他都是随机变量； $\mathbf{A}_k$ 称为转移矩阵， $\mathbf{C}_k$ 称为观测矩阵。

所以该情况下的状态估计问题可以定义为：

在 k 个（一个或多个）时间点上，基于初始的状态信息 $\mathbf{x}_0$ 、一系列观测数据 $\mathbf{y}$ ，一系列输入 $\mathbf{v}$ ，以及系统的运动和观测模型，来计算系统的真实状态的估计值 $\mathbf{x}_k$ 。不止计算状态的估计值，也计算它的不确定性。

为了显示各种方法之间的联系，从两个不同的途径着手解决批量 LG 系统的估计问题：

- **贝叶斯推断** (Bayesian inference) 我们从状态的先验概率密度函数出发，通过初始状态、输入、运动方程和观测数据，计算状态的后验概率密度函数。
- **最大后验估计** (Maximum A Posteriori, MAP) 我们也可以用优化理论，来寻找给定信息下（初始状态、输入、观测）的最大后验估计。

尽管上述两种方法本质上是不同的，但是对 LG 系统，它们将给出同样的结论。主要原因是在 LG 系统中，贝叶斯后验概率正好是高斯的。所以优化方法会找到高斯分布的最大值（也就是它的模 (mode) ），这也正是高斯的均值。当步入非线性、非高斯领域之后，一个分布的均值和模将不再重合，使得这两类方法给出不同的答案。

2. 最大后验估计

在批量估计中，MAP 的目标是求解这样一个问题：

$$\hat{\mathbf{x}} = \arg \max_{\mathbf{x}} p(\mathbf{x}|\mathbf{v}, \mathbf{y})$$

希望在给定先验信息和所有时刻的运动 $\mathbf{v}$ 、观测 $\mathbf{y}$ 的情况下，推测出所有时刻的最优状态 $\mathbf{x}$ 。

- 首先用贝叶斯公式重写MAP

$$\hat{\mathbf{x}} = \arg \max_{\mathbf{x}} p(\mathbf{x}|\mathbf{v}, \mathbf{y}) = \arg \max_{\mathbf{x}} \frac{p(\mathbf{y}|\mathbf{x}, \mathbf{v}) p(\mathbf{x}|\mathbf{v})}{p(\mathbf{y}|\mathbf{v})} = \arg \max_{\mathbf{x}} p(\mathbf{y}|\mathbf{x}) p(\mathbf{x}|\mathbf{v}) \quad (3.3)$$

这里我们把分母略去，因为它和 $\mathbf{x}$ 无关。同时省略 $p(\mathbf{y}|\mathbf{x}, \mathbf{v})$ 中的 $\mathbf{v}$ ，因为如果 $\mathbf{x}$ 已知，它不会影响观测数据（观测方程与它无关）。

- 假设噪声变量 $\mathbf{w}_k$ 和 $\mathbf{n}_k$ 都是无关的，所以可以对 $p(\mathbf{y}|\mathbf{x})$ 因子分解（联合概率可以由独立的条件概率乘积表示）

$$p(\mathbf{y}|\mathbf{x}) = \prod_{k=0}^K p(\mathbf{y}_k|\mathbf{x}_k)$$

同理 $p(\mathbf{x}|\mathbf{v})$ 可以分解为（初始时刻的先验 $\mathbf{x}_0$ 就是被当作输入 $\mathbf{v}$ 的一部分，因此要有专门一项）

$$p(\mathbf{x}|\mathbf{v}) = p(\mathbf{x}_0|\tilde{\mathbf{x}}_0) \prod_{k=1}^K p(\mathbf{x}_k|\mathbf{x}_{k-1}, \mathbf{v}_k)$$

- 展开上一步中的内容：

在线性系统中，高斯密度函数可展开为：

$$p(\mathbf{x}_0|\tilde{\mathbf{x}}_0) = \frac{1}{\sqrt{(2\pi)^N \det \tilde{\mathbf{P}}_0}} \times \exp \left(-\frac{1}{2} (\mathbf{x}_0 - \tilde{\mathbf{x}}_0)^T \tilde{\mathbf{P}}_0^{-1} (\mathbf{x}_0 - \tilde{\mathbf{x}}_0) \right) \quad (3.6a)$$

$$p(\mathbf{x}_k|\mathbf{x}_{k-1}, \mathbf{v}_k) = \frac{1}{\sqrt{(2\pi)^N \det \mathbf{Q}_k}} \times \exp \left(-\frac{1}{2} (\mathbf{x}_k - \mathbf{A}_{k-1}\mathbf{x}_{k-1} - \mathbf{v}_k)^T \mathbf{Q}_k^{-1} (\mathbf{x}_k - \mathbf{A}_{k-1}\mathbf{x}_{k-1} - \mathbf{v}_k) \right) \quad (3.6b)$$

$$p(\mathbf{y}_k|\mathbf{x}_k) = \frac{1}{\sqrt{(2\pi)^M \det \mathbf{R}_k}} \times \exp \left(-\frac{1}{2} (\mathbf{y}_k - \mathbf{C}_k\mathbf{x}_k)^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{C}_k\mathbf{x}_k) \right) \quad (3.6c)$$

状态 $\mathbf{x}_0$ 服从一个均值为先验 $\tilde{\mathbf{x}}_0$ ，方差为 $\tilde{\mathbf{P}}_0$ 的高斯分布；下两项同理，根据转移方程和观测方程，可以得到 $\mathbf{x}_k$ 和 $\mathbf{y}_k$ 分别都是 $\mathbf{x}_{k-1}$ 的线性变换，应该也满足高斯性质

- 对整体等式取对数

$$\ln(p(\mathbf{y}|\mathbf{x})p(\mathbf{x}|\mathbf{v})) = \ln p(\mathbf{x}_0|\check{\mathbf{x}}_0) + \sum_{k=1}^K \ln p(\mathbf{x}_k|\mathbf{x}_{k-1}, \mathbf{v}_k) + \sum_{k=0}^K \ln p(\mathbf{y}_k|\mathbf{x}_k)$$

这个过程中:

$$\begin{aligned} \ln p(\mathbf{x}_0|\check{\mathbf{x}}_0) = & -\frac{1}{2}(\mathbf{x}_0 - \check{\mathbf{x}}_0)^T \check{\mathbf{P}}_0^{-1}(\mathbf{x}_0 - \check{\mathbf{x}}_0) \\ & - \underbrace{\frac{1}{2} \ln((2\pi)^N \det \check{\mathbf{P}}_0)}_{\text{与 } \mathbf{x} \text{ 无关}} \end{aligned} \quad (3.8a)$$

$$\begin{aligned} \ln p(\mathbf{x}_k|\mathbf{x}_{k-1}, \mathbf{v}_k) = & -\frac{1}{2}(\mathbf{x}_k - \mathbf{A}_{k-1}\mathbf{x}_{k-1} - \mathbf{v}_k)^T \mathbf{Q}_k^{-1}(\mathbf{x}_k - \mathbf{A}_{k-1}\mathbf{x}_{k-1} - \mathbf{v}_k) \\ & - \underbrace{\frac{1}{2} \ln((2\pi)^N \det(\mathbf{Q}_k))}_{\text{与 } \mathbf{x} \text{ 无关}} \end{aligned} \quad (3.8b)$$

$$\begin{aligned} \ln p(\mathbf{y}_k|\mathbf{x}_k) = & -\frac{1}{2}(\mathbf{y}_k - \mathbf{C}_k\mathbf{x}_k)^T \mathbf{R}_k^{-1}(\mathbf{y}_k - \mathbf{C}_k\mathbf{x}_k) \\ & - \underbrace{\frac{1}{2} \ln((2\pi)^M \det \mathbf{R}_k)}_{\text{与 } \mathbf{x} \text{ 无关}} \end{aligned} \quad (3.8c)$$

注意到式 (3.8) 中出现了一些与 $\mathbf{x}$ 无关的项, 可以把它们忽略掉。因此, 定义下面这些量:

$$J_{v,k}(\mathbf{x}) = \begin{cases} \frac{1}{2}(\mathbf{x}_0 - \check{\mathbf{x}}_0)^T \check{\mathbf{P}}_0^{-1}(\mathbf{x}_0 - \check{\mathbf{x}}_0), & k = 0 \\ \frac{1}{2}(\mathbf{x}_k - \mathbf{A}_{k-1}\mathbf{x}_{k-1} - \mathbf{v}_k)^T \mathbf{Q}_k^{-1}(\mathbf{x}_k - \mathbf{A}_{k-1}\mathbf{x}_{k-1} - \mathbf{v}_k), & k = 1 \dots K \end{cases} \quad (3.9a)$$

$$J_{y,k}(\mathbf{x}) = \frac{1}{2}(\mathbf{y}_k - \mathbf{C}_k\mathbf{x}_k)^T \mathbf{R}_k^{-1}(\mathbf{y}_k - \mathbf{C}_k\mathbf{x}_k), \quad k = 0 \dots K \quad (3.9b)$$

这些都是平方马氏距离 (Mahalanobis distance)。然后我们就可以定义整体的目标函数 (Objective function) $J(\mathbf{x})$ 。通过最小化这个目标函数, 我们来求解自变量 $\mathbf{x}$ 的值:

$$J(\mathbf{x}) = \sum_{k=0}^K (J_{v,k}(\mathbf{x}) + J_{y,k}(\mathbf{x})) \quad (3.10)$$

- 提升形式, 将所有时候已知的数据组成一个向量 $\mathbf{z}$, 把所有时刻的状态组成一个向量 $\mathbf{x}$

$$\mathbf{z} = \begin{bmatrix} \check{\mathbf{x}}_0 \\ \mathbf{v}_1 \\ \vdots \\ \mathbf{v}_K \\ \mathbf{y}_0 \\ \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_K \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} \mathbf{x}_0 \\ \vdots \\ \mathbf{x}_K \end{bmatrix}$$

然后，定义以下的块矩阵：

$$H = \begin{bmatrix} 1 & & & & \\ -A_0 & 1 & & & \\ & \ddots & \ddots & & \\ & & -A_{K-1} & 1 & \\ C_0 & & & & \end{bmatrix} \quad (3.13a)$$

$$W = \begin{bmatrix} \tilde{P}_0 & & & \\ & Q_1 & & \\ & & \ddots & \\ & & & Q_K \\ & & & & R_0 \\ & & & & R_1 \\ & & & & & \ddots \\ & & & & & & R_K \end{bmatrix} \quad (3.13b)$$

该式只显示了非零块，分割线用以区分矩阵的不同部分，例如先验信息、输入 $\mathbf{v}$ 、测量 $\mathbf{y}$ 以及提升形式的 $\mathbf{z}$ 。根据上面这些定义，我们把目标函数写成：

$$J(\mathbf{x}) = \frac{1}{2}(\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{W}^{-1}(\mathbf{z} - \mathbf{H}\mathbf{x}) \quad (3.14)$$

求解过程变成了找到这个函数的最小值，就是让目标函数对于自变量的偏导数为0即可

$$\begin{aligned} \left. \frac{\partial J(\mathbf{x})}{\partial \mathbf{x}^T} \right|_{\hat{\mathbf{x}}} &= -\mathbf{H}^T \mathbf{W}^{-1}(\mathbf{z} - \mathbf{H}\hat{\mathbf{x}}) = \mathbf{0} \\ \Rightarrow (\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}) \hat{\mathbf{x}} &= \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z} \end{aligned}$$

3. 贝叶斯推断

在这个情况下，可以用初始状态和输入来建立状态的先验估计： $p(\mathbf{x}|\mathbf{v})$ 。用运动方程来建立先验：

$$\mathbf{x}_k = \mathbf{A}_{k-1} \mathbf{x}_{k-1} + \mathbf{v}_k + \mathbf{w}_k \quad (3.17)$$

在提升形式中^[6]，可以写成：

$$\mathbf{x} = \mathbf{A}(\mathbf{v} + \mathbf{w}) \quad (3.18)$$

这里 w 也是初始状态和运动噪声的提升形式，同时，

$$A = \begin{bmatrix} 1 & & & & \\ A_0 & 1 & & & \\ A_1 A_0 & A_1 & 1 & & \\ \vdots & \vdots & \vdots & \ddots & \\ A_{K-2} \cdots A_0 & A_{K-2} \cdots A_1 & A_{K-2} \cdots A_2 & \cdots & 1 \\ A_{K-1} \cdots A_0 & A_{K-1} \cdots A_1 & A_{K-1} \cdots A_2 & \cdots & A_{K-1} & 1 \end{bmatrix}$$

提升后的均值方差为：

$$\tilde{x} = E[x] = E[A(v + w)] = Av$$

$$\tilde{P} = E[(x - E[x])(x - E[x])^T] = AQA^T$$

再看观测模型和它的提升形式

$$y_k = C_k x_k + n_k$$

$$y = Cx + n$$

$$p(x|v) = \mathcal{N}(\tilde{x}, \tilde{P}) = \mathcal{N}(Av, AQA^T)$$

是提升后的观测矩阵。于是，提升之后的状态、观测联合概率密度函数可写成：

$$p(x, y|v) = \mathcal{N}\left(\begin{bmatrix} \tilde{x} \\ C\tilde{x} \end{bmatrix}, \begin{bmatrix} \tilde{P} & \tilde{P}C^T \\ C\tilde{P} & C\tilde{P}C^T + R \end{bmatrix}\right) \quad (3.26)$$

这里 $R = E[nn^T] = \text{diag}(R_0, R_1, \dots, R_K)$ 。这个式子可以因式分解：

$$p(x, y|v) = p(x|v, y)p(y|v) \quad (3.27)$$

我们只关心第一个因子，它表示了全贝叶斯后验概率。这一项可以用 2.2.3 节的方法，重写成：

$$p(x|v, y) = \mathcal{N}\left(\tilde{x} + \tilde{P}C^T(C\tilde{P}C^T + R)^{-1}(y - C\tilde{x}), \tilde{P} - \tilde{P}C^T(C\tilde{P}C^T + R)^{-1}C\tilde{P}\right) \quad (3.28)$$

看不懂了。。。。。。贴原文

利用式 (2.75) 中的 SMW 恒等式^[4]，可将上式转换成：

$$p(\mathbf{x}|\mathbf{v}, \mathbf{y}) = \mathcal{N}\left(\underbrace{(\check{\mathbf{P}}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})^{-1}}_{\text{即均值 } \hat{\mathbf{x}}} (\check{\mathbf{P}}^{-1} \check{\mathbf{x}} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{y}), \underbrace{(\check{\mathbf{P}}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})^{-1}}_{\text{即后验协方差 } \hat{\mathbf{P}}}\right) \quad (3.29)$$

事实上，基于这个等式就能实现一个贝叶斯估计器，因为它代表了全贝叶斯后验概率，但这种做法不高效。

为显示此方法与之前讲的优化方法的联系，我们来整理均值项，让它成为 $\hat{\mathbf{x}}$ 的线性函数：

$$\underbrace{(\check{\mathbf{P}}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})}_{\hat{\mathbf{P}}^{-1}} \hat{\mathbf{x}} = \check{\mathbf{P}}^{-1} \check{\mathbf{x}} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{y} \quad (3.30)$$

可见，左侧出现了先验的协方差矩阵的逆。代入 $\check{\mathbf{x}} = \mathbf{A}\mathbf{v}$ 和 $\check{\mathbf{P}}^{-1} = (\mathbf{A}\mathbf{Q}\mathbf{A}^T)^{-1} = \mathbf{A}^{-T}\mathbf{Q}^{-1}\mathbf{A}^{-1}$ ，可以将它重写成：

$$\underbrace{(\mathbf{A}^{-T}\mathbf{Q}^{-1}\mathbf{A}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})}_{\hat{\mathbf{P}}^{-1}} \hat{\mathbf{x}} = \mathbf{A}^{-T}\mathbf{Q}^{-1}\mathbf{v} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{y} \quad (3.31)$$

这里需要计算 $\mathbf{A}^{-1}$ ，不过它正好有个很好看的形式^[12]：

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & & & & \\ -\mathbf{A}_0 & 1 & & & \\ & -\mathbf{A}_1 & 1 & & \\ & & -\mathbf{A}_2 & \ddots & \\ & & & \ddots & 1 \\ & & & & -\mathbf{A}_{K-1} & 1 \end{bmatrix} \quad (3.32)$$

它仍是个下三角矩阵，但形式非常稀疏（仅有主对角线和下方的一块非零）。如果定义：

$$\mathbf{z} = \begin{bmatrix} \mathbf{v} \\ \mathbf{y} \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} \mathbf{A}^{-1} \\ \mathbf{C} \end{bmatrix}, \quad \mathbf{W} = \begin{bmatrix} \mathbf{Q} & \\ & \mathbf{R} \end{bmatrix} \quad (3.33)$$

就可以把系统写成：

$$(\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}) \hat{\mathbf{x}} = \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z} \quad (3.34)$$

4. 存在性，唯一性和能观性

上面论述的结论是线性高斯系统的状态求解目标就是如下等式

$$(\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}) \hat{\mathbf{x}} = \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z}$$

$\mathbf{x}$ 存在唯一解，当且仅当

$$H^T W^{-1} H$$

是可逆的， W 是实对称正定矩阵，所以只需要保证 H 的秩为 $K+1$,也就是有 $K+1$ 个线性无关的行/列向量。

分为两种情况讨论：

- 有初始状态的先验信息 x_0

将 H^T 展开，我们需要检测秩的矩阵为：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{cccc|cccc} 1 & -A_0^T & & & C_0^T & & & \\ & 1 & -A_1^T & & & C_1^T & & \\ & & 1 & \ddots & & & C_2^T & \\ & & & \ddots & -A_{K-1}^T & & & \ddots \\ & & & & 1 & & & C_K^T \end{array} \right] \quad (3.38)$$

这是一个阶梯形矩阵。显然它每一行都是线性无关的，这意味着该矩阵是满秩的。所以，我们能够得到一个唯一解 $\hat{x}$ ，只需：

$$\tilde{P}_0 > 0, \quad Q_k > 0 \quad (3.39)$$

这里 > 0 意味着矩阵是正定的（因此也是可逆的）。直观上说，因为先验已经给出了系统的一个解，我们只是用观测来修正它。请注意这只是充分但不是必要的条件。

- 没有初始状态先验

H^T 中每一列中的块都表示了一部分有关系统的信息，而第一列的块表达我们对初始状态的信息。因此，去掉第一列之后，变为：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{c|ccc} -A_0^T & & & \\ \hline 1 & -A_1^T & & \\ & 1 & \ddots & \\ & & \ddots & -A_{K-1}^T \\ & & & 1 \end{array} \middle| \begin{array}{c} C_0^T \\ C_1^T \\ C_2^T \\ \vdots \\ C_K^T \end{array} \right] \quad (3.40)$$

这个矩阵有 $K + 1$ 个行（每块大小为 N ）。将最上一行移到最下（这不会改变矩阵的秩），得：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{c|ccc} 1 & -A_1^T & & \\ & 1 & \ddots & \\ & & \ddots & -A_{K-1}^T \\ & & & 1 \\ \hline -A_0^T & & & \end{array} \middle| \begin{array}{c} C_1^T \\ C_2^T \\ \vdots \\ C_K^T \\ C_0^T \end{array} \right] \quad (3.41)$$

那么，除去最后一行，这个矩阵仍是梯形矩阵。同理，在不影响秩的前提下，我们可以用 A_0^T 乘最后一行，然后加到最后一行上；再用 $A_0^T A_1^T$ 乘第二行，加到最后一行上……最后用 $A_0^T A_1^T \dots A_{K-1}^T$ 乘倒数第二行，加到最后一行，得到：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{c|ccc} 1 & -A_1^T & & \\ & 1 & \ddots & \\ & & \ddots & -A_{K-1}^T \\ & & & 1 \\ \hline & & & \end{array} \middle| \begin{array}{c} C_1^T \\ C_2^T \\ \vdots \\ C_K^T \\ C_0^T + A_0^T C_1^T + A_0^T A_1^T C_2^T + \dots + A_0^T \dots A_{K-1}^T C_K^T \end{array} \right] \quad (3.42)$$

检查最终的表达式，可见左下角块为零，同时，左上角块是梯形矩阵，所以是满秩的（每一行有一个领头的非零块）。于是，对 H^T 的秩判定，归结于右下角部分是否为秩 N ：

$$\text{rank} \left[\begin{array}{cccc} C_0^T & A_0^T C_1^T & A_0^T A_1^T C_2^T & \dots & A_0^T \dots A_{K-1}^T C_K^T \end{array} \right] = N \quad (3.43)$$

2、离散时间的递归平滑算法

暴力求解前面的线性方程非常低效，等式左侧的逆协方差矩阵有稀疏结构（对角块），我们可以利用这个性质加速方程的求解：一次前向递推和一次后向递推。这样的做法被称为典型的固定区间平滑算法（fixed-interval smoother）。

如前所述，式 (3.34) 左侧的 $H^T W^{-1} H$ 是一个三对角块（当 x 的变量按时间顺序排列时）：

$$H^T W^{-1} H = \begin{bmatrix} * & * & & & \\ * & * & * & & \\ & * & * & * & \\ & & \ddots & \ddots & \ddots \\ & & & * & * & * \\ & & & & * & * \end{bmatrix} \quad (3.55)$$

此处 $*$ 表示非零块。有一些求解器可以高效地在这种结构的线性方程中解出 $\hat{x}$ 。

André Louis Cholesky (1875—1918) 是法国军官，也是一位数学家。他主要的贡献是一种特殊的矩阵分解，用于他在军队中的制图工作。Cholesky 分解是指，将一个共轭对称正定矩阵 A ，分解成 $A = LL^*$ ，其中 L 是一个下三角矩阵，对角线上为正实数。 L^* 为 L 的共轭转置。任意一个共轭对称的正定矩阵（因而也是实对称正定矩阵）都有唯一的 Cholesky 分解。

这个分解的复杂度是 $O(N(K+1))$ 。然后，求解

$$Ld = H^T W^{-1} z \quad (3.58)$$

得到 d 。这也是一个 $O(N(K+1))$ 的操作，因为可以从上往下求解 d 的每一项，再把结果代入下一行中。这个操作称为前向迭代（forward pass）。然后，求解

$$L^T \hat{x} = d \quad (3.59)$$

1. cholesky平滑算法

- 前向：先假设 L 形式，求解出 d
- 后向：根据 d 求解出 x

对于中间量 I_k 和 q_k ，我们能够综合前向与后向两步（即解 L 和 d 的过程），将它们写成：

前向： $k = 1 \dots K$

$$L_{k-1}L_{k-1}^T = I_{k-1} + A_{k-1}^T Q_k^{-1} A_{k-1} \quad (3.66a)$$

$$L_{k-1}d_{k-1} = q_{k-1} - A_{k-1}^T Q_k^{-1} v_k \quad (3.66b)$$

$$L_{k,k-1}L_{k-1}^T = -Q_k^{-1} A_{k-1} \quad (3.66c)$$

$$I_k = -L_{k,k-1}L_{k,k-1}^T + Q_k^{-1} + C_k^T R_k^{-1} C_k \quad (3.66d)$$

$$q_k = -L_{k,k-1}d_{k-1} + Q_k^{-1} v_k + C_k^T R_k^{-1} y_k \quad (3.66e)$$

后向： $k = K \dots 1$

$$L_{k-1}^T \hat{x}_{k-1} = -L_{k,k-1}^T \hat{x}_k + d_{k-1} \quad (3.66f)$$

这些量的初始值为：

$$I_0 = \check{P}_0^{-1} + C_0^T R_0^{-1} C_0 \quad (3.67a)$$

$$q_0 = \check{P}_0^{-1} \check{x}_0 + C_0^T R_0^{-1} y_0 \quad (3.67b)$$

$$\hat{x}_K = L_K^{-T} d_K \quad (3.67c)$$

2. Rauch-Tung-Striebel (RTS) 平滑算法

cholesky平滑等价与RTS平滑

综上所述，式 (3.69a)，式 (3.71)，式 (3.76a)，式 (3.78)，式 (3.81) 构成了 Rauch-Tung-Striebel 平滑算法：

前向： $k = 1 \dots K$

$$\check{P}_{k,f} = A_{k-1} \hat{P}_{k-1,f} A_{k-1}^T + Q_k \quad (3.82a)$$

$$\check{x}_{k,f} = A_{k-1} \hat{x}_{k-1,f} + v_k \quad (3.82b)$$

$$K_k = \check{P}_{k,f} C_k^T (C_k \check{P}_{k,f} C_k^T + R_k)^{-1} \quad (3.82c)$$

$$\hat{P}_{k,f} = (1 - K_k C_k) \check{P}_{k,f} \quad (3.82d)$$

$$\hat{x}_{k,f} = \check{x}_{k,f} + K_k (y_k - C_k \check{x}_{k,f}) \quad (3.82e)$$

后向： $k = K \dots 1$

$$\hat{x}_{k-1} = \hat{x}_{k-1,f} + \hat{P}_{k-1,f} A_{k-1}^T \check{P}_{k,f}^{-1} (\hat{x}_k - \check{x}_{k,f}) \quad (3.82f)$$

它们的初始值为：

$$\check{P}_{0,f} = \check{P}_0 \quad (3.83a)$$

$$\check{x}_{0,f} = \check{x}_0 \quad (3.83b)$$

$$\hat{x}_K = \hat{x}_{K,f} \quad (3.83c)$$

3、离散时间的递归滤波算法

前面介绍的批量优化的方案（以及对应的平滑算法方案），是我们在 LG 问题下能够找到的最好的方法了。它利用了所有能用到的数据，来估计所有时刻的状态。不过这种方法有一个致命的问题：它无法在线运行（online），因为它需要用未来时刻的信息估计过去的状态

为了在实时场合使用，当前时刻的状态只能由它之前时间的信息决定，而**卡尔曼滤波**则是对这样一个问题的传统解决方案。

为了把结论写成递归的形式，我们重新排列一下批量优化中的一些变量。将 z, H, W 重新定义成：

$$z = \begin{bmatrix} \tilde{x}_0 \\ y_0 \\ v_1 \\ y_1 \\ v_2 \\ y_2 \\ \vdots \\ v_K \\ y_K \end{bmatrix}, \quad H = \begin{bmatrix} 1 & & & & \\ C_0 & & & & \\ -A_0 & 1 & & & \\ & C_1 & & & \\ -A_1 & 1 & & & \\ & & C_2 & & \\ & & \ddots & \ddots & \\ & & & -A_{K-1} & 1 \\ & & & & C_K \end{bmatrix}, \quad (3.84)$$

$$W = \begin{bmatrix} \tilde{P}_0 & & & & \\ & R_0 & & & \\ & & Q_1 & & \\ & & & R_1 & \\ & & & & Q_2 \\ & & & & & R_2 \\ & & & & & & \ddots \\ & & & & & & & Q_K \\ & & & & & & & & R_K \end{bmatrix}$$

其中分割线区分了不同时刻的变量。请注意这个重排并不影响系统状态 x ，所以 $H^T W^{-1} H$ 仍是三对角块形式。

为了实现分解，我们要用到 3.2.1 节中 H 的稀疏结构。首先把 H 分解成 12 个块（仅有 6 个块非零）：

$$H = \begin{bmatrix} H_{11} & & & \\ H_{21} & H_{22} & & \\ & H_{32} & H_{33} & \\ & & H_{43} & \end{bmatrix} \quad \begin{array}{l} \text{从 } 0 \dots k-1 \text{ 的信息} \\ k \text{ 时刻的信息} \\ k+1 \text{ 时刻的信息} \\ \text{从 } k+2 \dots K \text{ 的信息} \end{array} \quad (3.87)$$

$\uparrow$ 从 $k+1 \dots K$ 的状态
 $\uparrow$ k 时刻的状态
 $\uparrow$ 从 $0 \dots k-1$ 的状态

该矩阵的每一行和每一列的含义如上所示。例如，对于 $k=2, K=4$ 的情况，矩阵分块为：

$$H = \begin{bmatrix} 1 & & & & \\ C_0 & & & & \\ -A_0 & 1 & & & \\ & C_1 & & & \\ & -A_1 & 1 & & \\ & & C_2 & & \\ & & -A_2 & 1 & \\ & & & C_3 & \\ & & & -A_3 & 1 \\ & & & & C_4 \end{bmatrix} \quad (3.88)$$

把 z 和 W 也划分为同样的形式：

$$z = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \\ z_4 \end{bmatrix}, \quad W = \begin{bmatrix} W_1 & & & \\ & W_2 & & \\ & & W_3 & \\ & & & W_4 \end{bmatrix} \quad (3.89)$$

那么，矩阵 $H^T W^{-1} H$ ，具体计算为：

$$\begin{aligned}
 & H^T W^{-1} H \\
 &= \begin{bmatrix} H_{11}^T W_1^{-1} H_{11} + H_{21}^T W_2^{-1} H_{21} & H_{21}^T W_2^{-1} H_{22} & H_{32}^T W_3^{-1} H_{33} \\ H_{22}^T W_2^{-1} H_{21} & H_{22}^T W_2^{-1} H_{22} + H_{32}^T W_3^{-1} H_{32} & H_{32}^T W_3^{-1} H_{33} \\ H_{33}^T W_3^{-1} H_{32} & H_{33}^T W_3^{-1} H_{33} & H_{33}^T W_3^{-1} H_{33} + H_{43}^T W_4^{-1} H_{43} \end{bmatrix} \\
 &= \begin{bmatrix} L_{11} & L_{12} \\ L_{12}^T & L_{22} & L_{32}^T \\ L_{32} & L_{33} \end{bmatrix}
 \end{aligned} \tag{3.90}$$

我们把一些用到的中间变量记作 L_{ij} 。对于 $H^T W^{-1} z$ ，有：

$$H^T W^{-1} z = \begin{bmatrix} H_{11}^T W_1^{-1} z_1 + H_{21}^T W_2^{-1} z_2 \\ H_{22}^T W_2^{-1} z_2 + H_{32}^T W_3^{-1} z_3 \\ H_{33}^T W_3^{-1} z_3 + H_{43}^T W_4^{-1} z_4 \end{bmatrix} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \end{bmatrix} \tag{3.91}$$

同样把一些用到的中间变量定义成 r_i 。然后，将状态变量用以下方式划分：

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_{0:k-1} \\ \mathbf{x}_k \\ \mathbf{x}_{k+1:K} \end{bmatrix} \begin{array}{l} \text{从 } 0 \dots k-1 \text{ 的状态} \\ k \text{ 时刻状态} \\ k+1 \dots K \text{ 时刻状态} \end{array} \tag{3.92}$$

那么整个批量优化的方程变为：

$$\begin{bmatrix} L_{11} & L_{12} \\ L_{12}^T & L_{22} & L_{32}^T \\ L_{32} & L_{33} \end{bmatrix} \begin{bmatrix} \hat{\mathbf{x}}_{0:k-1} \\ \hat{\mathbf{x}}_k \\ \hat{\mathbf{x}}_{k+1:K} \end{bmatrix} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \end{bmatrix} \tag{3.93}$$

不贴原文了，等以后在去琢磨吧，。。。大意就是如何把前向估计（利用k-1前时刻的信息估计k时刻状态）转换为卡尔曼滤波器形式

1. 通过MAP推导卡尔曼滤波

假设现在已经有了k-1时刻的前向估计，以及k时刻的输入和观测 v_k 和 y_k ，目标是计算k时刻的状态和协方差

$$\{\hat{\mathbf{x}}_{k-1}, \hat{P}_{k-1}, v_k, y_k\} \mapsto \{\hat{\mathbf{x}}_k, \hat{P}_k\}$$

为了推导这个过程，定义：

$$\mathbf{z} = \begin{bmatrix} \hat{\mathbf{x}}_{k-1} \\ v_k \\ y_k \end{bmatrix}, \quad H = \begin{bmatrix} \mathbf{1} & 0 \\ -A_{k-1} & \mathbf{1} \\ 0 & C_k \end{bmatrix}, \quad W = \begin{bmatrix} \hat{P}_{k-1} & 0 \\ 0 & Q_k \\ 0 & 0 & R_k \end{bmatrix}$$

目标是求解

$$(H^T W^{-1} H) \hat{x} = H^T W^{-1} z$$

推导过程省略。。。。。

解出最后一式中 K_k 的表达式，就可以将递归滤波重写成：

预测：

$$\check{P}_k = A_{k-1} \hat{P}_{k-1} A_{k-1}^T + Q_k \quad (3.120a)$$

$$\check{x}_k = A_{k-1} \hat{x}_{k-1} + v_k \quad (3.120b)$$

卡尔曼增益：

$$K_k = \check{P}_k C_k^T (C_k \check{P}_k C_k^T + R_k)^{-1} \quad (3.120c)$$

更新：

$$\hat{P}_k = (1 - K_k C_k) \check{P}_k \quad (3.120d)$$

$$\hat{x}_k = \check{x}_k + K_k \underbrace{(y_k - C_k \check{x}_k)}_{\text{更新量}} \quad (3.120e)$$

2. 通过贝叶斯推断推导卡尔曼滤波

终于有一个能看懂的了。。。。

预测过程：

$$\check{P}_k = A_{k-1} \hat{P}_{k-1} A_{k-1}^T + Q_k$$

$$\check{x}_k = A_{k-1} \hat{x}_{k-1} + v_k$$

更新过程：

然后，对于更新部分，我们将状态与最近的一次测量（即 k 时刻）写成联合高斯分布的形式：

$$\begin{aligned} p(x_k, y_k | \check{x}_0, v_{1:k}, y_{0:k-1}) &= \mathcal{N} \left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix} \right) \\ &= \mathcal{N} \left(\begin{bmatrix} \check{x}_k \\ C_k \check{x}_k \end{bmatrix}, \begin{bmatrix} \check{P}_k & \check{P}_k C_k^T \\ C_k \check{P}_k & C_k \check{P}_k C_k^T + R_k \end{bmatrix} \right) \end{aligned} \quad (3.126)$$

回顾 2.2.3 节引入的贝叶斯推断，我们可以直接将 x_k 的条件分布（即后验概率）写成：

$$p(x_k | \check{x}_0, v_{1:k}, y_{0:k}) = \mathcal{N} \left(\underbrace{\mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y_k - \mu_y)}_{\hat{x}_k}, \underbrace{\Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}}_{\hat{P}_k} \right) \quad (3.127)$$

见公式2.53b

这个部分可以看slam14讲的推导

3. 从增益最优化的角度来看卡尔曼滤波

后面先省略。。。。见原文吧，也是推导，记住结论性的东西就好

4、连续时间的批量估计问题

从高斯过程回归的角度来解决运动模型为连续时间的情况。

https://blog.csdn.net/ting_qifengl/article/details/121535264

1. 高斯过程回归

考虑连续时间的高斯过程作为运动模型，同时观测模型是离散时间、线性的模型：

$$\mathbf{x}(t) \sim \mathcal{GP}(\tilde{\mathbf{x}}(t), \tilde{\mathbf{P}}(t, t')), \quad t_0 < t, t' \quad (3.146)$$

$$\mathbf{y}_k = \mathbf{C}_k \mathbf{x}(t_k) + \mathbf{n}_k, \quad t_0 < t_1 < \dots < t_K \quad (3.147)$$

其中 $\mathbf{x}(t)$ 为状态， $\tilde{\mathbf{x}}_t$ 是期望函数， $\tilde{\mathbf{P}}(t, t')$ 是协方差函数， $\mathbf{y}_k$ 是测量， $\mathbf{n}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$ 为高斯测量噪声， $\mathbf{C}_k$ 是测量模型的参数。

定义：高斯过程回归是使用高斯过程先验对数据进行回归分析的非参数模型（指系统的数学模型中非显式地包含可估参数）。简单来讲就是根据先验+观测值推出后验的过程。

现在设我们希望在某些时间点 ($\tau_0 < \tau_1 < \dots < \tau_J$) 上对状态进行查询。这些时间点可能与测量时刻 ($t_0 < t_1 < \dots < t_K$) 相同, 也可能不相同。图 3-6 描述了这个问题的。那么, 各时间点上的状态与所有 (在测量时刻点上的) 测量的联合分布, 可以写成:

$$p\left(\begin{bmatrix} \mathbf{x}_\tau \\ \mathbf{y} \end{bmatrix}\right) = \mathcal{N}\left(\begin{bmatrix} \tilde{\mathbf{x}}_\tau \\ C\tilde{\mathbf{x}} \end{bmatrix}, \begin{bmatrix} \tilde{P}_{\tau\tau} & \tilde{P}_\tau C^T \\ C\tilde{P}_\tau^T & R + C\tilde{P}_\tau C^T \end{bmatrix}\right) \quad (3.148)$$

其中:

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}(t_0) \\ \vdots \\ \mathbf{x}(t_K) \end{bmatrix}, \quad \tilde{\mathbf{x}} = \begin{bmatrix} \tilde{\mathbf{x}}(t_0) \\ \vdots \\ \tilde{\mathbf{x}}(t_K) \end{bmatrix}, \quad \mathbf{x}_\tau = \begin{bmatrix} \mathbf{x}(\tau_0) \\ \vdots \\ \mathbf{x}(\tau_J) \end{bmatrix}, \quad \tilde{\mathbf{x}}_\tau = \begin{bmatrix} \tilde{\mathbf{x}}(\tau_0) \\ \vdots \\ \tilde{\mathbf{x}}(\tau_J) \end{bmatrix}$$

$$\mathbf{y} = \begin{bmatrix} \mathbf{y}_0 \\ \vdots \\ \mathbf{y}_K \end{bmatrix}, \quad C = \text{diag}(C_0, \dots, C_K), \quad R = \text{diag}(R_0, \dots, R_K)$$

$$\tilde{P} = [\tilde{P}(t_i, t_j)]_{ij}, \quad \tilde{P}_\tau = [\tilde{P}(\tau_i, t_j)]_{ij}, \quad \tilde{P}_{\tau\tau} = [\tilde{P}(\tau_i, \tau_j)]_{ij}$$

在高斯回归中, 矩阵 $\tilde{P}$ 称为核矩阵 (kernel matrix)。基于 2.2.3 节讨论的分解式, 有:

$$p(\mathbf{x}_\tau | \mathbf{y}) = \mathcal{N}\left(\underbrace{\tilde{\mathbf{x}}_\tau + \tilde{P}_\tau C^T (C\tilde{P}_\tau C^T + R)^{-1} (\mathbf{y} - C\tilde{\mathbf{x}})}_{\hat{\mathbf{x}}_\tau, \text{ 均值}}, \underbrace{\tilde{P}_{\tau\tau} - \tilde{P}_\tau C^T (C\tilde{P}_\tau C^T + R)^{-1} C\tilde{P}_\tau^T}_{\hat{P}_{\tau\tau}, \text{ 协方差}}\right) \quad (3.149)$$

根据联合高斯概率分布的公式得来, 总之经过一系列SMW的变换, 后验xr的求解变为了

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \frac{1}{2} (\tilde{\mathbf{x}} - \mathbf{x})^T \tilde{P}^{-1} (\tilde{\mathbf{x}} - \mathbf{x}) + \frac{1}{2} (\mathbf{y} - C\mathbf{x})^T R^{-1} (\mathbf{y} - C\mathbf{x})$$

除了得到测量时刻的轨迹, 我们有时也希望求得非测量时刻的轨迹, 就需要查询该高斯过程

如果在求解了测量时刻点的状态之后, 我们又想要查询其它时间上的状态 ($\tau_0 < \tau_1 < \dots < \tau_J$), 那么可以用高斯过程插值来完成此事:

$$\hat{\mathbf{x}}_\tau = \tilde{\mathbf{x}}_\tau + (\tilde{P}_\tau \tilde{P}^{-1}) (\hat{\mathbf{x}} - \tilde{\mathbf{x}}) \quad (3.155a)$$

$$\hat{P}_{\tau\tau} = \tilde{P}_{\tau\tau} + (\tilde{P}_\tau \tilde{P}^{-1}) (\hat{P} - \tilde{P}) (\tilde{P}_\tau \tilde{P}^{-1})^T \quad (3.155b)$$

2. 一种稀疏的高斯过程先验方法

又看不懂了。。。。。。

3. 线性时不变情况

又看不懂了。。。。。。

第四章 非线性非高斯系统的状态估计

将研究如何处理现实世界中的系统——这些系统往往不是线性高斯的。可以说非线性非高斯（nonlinear, non-Gaussian, NLNG）系统的状态估计仍然是一个非常热门的研究课题。

1、简单非线性状态估计例子

对于由高斯噪声驱动的线性运动和观测模型，最大后验的最优估计值等于全贝叶斯方法的均值，这是因为得到的全后验概率正是高斯的，所以均值和模（即极大值点）是相同的点。但是在非线性模型中，结论就不正确了，因为此时全贝叶斯后验概率不再是高斯的。

从一个简化的、一维的非线性状态估计问题入手：估计立体相机中路标点的位置。




图 4-1 在理想的立体相机模型中，深度为 x 的路标点，其对应的（理想）视差为 y

1. 全贝叶斯估计

观测是左右图像的视差 y ，状态为路标点的距离 x ， f 是焦距， b 为基线长度， n 为测量噪声。观测方程如下：

$$y = \frac{fb}{x} + n$$

贝叶斯推断，能够求出在观测 y 的情况下的状态 x 的概率分布（后验）：

$$p(x|y) = \frac{p(y|x)p(x)}{\int_{-\infty}^{\infty} p(y|x)p(x)dx}$$

因此只要求出观测 $p(y|x)$ 和先验 $p(x)$ 就可以得到后验。

假设噪声服从零均值的高斯分布，对一个观测 y 来说，状态 x 是一个固定常量，所以根据观测方程可以得到观测的概率分布 $p(y|x)$ ：

$$p(y|x) = \mathcal{N}\left(\frac{fb}{x}, R\right) = \frac{1}{\sqrt{2\pi R}} \exp\left(-\frac{1}{2R} \left(y - \frac{fb}{x}\right)^2\right)$$

假设先验也服从高斯分布：

$$p(x) = \mathcal{N}(\tilde{x}, \tilde{P}) = \frac{1}{\sqrt{2\pi \tilde{P}}} \exp\left(-\frac{1}{2\tilde{P}} (x - \tilde{x})^2\right)$$

贝叶斯推断中隐含了一个操作顺序：给定一个先验 $\rightarrow$ 根据先验采样出“实际”情况 x_{true} （也就是预测） $\rightarrow$ 根据 x_{true} 进行观测，得到测量值 y_{meas} $\rightarrow$ 计算后验

为了更直观地理解，我们再次用具体的数值代入数学模型中：


$$\tilde{x} = 20[\text{m}], \quad \tilde{P} = 9[\text{m}^2]$$

$$f = 400[\text{pixel}], \quad b = 0.1[\text{m}], \quad R = 0.09[\text{pixel}^2]$$

正如前面提到的，实际状态 x_{true} 和（带有噪声的）测量 y_{meas} ，分别是对 $p(x)$ 和 $p(y|x)$ 随机采样得到的。每次重复试验时，这些值都会改变。为了绘制出单次试验的后验概率密度图像，我们使用了特定的值：

$$x_{\text{true}} = 22[\text{m}], \quad y_{\text{meas}} = \frac{fb}{x_{\text{true}}} + 1[\text{pixel}]$$

因此可以直接计算出后验的概率分布函数，画出图像



注意：

- 后验却是非对称的；经过非线性的观测模型后，后验明显偏向一边。然而，由于后验仍然是单峰的（存在单个极值），我们仍可用高斯近似它

- 在引入测量后，得到的后验概率密度比先验更加集中（即更加确定）；这正是隐含在贝叶斯状态估计背后的主要思想：我们将测量结果与先验结合，得到更确定的后验状态

2. 最大后验估计

但是通常情况下计算全贝叶斯后验是不切实际的（不一定能够积分，且可能多维计算复杂度极高），一般做法是估计单个点，在这个点上后验概率得以最大化（也就是这是一个后验概率函数的极大值点），所以目标变成：

$$\hat{x}_{\text{map}} = \arg \min_x (-\ln(p(x|y)))$$

通过贝叶斯公式展开：

$$\hat{x}_{\text{map}} = \arg \min_x (-\ln(p(y|x)) - \ln(p(x)))$$

回到立体相机的例子，有：

$$\hat{x}_{\text{map}} = \arg \min_x J(x)$$

其中

$$J(x) = \frac{1}{2R} \left(y - \frac{fb}{x} \right)^2 + \frac{1}{2P} (\tilde{x} - x)^2$$

注意：MAP方法得到的结果仍然是有偏差的（对比起先验采样得到的实际值）

2、离散时间的递归估计问题

1. 问题定义

非线性情况下的运动和观测方程，并且不假设任何随机变量是高斯的：

$$\text{运动方程: } \mathbf{x}_k = \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k), \quad k = 1 \dots K \quad (4.14a)$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k), \quad k = 0 \dots K \quad (4.14b)$$

非线性非高斯系统（NLNG系统）仍然是具有马尔可夫性的，当前状态只与上一时刻的状态相关，可以有递归形式

2. 贝叶斯滤波

贝叶斯滤波仅使用过去以及当前的测量，构造一个完整的 PDF（概率密度函数）来刻画当前状态

$$p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k})$$

中间推导过程省略。。。。

$$\underbrace{p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k})}_{\text{后验置信度}} = \eta \underbrace{p(\mathbf{y}_k | \mathbf{x}_k)}_{\text{利用 } g(\cdot) \text{ 进行更新}} \int \underbrace{p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{v}_k)}_{\text{利用 } f(\cdot) \text{ 进行预测}} \underbrace{p(\mathbf{x}_{k-1} | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1})}_{\text{先验置信度}} d\mathbf{x}_{k-1}$$

注意：贝叶斯滤波器基本是难以求解的，需要用各种近似方法来近似计算

3. 扩展卡尔曼滤波

如果将置信度和噪声限制为高斯分布，并且对运动模型和观测模型进行线性化，计算贝叶斯滤波中的积分（以及归一化积），我们将得到著名的扩展卡尔曼滤波（EKF）

在上一小节的基础上，假设 $\mathbf{x}_k$ 的置信度函数为高斯分布，噪声也是高斯的

$$p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) = \mathcal{N}(\hat{\mathbf{x}}_k, \hat{P}_k)$$

$$\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$$

$$\mathbf{n}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$$

我们在当前状态估计的均值处展开，对运动和观测模型进行线性化

$$\mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k) \approx \tilde{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \mathbf{w}'_k \quad (4.24a)$$

$$\mathbf{g}(\mathbf{x}_k, \mathbf{n}_k) \approx \tilde{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \tilde{\mathbf{x}}_k) + \mathbf{n}'_k \quad (4.24b)$$

其中

$$\tilde{\mathbf{x}}_k = \mathbf{f}(\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0}), \quad \mathbf{F}_{k-1} = \left. \frac{\partial \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k)}{\partial \mathbf{x}_{k-1}} \right|_{\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0}} \quad (4.25a)$$

$$\mathbf{w}'_k = \left. \frac{\partial \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k)}{\partial \mathbf{w}_k} \right|_{\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0}} \mathbf{w}_k \quad (4.25b)$$

并且

$$\tilde{\mathbf{y}}_k = \mathbf{g}(\tilde{\mathbf{x}}_k, \mathbf{0}), \quad \mathbf{G}_k = \left. \frac{\partial \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k)}{\partial \mathbf{x}_k} \right|_{\tilde{\mathbf{x}}_k, \mathbf{0}} \quad (4.26a)$$

$$\mathbf{n}'_k = \left. \frac{\partial \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k)}{\partial \mathbf{n}_k} \right|_{\tilde{\mathbf{x}}_k, \mathbf{0}} \mathbf{n}_k \quad (4.26b)$$

给定过去的状态和最新输入，则当前状态 $\mathbf{x}_k$ 的统计学特性为：

$$\begin{aligned}\mathbf{x}_k &\approx \tilde{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \mathbf{w}'_k \\ E[\mathbf{x}_k] &\approx \tilde{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \underbrace{E[\mathbf{w}'_k]}_0 \\ E[(\mathbf{x}_k - E[\mathbf{x}_k])(\mathbf{x}_k - E[\mathbf{x}_k])^T] &\approx \underbrace{E[\mathbf{w}'_k \mathbf{w}'_k{}^T]}_{\mathbf{Q}'_k} \\ p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{v}_k) &\approx \mathcal{N}(\tilde{\mathbf{x}}_k + \mathbf{F}_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}), \mathbf{Q}'_k)\end{aligned}$$

给定当前状态，则当前观测 $\mathbf{y}_k$ 的统计学特性为：

$$\begin{aligned}\mathbf{y}_k &\approx \tilde{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \tilde{\mathbf{x}}_k) + \mathbf{n}'_k \\ E[\mathbf{y}_k] &\approx \tilde{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \tilde{\mathbf{x}}_k) + \underbrace{E[\mathbf{n}'_k]}_0 \\ E[(\mathbf{y}_k - E[\mathbf{y}_k])(\mathbf{y}_k - E[\mathbf{y}_k])^T] &\approx \underbrace{E[\mathbf{n}'_k \mathbf{n}'_k{}^T]}_{\mathbf{R}'_k} \\ p(\mathbf{y}_k | \mathbf{x}_k) &\approx \mathcal{N}(\tilde{\mathbf{y}}_k + \mathbf{G}_k(\mathbf{x}_k - \tilde{\mathbf{x}}_k), \mathbf{R}'_k)\end{aligned}$$

推导省略。。。。。

预测：

$$\tilde{\mathbf{P}}_k = \mathbf{F}_{k-1} \hat{\mathbf{P}}_{k-1} \mathbf{F}_{k-1}^T + \mathbf{Q}'_k \quad (4.32a)$$

$$\tilde{\mathbf{x}}_k = \mathbf{f}(\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k, \mathbf{0}) \quad (4.32b)$$

卡尔曼增益：

$$\mathbf{K}_k = \tilde{\mathbf{P}}_k \mathbf{G}_k^T (\mathbf{G}_k \tilde{\mathbf{P}}_k \mathbf{G}_k^T + \mathbf{R}'_k)^{-1} \quad (4.32c)$$

更新：

$$\hat{\mathbf{P}}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{G}_k) \tilde{\mathbf{P}}_k \quad (4.32d)$$

$$\hat{\mathbf{x}}_k = \tilde{\mathbf{x}}_k + \mathbf{K}_k \underbrace{(\mathbf{y}_k - \mathbf{g}(\tilde{\mathbf{x}}_k, \mathbf{0}))}_{\text{更新量}} \quad (4.32e)$$

4. 广义高斯滤波

一般来说，我们先从 $k-1$ 时刻的高斯先验开始：

$$p(\mathbf{x}_{k-1} | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1}) = \mathcal{N}(\hat{\mathbf{x}}_{k-1}, \hat{\mathbf{P}}_{k-1}) \quad (4.33)$$

我们通过非线性运动模型 $\mathbf{f}(\cdot)$ 在时间上向前传递，以得到在 k 时刻的高斯先验：

$$p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) = \mathcal{N}(\tilde{\mathbf{x}}_k, \tilde{\mathbf{P}}_k) \quad (4.34)$$

这是预测步骤，结合了最新的输入 $\mathbf{v}_k$ 。

对于校正步骤，我们采用 2.2.3 节的方法，写出在时刻 k 状态和最新测量的联合高斯分布：

$$p(\mathbf{x}_k, \mathbf{y}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) = \mathcal{N}\left(\begin{bmatrix} \mu_{x,k} \\ \mu_{y,k} \end{bmatrix}, \begin{bmatrix} \Sigma_{xx,k} & \Sigma_{xy,k} \\ \Sigma_{yx,k} & \Sigma_{yy,k} \end{bmatrix}\right) \quad (4.35)$$

然后我们写出 $\mathbf{x}_k$ 的条件高斯密度函数（即后验概率）：

$$\begin{aligned} p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) \\ = \mathcal{N}\left(\underbrace{\mu_{x,k} + \Sigma_{xy,k} \Sigma_{yy,k}^{-1} (\mathbf{y}_k - \mu_{y,k})}_{\hat{\mathbf{x}}_k}, \underbrace{\Sigma_{xx,k} - \Sigma_{xy,k} \Sigma_{yy,k}^{-1} \Sigma_{yx,k}}_{\hat{\mathbf{P}}_k}\right) \end{aligned} \quad (4.36)$$

其中，我们将 $\hat{\mathbf{x}}_k$ 定义为均值，将 $\hat{\mathbf{P}}_k$ 定义为协方差，而 $\mu_{y,k}$ 则通过非线性观测模型 $\mathbf{g}(\cdot)$ 来计算。这里，我们可以写出广义高斯滤波中校正步骤的方程：

$$\mathbf{K}_k = \Sigma_{xy,k} \Sigma_{yy,k}^{-1} \quad (4.37a)$$

$$\hat{\mathbf{P}}_k = \tilde{\mathbf{P}}_k - \mathbf{K}_k \Sigma_{xy,k}^T \quad (4.37b)$$

$$\hat{\mathbf{x}}_k = \tilde{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \mu_{y,k}) \quad (4.37c)$$

其中，令 $\mu_{x,k} = \tilde{\mathbf{x}}_k$ ， $\Sigma_{xx,k} = \tilde{\mathbf{P}}_k$ ， $\mathbf{K}_k$ 仍被称为卡尔曼增益。然而，除非运动和观测模型是线性的，

5. 迭代扩展卡尔曼滤波IEKF

与EKF不同的是，线性化点设置为上一次迭代后的后验均值，而不是先验的均值

$$\begin{aligned} \mathbf{K}_k &= \tilde{\mathbf{P}}_k \mathbf{G}_k^T (\mathbf{G}_k \tilde{\mathbf{P}}_k \mathbf{G}_k^T + \mathbf{R}'_k)^{-1} \\ \hat{\mathbf{P}}_k &= (\mathbf{I} - \mathbf{K}_k \mathbf{G}_k) \tilde{\mathbf{P}}_k \\ \hat{\mathbf{x}}_k &= \tilde{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \mathbf{y}_{\text{op},k} - \mathbf{G}_k (\tilde{\mathbf{x}}_k - \mathbf{x}_{\text{op},k})) \end{aligned}$$

6. 从MAP角度看IEKF

一个重要的问题是：EKF、IEKF 与全贝叶斯后验之间的关系是什么？可以发现，IEKF 对应于全后验概率的（局部）极大值⁷；换句话说，它是一个 MAP 估计。另一方面，由于 EKF 的校正部分并没有迭代，它可能远离局部极大值；实际上我们很难说清楚它与全后验概率的关系

由于 IEKF 在最优估计处迭代地进行线性化，其估计结果等同于 MAP 的解。因此，IEKF 高斯估计器的“均值”并不等于全贝叶斯后验的均值——它计算的是模。

7. 其它将 PDF 传入非线性函数的方法

在推导 EKF 和 IEKF 时，我们使用一种特殊的方法将 PDF 传递进非线性函数中。具体来说，就是在**非线性模型的工作点处进行线性化**，然后通过解析的线性化模型传递高斯 PDF。

三种其他的方法：蒙特卡罗方法、线性化方法、sigmapoint或无迹变换，主要是获得EKF和IEKF的替代方案

内容先省略。。。。。

8. 粒子滤波

采集大量的样本就可以近似地描述 PDF。同时，将每个样本代入非线性函数中再进行重新组合，可以获得 PDF 转换后的近似值。=====》就是样本模拟函数

算法流程：

- 从由先验和运动噪声的联合概率密度中抽取 M 个样本

$$\begin{bmatrix} \hat{x}_{k-1,m} \\ w_{k,m} \end{bmatrix} \leftarrow p(x_{k-1}|\tilde{x}_0, v_{1:k-1}, y_{1:k-1})p(w_k)$$

- 使用vk（输入）得到后验PDF的预测，这可以将每个先验粒子和噪声样本代入非线性运动模型

$$\tilde{x}_{k,m} = f(\hat{x}_{k-1,m}, v_k, w_{k,m})$$

- 结合yk（观测）对后验概率校正
 - 根据每个粒子的期望后验和预测后验的收敛程度，对每个粒子赋予权值Wk,m

$$w_{k,m} = \frac{p(\tilde{x}_{k,m}|\tilde{x}_0, v_{1:k}, y_{1:k})}{p(\tilde{x}_{k,m}|\tilde{x}_0, v_{1:k}, y_{1:k-1})} = \eta p(y_k|\tilde{x}_{k,m})$$

其中 η 为归一化系数。在实践中，通常使用非线性观测模型来模拟期望的传感器读数 $\tilde{y}_{k,m}$ ：

$$\tilde{y}_{k,m} = g(\tilde{x}_{k,m}, 0) \tag{4.68}$$

接着假设 $p(y_k|\tilde{x}_{k,m}) = p(y_k|\tilde{y}_{k,m})$ ，其中等式右边的概率密度已知（比如高斯分布）。

- 根据赋予的权重，对每个粒子进行重要性重采样

$$\hat{x}_{k,m} \overset{\text{重要性重采样}}{\leftarrow} \{\tilde{x}_{k,m}, w_{k,m}\}$$

9. sigmapoint卡尔曼滤波（无迹卡尔曼滤波，UKF）

对于基础的 EKF 算法，可以改进的另一个思路是：在非线性的运动和观测模型中，不采用线性化的方法，而是使用 sigmapoint 变换来传递 PDF。这就导出了 sigmapoint 卡尔曼滤（SPKF），有时也称为无迹卡尔曼滤波（UKF）

推导部分涉及无迹变换等，先省略。。。。。

10. 迭代sigmapoint卡尔曼滤波

省略。。。

11. 本节滤波器分类



图 4-16 不同滤波方法的分类，展示了它们与贝叶斯滤波的关系

3、离散时间的批量估计问题

1. 最大后验估计

- 目标函数

构建目标函数，优化变量为：

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_0 \\ \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_K \end{bmatrix}$$

相对于先验和测量的误差分别是：

$$\mathbf{e}_{v,k}(\mathbf{x}) = \begin{cases} \tilde{\mathbf{x}}_0 - \mathbf{x}_0 & k = 0 \\ \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, 0) - \mathbf{x}_k & k = 1 \dots K \end{cases}$$
$$\mathbf{e}_{y,k}(\mathbf{x}) = \mathbf{y}_k - \mathbf{g}(\mathbf{x}_k, 0), \quad k = 0 \dots K$$

目标函数就是这些误差的二次型，将其整理合并（中间省略一些步骤，具体见原文）得到

$$J(\mathbf{x}) = \frac{1}{2} \mathbf{u}(\mathbf{x})^T \mathbf{u}(\mathbf{x})$$

目标就是最小化目标函数，得到最优的参数

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} J(\mathbf{x})$$

• 牛顿法

牛顿法是指，以迭代的方式，不断用二次函数来近似（可微的）目标函数，朝着二次近似极小值移动的方法。

具体就是在目标点进行二阶泰勒展开

$$J(\mathbf{x}_{\text{op}} + \delta \mathbf{x}) \approx J(\mathbf{x}_{\text{op}}) + \underbrace{\left(\frac{\partial J(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}}}_{\text{雅可比}} \delta \mathbf{x} + \frac{1}{2} \delta \mathbf{x}^T \underbrace{\left(\frac{\partial^2 J(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right) \bigg|_{\mathbf{x}_{\text{op}}}}_{\text{海塞}} \delta \mathbf{x}$$

下一步就是找到 $\delta \mathbf{x}$ 的值，以最小化该二次近似，也就是让目标函数对于 $\delta \mathbf{x}$ 的偏导数为0, 求出合适的 $\delta \mathbf{x}$ 的值然后更新 $\mathbf{x}$ 即可

$$\begin{aligned} \frac{\partial J(\mathbf{x}_{\text{op}} + \delta \mathbf{x})}{\partial \delta \mathbf{x}} &= \left(\frac{\partial J(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}} + \delta \mathbf{x}^T \left(\frac{\partial^2 J(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right) \bigg|_{\mathbf{x}_{\text{op}}} = \mathbf{0} \\ \Rightarrow \left(\frac{\partial^2 J(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right) \bigg|_{\mathbf{x}_{\text{op}}} \delta \mathbf{x}^* &= - \left(\frac{\partial J(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}}^T \end{aligned}$$

不停地迭代，直到 $\delta \mathbf{x}$ 足够小为止

• 高斯牛顿法

$$\text{雅可比: } \left(\frac{\partial J(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}} = \mathbf{u}(\mathbf{x}_{\text{op}})^T \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}}$$

$$\begin{aligned} \text{海塞: } \left(\frac{\partial^2 J(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right) \bigg|_{\mathbf{x}_{\text{op}}} &= \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}}^T \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}} \\ &\quad + \sum_{i=1}^M u_i(\mathbf{x}_{\text{op}}) \left(\frac{\partial^2 u_i(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right) \bigg|_{\mathbf{x}_{\text{op}}} \end{aligned}$$

海塞矩阵较为复杂，可以假设在极小值附近，海塞矩阵的第二项想对于第一项是很小的，忽略了二阶导的项时，海塞可以近似为

$$\left(\frac{\partial^2 J(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right) \bigg|_{\mathbf{x}_{\text{op}}} \approx \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}}^T \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}}$$

这样带入回到牛顿法的更新求解中就形式简单多了。

- 另一种理解是对 $u(x)$ 进行泰勒展开，而不是对 $J(x)$ 泰勒展开：

$$u(x_{op} + \delta x) \approx u(x_{op}) + \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right) \delta x$$

带入回 J 中，则

$$J(x_{op} + \delta x) \approx \frac{1}{2} \left(u(x_{op}) + \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right) \delta x \right)^T \left(u(x_{op}) + \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right) \delta x \right)$$

针对 δx 最小化：

$$\begin{aligned} \frac{\partial J(x_{op} + \delta x)}{\partial \delta x} &= \left(u(x_{op}) + \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right) \delta x^* \right)^T \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right) = 0 \\ \Rightarrow \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right)^T \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right) \delta x^* &= - \left(\frac{\partial u(x)}{\partial x} \bigg|_{x_{op}} \right)^T u(x_{op}) \end{aligned}$$

- 高斯牛顿法的改进

由于高斯牛顿法不能保证收敛（因为对海塞矩阵进行了近似），可以在两个方向进行改进：

i>

1. 一旦计算出最优增量 δx^* ，则实际的更新为

$$x_{op} \leftarrow x_{op} + \alpha \delta x^* \quad (4.126)$$

其中 $\alpha \in [0, 1]$ 为自定义的参数。在实际应用中，常常通过线搜索（line search）的方式求得 α 的最优值。该方法能够有效的原因在于， δx^* 是下降方向；而我们只是调整了在这个方向上行进的距离，使得收敛性质更加鲁棒（而不是更快）。

ii>列文伯格-马夸尔特（LM）

2. 可以使用列文伯格-马夸尔特 (Levenberg-Marquardt) 改进高斯牛顿法:

$$\left(\left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \right) \bigg|_{\mathbf{x}_{\text{op}}} \right)^T \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \bigg|_{\mathbf{x}_{\text{op}}} \right) + \lambda \mathbf{D} \delta \mathbf{x}^* = - \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \bigg|_{\mathbf{x}_{\text{op}}} \right)^T \mathbf{u}(\mathbf{x}_{\text{op}}) \quad (4.127)$$

其中 $\mathbf{D}$ 为正定对角矩阵。当 $\mathbf{D} = \mathbf{1}$ 时, 随着 $\lambda \geq 0$ 变大, 海塞矩阵所占比重相对较小, 此时:

$$\delta \mathbf{x}^* \approx -\frac{1}{\lambda} \left(\frac{\partial \mathbf{u}(\mathbf{x})}{\partial \mathbf{x}} \bigg|_{\mathbf{x}_{\text{op}}} \right)^T \mathbf{u}(\mathbf{x}_{\text{op}}) \quad (4.128)$$

即最速下降 (即负梯度) 中非常小的一个步长。当 $\lambda = 0$ 时, 则恢复为通常的高斯牛顿更新。列文伯格-马夸尔特法通过缓慢增加 λ 的值, 可以在海塞矩阵近似较差或病态的情况下工作。

• 批量式估计

那么就可以定义:

$$\delta \mathbf{x} = \begin{bmatrix} \delta \mathbf{x}_0 \\ \delta \mathbf{x}_1 \\ \delta \mathbf{x}_2 \\ \vdots \\ \delta \mathbf{x}_K \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 1 & & & & \\ -\mathbf{F}_0 & 1 & & & \\ & -\mathbf{F}_1 & \ddots & & \\ & & \ddots & 1 & \\ & & & -\mathbf{F}_{K-1} & 1 \\ \hline \mathbf{G}_0 & & & & \\ & \mathbf{G}_1 & & & \\ & & \mathbf{G}_2 & & \\ & & & \ddots & \\ & & & & \mathbf{G}_K \end{bmatrix} \quad (4.139a)$$

$$\mathbf{e}(\mathbf{x}_{\text{op}}) = \begin{bmatrix} \mathbf{e}_{v,0}(\mathbf{x}_{\text{op}}) \\ \mathbf{e}_{v,1}(\mathbf{x}_{\text{op}}) \\ \vdots \\ \mathbf{e}_{v,K}(\mathbf{x}_{\text{op}}) \\ \mathbf{e}_{y,0}(\mathbf{x}_{\text{op}}) \\ \mathbf{e}_{y,1}(\mathbf{x}_{\text{op}}) \\ \vdots \\ \mathbf{e}_{y,K}(\mathbf{x}_{\text{op}}) \end{bmatrix} \quad (4.139b)$$

以及

$$\mathbf{W} = \text{diag}(\tilde{P}_0, Q'_1, \dots, Q'_K, R'_0, R'_1, \dots, R'_K) \quad (4.140)$$

$$\underbrace{(H^T W^{-1} H)}_{\text{三对角块}} \delta x^* = H^T W^{-1} e(x_{\text{op}})$$

2. 贝叶斯推断

3. 最大似然估计

(似然估计和后验估计最大的差别是似然估计不包含先验信息)

不考虑先验时，目标函数为

$$J(\mathbf{x}) = \frac{1}{2} \sum_k (\mathbf{y}_k - \mathbf{g}_k(\mathbf{x}))^T \mathbf{R}_k^{-1} (\mathbf{y}_k - \mathbf{g}_k(\mathbf{x})) = -\log p(\mathbf{y}|\mathbf{x}) + C$$

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} J(\mathbf{x}) = \arg \max_{\mathbf{x}} p(\mathbf{y}|\mathbf{x})$$

同样可以使用高斯牛顿法进行求解

最大似然估计的偏差问题不看了。。。

4、连续时间的批量估计问题

在本节中，我们会将之前的结论进行扩展。非线性连续时间的运动模型具有以下形式

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{v}(t), \mathbf{w}(t), t) \quad (4.186)$$

其中 $\mathbf{f}(\cdot)$ 为非线性函数。同样，假设观测来自离散时间

$$\mathbf{y}_k = \mathbf{g}(\mathbf{x}(t_k), \mathbf{n}_k, t) \quad (4.187)$$

其中 $\mathbf{g}(\cdot)$ 也是非线性函数，并且

$$\mathbf{n}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k) \quad (4.188)$$

我们将首先对这个两个模型进行线性化，接着构建它们的提升形式，然后进行 GP 回归（贝叶斯推断）。参见 Anderson 等人 [44] 对本节方法的应用。

先不看了。。。大意也是线性化近似之后求解

4.4.4 算法总结

我们总结一下使用非线性运动模型和测量模型进行 GP 回归所需的步骤：

1. 从整条轨迹 $\mathbf{x}_{\text{op}}(t)$ 的后验均值的初始估计开始。我们只需要这个初始估计来初始化整个过程，并且只会在测量时刻更新我们的估计 $\mathbf{x}_{\text{op}}$ ，然后使用 GP 插值计算其它时刻的值。
2. 在每一次新迭代的时候计算 $\boldsymbol{\nu}$ ， $\mathbf{F}^{-1}$ 和 $\mathbf{Q}^{-1}$ 。这可能通过数值的方式计算，并且将涉及到 $\boldsymbol{\nu}(s)$ ， $\mathbf{F}(s)$ （由于 $\Phi(t, s)$ 的关系）和 $\mathbf{L}(s)$ 的计算，而这些项又依赖于 $\mathbf{x}_{\text{op}}(s)$ ，因此使用上一次迭代后的 $\tilde{\mathbf{x}}(s)$ ， $\tilde{\mathbf{P}}(s)$ ， $\tilde{\mathbf{x}}$ 和 $\tilde{\mathbf{P}}$ 来进行插值计算要求的积分。
3. 在每一次新迭代的时候计算 $\mathbf{y}_{\text{op}}$ ， $\mathbf{G}$ ， $\mathbf{R}^{-1}$ 。
4. 求解 $\delta \mathbf{x}^*$ ：

$$\begin{aligned} & \underbrace{(\mathbf{F}^{-\text{T}} \mathbf{Q}^{-1} \mathbf{F}^{-1} + \mathbf{G}^{\text{T}} \mathbf{R}^{-1} \mathbf{G})}_{\text{三对角块}} \delta \mathbf{x}^* \\ &= \mathbf{F}^{-\text{T}} \mathbf{Q}^{-1} (\boldsymbol{\nu} - \mathbf{F}^{-1} \mathbf{x}_{\text{op}}) + \mathbf{G}^{\text{T}} \mathbf{R}^{-1} (\mathbf{y} - \mathbf{y}_{\text{op}}) \end{aligned} \quad (4.206)$$

实际上，我们更愿意只对上方程矩阵乘积部分的非零块进行构建。

5. 在测量时刻更新我们的估计，即

$$\mathbf{x}_{\text{op}} \leftarrow \mathbf{x}_{\text{op}} + \delta \mathbf{x}^* \quad (4.207)$$

并检查估计的收敛程度。如果没有收敛，则返回步骤 2。如果收敛，输出 $\hat{\mathbf{x}} = \mathbf{x}_{\text{op}}$ 。

6. 如果需要，计算测量时刻的协方差 $\hat{\mathbf{P}}$ 。
7. 也可以使用 GP 插值方程^[4]计算出其它时刻 $\hat{\mathbf{x}}_{\tau}$ ， $\hat{\mathbf{P}}_{\tau\tau}$ 的估计。

整个过程中最耗时的一步是构建 $\boldsymbol{\nu}$ ， $\mathbf{F}^{-1}$ 和 $\mathbf{Q}^{-1}$ 。尽管如此，计算代价（在每次迭代中）仍然是线性于轨迹长度的，因此应该也是可控的。

第五章 偏差、匹配和外点

1、处理输入和测量的偏差

1. 偏差对于卡尔曼滤波器的影响

们假设：

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}(\mathbf{u}_k + \bar{\mathbf{u}}) + \mathbf{w}_k \quad (5.1a)$$

$$\mathbf{y}_k = \mathbf{C}\mathbf{x}_k + \bar{\mathbf{y}} + \mathbf{n}_k \quad (5.1b)$$

其中 $\bar{\mathbf{u}}$ 是输入的偏差， $\bar{\mathbf{y}}$ 是测量的偏差。在这里，我们仍然假设运动和观测模型都受到零均值高斯噪声影响：

$$\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}), \quad \mathbf{n}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}) \quad (5.2)$$

论证可得：

- 卡尔曼滤波对真实的误差不确定性是欠估计（低估）的
- 卡尔曼滤波器对于协方差的估计仍然是过度确信（高估）的

随着k的增大，偏差带来的影响也会逐渐增大，所以在估计问题中应该把偏差也估计出来。

预测：

$$\begin{aligned} \tilde{\mathbf{P}}_k &= \mathbf{A}\hat{\mathbf{P}}_{k-1}\mathbf{A}^T + \mathbf{Q} \\ \tilde{\mathbf{x}}_k &= \mathbf{A}\hat{\mathbf{x}}_{k-1} + \mathbf{B}\mathbf{u}_k + \underbrace{\mathbf{B}\bar{\mathbf{u}}}_{\text{偏差}} \end{aligned}$$

卡尔曼增益：

$$\mathbf{K}_k = \tilde{\mathbf{P}}_k \mathbf{C}^T (\mathbf{C}\tilde{\mathbf{P}}_k \mathbf{C}^T + \mathbf{R})^{-1}$$

$$\hat{\mathbf{P}}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}) \tilde{\mathbf{P}}_k$$

更新：

$$\hat{\mathbf{x}}_k = \tilde{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \mathbf{C}\tilde{\mathbf{x}}_k - \underbrace{\bar{\mathbf{y}}}_{\text{偏差}})$$

2. 未知的输入偏差

假设测量偏差 $\mathbf{y}=0$ ，输入偏差 $\mathbf{u}!=0$ ，因此在估计的状态中加上输入偏差，偏差表现形式为时间的函数，给偏差定义一个经典的运动模型

$$\bar{\mathbf{u}}_k = \bar{\mathbf{u}}_{k-1} + \mathbf{s}_k$$

此时的新的估计状态为

$$\mathbf{x}'_k = \begin{bmatrix} \mathbf{x}_k \\ \bar{\mathbf{u}}_k \end{bmatrix}$$

增广的运动模型为：

$$\mathbf{x}'_k = \underbrace{\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{1} \end{bmatrix}}_{\mathbf{A}'} \mathbf{x}'_{k-1} + \underbrace{\begin{bmatrix} \mathbf{B} \\ \mathbf{0} \end{bmatrix}}_{\mathbf{B}'} \mathbf{u}_k + \underbrace{\begin{bmatrix} \mathbf{w}_k \\ \mathbf{s}_k \end{bmatrix}}_{\mathbf{w}'_k}$$

$$\mathbf{w}'_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}'), \quad \mathbf{Q}' = \begin{bmatrix} \mathbf{Q} & \mathbf{0} \\ \mathbf{0} & \mathbf{W} \end{bmatrix}$$

这样又回到了无偏估计的形式，变化只有状态多了输入误差，对应的运动方程也改变，这种情况下的观测模型

$$\mathbf{y}_k = \underbrace{\begin{bmatrix} \mathbf{C} & \mathbf{0} \end{bmatrix}}_{\mathbf{C}'} \mathbf{x}'_k + \mathbf{n}_k$$

3. 未知的测量偏差

假设测量偏差 $y \neq 0$ ，输入偏差 $u=0$ ，增广状态和噪声模型为

$$\mathbf{x}'_k = \begin{bmatrix} \mathbf{x}_k \\ \bar{\mathbf{y}}_k \end{bmatrix}$$

$$\bar{\mathbf{y}}_k = \bar{\mathbf{y}}_{k-1} + \mathbf{s}_k$$

此时的增广运动和观测模型

$$\mathbf{x}'_k = \underbrace{\begin{bmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{1} \end{bmatrix}}_{\mathbf{A}'} \mathbf{x}'_{k-1} + \underbrace{\begin{bmatrix} \mathbf{B} \\ \mathbf{0} \end{bmatrix}}_{\mathbf{B}'} \mathbf{u}_k + \underbrace{\begin{bmatrix} \mathbf{w}_k \\ \mathbf{s}_k \end{bmatrix}}_{\mathbf{w}'_k}$$

为了简化描述，我们定义下面的符号：

$$\mathbf{w}'_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}'), \quad \mathbf{Q}' = \begin{bmatrix} \mathbf{Q} & \mathbf{0} \\ \mathbf{0} & \mathbf{W} \end{bmatrix}$$

对于增广状态系统，观测模型为：

$$\mathbf{y}_k = \underbrace{\begin{bmatrix} \mathbf{C} & \mathbf{1} \end{bmatrix}}_{\mathbf{C}'} \mathbf{x}'_k + \mathbf{n}_k$$

这样又回到了无偏估计的形式

2、数据关联

数据关联问题就是找出每一个测量信息对应于模型中的哪一部分。数据关联技术本质上分为两类：外部关联和内部关联。

1. 外部数据关联

在外部数据关联中，需要用到基于模型和测量的专业知识。这些专业知识对于估计问题来说是“外部的”。从估计问题的角度来看，数据关联的任务已经完成，因此外部数据关联有时被称为“已知的数据关联”。

例如视觉条形码、颜色等不属于观测和状态的信息。

2. 内部数据关联

在内部数据关联中，只能用测量和模型的数据来计算数据关联。

对于给定的模型，内部数据关联与给定观测的似然有关。在最简单的版本中，只有最有可能的数据关联被接受，而其它可能性的关联将会被忽略。

3、处理外点

将非常不可能的测量值（根据测量模型）称为外点（outlier）。需要设计一种检测，减少或移除外点对估计问题影响的方案。

1. 随机一致性采样RANSAC

随机采样一致性（RANSAC）是一种根据含有外点的数据拟合参数模型的迭代方法。外点（outlier）是“不符合”模型的测量，内点（inlier）是“符合”模型的测量。

RANSAC 以迭代的方式进行。在基础版本中，每个迭代包括以下五个步骤：

1. 在原始数据中随机选取一个子集作为假设的内点（例如，如果根据数据拟合一条二维直线，则选择两个点）。
2. 根据假设的内点拟合一个模型（例如，根据两个点拟合直线）。
3. 判断剩余的原始数据是否符合拟合的模型，并将其分为内点和外点。如果内点太少，则该次迭代被标记为无效并中止。
4. 根据假设的内点和上一步中划分出的内点重新拟合模型。
5. 计算所有内点的残差，根据残差和评估模型。

迭代上述步骤，把具有最小残差和的模型作为最佳模型。

2. M-估计

许多估计技术都是以最小化误差平方和为代价函数，外点会对代价函数产生极大的影响。

M-估计修改了代价函数形状，让求解过程中外点不会成为主导地位。

在目标函数取极小值时梯度为 0。现在让我们一般化这个目标函数，并将其写成

$$J'(\mathbf{x}) = \sum_{i=1}^N \alpha_i \rho(u_i(\mathbf{x})) \quad (5.40)$$

其中 $\alpha_i > 0$ ，是一个标量权重值，而

$$u_i(\mathbf{x}) = \sqrt{\mathbf{e}_i(\mathbf{x})^T \mathbf{W}_i^{-1} \mathbf{e}_i(\mathbf{x})} \quad (5.41)$$

同时 $\rho(u)$ 为非线性代价函数，满足：有界，在 $u = 0$ 处有唯一的零点，在 $u > 0$ 时单调递增。

这样的非线性代价函数成为鲁棒代价函数，梯度减小时大的误差对应的权重也不会太大。




图 5-7 Quadratic, Cauchy, Geman-McClure 代价函数对于标量输入的响应

新的代价函数的梯度为：

$$\frac{\partial J'(\mathbf{x})}{\partial \mathbf{x}} = \sum_{i=1}^N \alpha_i \frac{\partial \rho}{\partial u_i} \frac{\partial u_i}{\partial \mathbf{e}_i} \frac{\partial \mathbf{e}_i}{\partial \mathbf{x}}$$

迭代重加权最小二乘法。。。省略，主要是计算的应用，思想是利用一些非线性函数减小外点的代价，然后给定一个较小的权重保证估计过程的鲁棒。

3. 协方差估计

在 MAP 估计中，我们一直在处理下面形式的代价函数：

$$J(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^N \mathbf{e}_i(\mathbf{x})^T \mathbf{W}_i^{-1} \mathbf{e}_i(\mathbf{x})$$

尝试同时估计状态与协方差，有时这被称为自适应估计（adaptive estimation）。修改MAP问题为

$$\{\hat{\mathbf{x}}, \hat{\mathbf{M}}\} = \arg \min_{\{\mathbf{x}, \mathbf{M}\}} J'(\mathbf{x}, \mathbf{M}) \quad (5.55)$$

其中， $\mathbf{M} = \{\mathbf{M}_1, \dots, \mathbf{M}_N\}$ 用来表示所有未知协方差矩阵。这与本章前面所讨论的估计偏差的想法相似；我们简单地将 $\mathbf{M}_i$ 包含在待估计的一组变量中。为了做到这一点，我们需要以一种先验的方式，为 $\mathbf{M}_i$ 提供一些可能的指导。如果没有先验，估计器可能会产生过拟合。

一个可能的先验是假设协方差是服从逆维希特分布（inverse-Wishart distribution），该分布是在实正定矩阵上定义的：

$$\mathbf{M}_i \sim \mathcal{W}^{-1}(\Psi_i, \nu_i) \quad (5.56)$$

其中 $\Psi_i > 0$ 为尺度矩阵， $\nu_i > M_i - 1$ 是自由度参数，并且 $M_i = \dim \mathbf{M}_i$ 。逆维希特概率密度函数

论述过程省略。。。。

二、三维空间运动机理

第六章 三维几何学基础

1、向量和参考系

我们熟知的载具（vehicle）（例如机器人、卫星、飞行器等）的运动可以分为两种：**三个自由度的平移和三个自由度的旋转，合计六个自由度**。我们把这六个自由度定义为载具的姿态（pose），包含**位置（position）和朝向（orientation）**。一个载具内可能有多个组成部分，我们把每个部分称作载体（body），每个载体有自己的姿态。

1. 参考系

我们用 $\underline{r}$ 来表示一个有长度和方向的**向量（vector）**。在参考坐标系中，这个向量写成如下形式：

$$\begin{aligned}\underline{r} &= r_1 \underline{1}_1 + r_2 \underline{1}_2 + r_3 \underline{1}_3 \\ &= \begin{bmatrix} r_1 & r_2 & r_3 \end{bmatrix} \begin{bmatrix} \underline{1}_1 \\ \underline{1}_2 \\ \underline{1}_3 \end{bmatrix} \\ &= \underline{r}_1^T \underline{\mathcal{F}}_1\end{aligned}\tag{6.1}$$

2. 点积、叉积

那么它们的**点积（dot product）**（又名内积）的定义为：

$$\begin{aligned}\underline{r} \cdot \underline{s} &= \begin{bmatrix} r_1 & r_2 & r_3 \end{bmatrix} \begin{bmatrix} \underline{1}_1 \\ \underline{1}_2 \\ \underline{1}_3 \end{bmatrix} \cdot \begin{bmatrix} \underline{1}_1 & \underline{1}_2 & \underline{1}_3 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ s_3 \end{bmatrix} \\ &= \begin{bmatrix} r_1 & r_2 & r_3 \end{bmatrix} \begin{bmatrix} \underline{1}_1 \cdot \underline{1}_1 & \underline{1}_1 \cdot \underline{1}_2 & \underline{1}_1 \cdot \underline{1}_3 \\ \underline{1}_2 \cdot \underline{1}_1 & \underline{1}_2 \cdot \underline{1}_2 & \underline{1}_2 \cdot \underline{1}_3 \\ \underline{1}_3 \cdot \underline{1}_1 & \underline{1}_3 \cdot \underline{1}_2 & \underline{1}_3 \cdot \underline{1}_3 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ s_3 \end{bmatrix}\end{aligned}$$

由于：

$$\underline{1}_1 \cdot \underline{1}_1 = \underline{1}_2 \cdot \underline{1}_2 = \underline{1}_3 \cdot \underline{1}_3 = 1$$

以及：

$$\underline{1}_1 \cdot \underline{1}_2 = \underline{1}_2 \cdot \underline{1}_3 = \underline{1}_3 \cdot \underline{1}_1 = 0$$

因此，得到：

$$\underline{r} \cdot \underline{s} = \underline{r}_1^T \mathbf{1} \underline{s}_1 = \underline{r}_1^T \underline{s}_1 = r_1 s_1 + r_2 s_2 + r_3 s_3$$

符号 $\mathbf{1}$ 表示**单位矩阵（identity matrix）**。它的维数由具体情况决定。

我们把两个相同参考系下的向量的叉积（cross product）定义为：

$$\begin{aligned}\vec{r} \times \vec{s} &= \begin{bmatrix} r_1 & r_2 & r_3 \end{bmatrix} \begin{bmatrix} \vec{1}_1 \times \vec{1}_1 & \vec{1}_1 \times \vec{1}_2 & \vec{1}_1 \times \vec{1}_3 \\ \vec{1}_2 \times \vec{1}_1 & \vec{1}_2 \times \vec{1}_2 & \vec{1}_2 \times \vec{1}_3 \\ \vec{1}_3 \times \vec{1}_1 & \vec{1}_3 \times \vec{1}_2 & \vec{1}_3 \times \vec{1}_3 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ s_3 \end{bmatrix} \\ &= \begin{bmatrix} r_1 & r_2 & r_3 \end{bmatrix} \begin{bmatrix} 0 & \vec{1}_3 & -\vec{1}_2 \\ -\vec{1}_3 & 0 & \vec{1}_1 \\ \vec{1}_2 & -\vec{1}_1 & 0 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ s_3 \end{bmatrix} \\ &= \begin{bmatrix} \vec{1}_1 & \vec{1}_2 & \vec{1}_3 \end{bmatrix} \begin{bmatrix} 0 & -r_3 & r_2 \\ r_3 & 0 & -r_1 \\ -r_2 & r_1 & 0 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ s_3 \end{bmatrix} \\ &= \underline{\mathcal{F}}_1^T \mathbf{r}_1^\times \mathbf{s}_1\end{aligned}$$

如果 $\mathbf{r}$ 和 $\mathbf{s}$ 都是在相同的参考系下，可以用向量的反对称阵来构建叉积元素

$$\mathbf{r}_1^\times = \begin{bmatrix} 0 & -r_3 & r_2 \\ r_3 & 0 & -r_1 \\ -r_2 & r_1 & 0 \end{bmatrix}$$

2、旋转

1. 旋转矩阵

设有原点相同的参考系 $\underline{\mathcal{F}}_1$ 和 $\underline{\mathcal{F}}_2$ ，那么向量 $\vec{r}$ 在这两个参考系下可以分别表示为：

$$\vec{r} = \underline{\mathcal{F}}_1^T \mathbf{r}_1 = \underline{\mathcal{F}}_2^T \mathbf{r}_2$$

为了找到 $\mathbf{r}_1$ 和 $\mathbf{r}_2$ 的转换关系，我们继续推导：

$$\begin{aligned}\underline{\mathcal{F}}_2^T \mathbf{r}_2 &= \underline{\mathcal{F}}_1^T \mathbf{r}_1 \\ \underline{\mathcal{F}}_2 \cdot \underline{\mathcal{F}}_2^T \mathbf{r}_2 &= \underline{\mathcal{F}}_2 \cdot \underline{\mathcal{F}}_1^T \mathbf{r}_1 \\ \mathbf{r}_2 &= \mathbf{C}_{21} \mathbf{r}_1\end{aligned}$$

这就定义了：

$$\begin{aligned} C_{21} &= \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_1^T \\ &= \begin{bmatrix} \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_1 \\ \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_2 \\ \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_3 \end{bmatrix} \cdot \begin{bmatrix} \underline{\underline{F}}_1 & \underline{\underline{F}}_2 & \underline{\underline{F}}_3 \end{bmatrix} \\ &= \begin{bmatrix} \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_1 & \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_2 & \underline{\underline{F}}_2 \cdot \underline{\underline{F}}_3 \\ \underline{\underline{F}}_3 \cdot \underline{\underline{F}}_1 & \underline{\underline{F}}_3 \cdot \underline{\underline{F}}_2 & \underline{\underline{F}}_3 \cdot \underline{\underline{F}}_3 \end{bmatrix} \end{aligned}$$

我们称矩阵 C_{21} 为**旋转矩阵** (rotation matrix)。有时我们也称它为方向余弦矩阵，因为两个单位向量

旋转矩阵性质：

由于 $C_{21}^T = C_{12}$ ，我们有：

$$C_{12} = C_{21}^{-1} = C_{21}^T$$




$$C_{31} = C_{32} C_{21}$$

2. 其他旋转表示形式

• 欧拉角

两个参考系间的旋转关系可以用一系列绕三个主轴的旋转序列来表示。下面是一个例子：

1. 在原始坐标系基础上沿着主轴 3 旋转 ψ 度；
2. 在第一步的基础上，沿着新坐标系的主轴 1 旋转 γ 度；
3. 在第二步的基础上，沿着新坐标系的主轴 3 旋转 θ 度。



另一种旋转序列的表示形式如下所示：

1. 沿着原始坐标系的主轴 1 旋转 θ_1 度（翻滚角）；
2. 沿着新坐标系的主轴 2 旋转 θ_2 度（俯仰角）；
3. 沿着新坐标系主轴 3 旋转 θ_3 度（偏航角）。

这种序列被广泛运用在航空航天领域，称为 1-2-3 姿态序列，或是 RPY（翻滚角-俯仰角-偏航角）表示法。这种情况下，可以得到参考系 1 到参考系 2 的旋转矩阵为：

$$\begin{aligned} C_{21}(\theta_3, \theta_2, \theta_1) &= C_3(\theta_3)C_2(\theta_2)C_1(\theta_1) \\ &= \begin{bmatrix} c_2c_3 & c_1s_3 + s_1s_2c_3 & s_1s_3 - c_1s_2c_3 \\ -c_2s_3 & c_1c_3 - s_1s_2s_3 & s_1c_3 + c_1s_2s_3 \\ s_2 & -s_1c_2 & c_1c_2 \end{bmatrix} \end{aligned} \quad (6.9)$$

其中 $s_i = \sin(\theta_i)$, $c_i = \cos(\theta_i)$ 。

欧拉角的奇异点

所有的欧拉序列都有奇异点。例如，如果 3-1-3 序列中的 $\gamma = 0$ ，那么改变欧拉角 θ 或 ψ ，会对运动造成同样的效果。这使得原本应该有两个自由度的旋转变成了一个自由度，从而无法确定这两个角度各自的值。

第 6 章 三维几何学基础

对于 1-2-3 序列， $\theta_2 = \pi/2$ 是它的奇异点，旋转矩阵简化成以下形式：

$$C_{21}(\theta_3, \frac{\pi}{2}, \theta_1) = \begin{bmatrix} 0 & \sin(\theta_1 + \theta_3) & -\cos(\theta_1 + \theta_3) \\ 0 & \cos(\theta_1 + \theta_3) & \sin(\theta_1 + \theta_3) \\ 1 & 0 & 0 \end{bmatrix}$$

可见 θ_1 和 θ_3 描述了同样的运动。不过，这个问题仅存在于当我们想从旋转矩阵中计算欧拉角的过程中，反之则不存在。

• 无穷小旋转

现在考虑在 1-2-3 转换中, 旋转角 $\theta_1, \theta_2, \theta_3$ 极小的情况。在这种情况下, 三角函数可近似为 $c_i \approx 1, s_i \approx \theta_i$, 并且可以忽略两个极小角度的乘积 $\theta_i \theta_j \approx 0$ 。那么有:

$$\begin{aligned} C_{21} &\approx \begin{bmatrix} 1 & \theta_3 & -\theta_2 \\ -\theta_3 & 1 & \theta_1 \\ \theta_2 & -\theta_1 & 1 \end{bmatrix} \\ &\approx \mathbf{1} - \boldsymbol{\theta}^\times \end{aligned} \quad (6.10)$$

其中

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}$$

这个向量称为**旋转向量**

- 欧拉参数表示法

欧拉旋转定理告诉我们, 刚体在三维空间里的一般运动, 可分解为刚体上方某一点的平移, 以及绕经过此点的旋转轴的转动。

我们定义旋转运动的**旋转轴** (axis of rotation) 为单位向量 $\mathbf{a} = [a_1, a_2, a_3]^T$, 满足:

$$\mathbf{a}^T \mathbf{a} = a_1^2 + a_2^2 + a_3^2 = 1 \quad (6.11)$$

同时把沿着 $\mathbf{a}$ 旋转的**旋转角度** (angle of rotation) 定义为 ϕ 。这种情况下的旋转矩阵为^[1]:

$$C_{21} = \cos \phi \mathbf{1} + (1 - \cos \phi) \mathbf{a} \mathbf{a}^T - \sin \phi \mathbf{a}^\times \quad (6.12)$$

它与 $\mathbf{a}$ 在哪个参考系下表示无关, 因为:

$$C_{21} \mathbf{a} = \mathbf{a} \quad (6.13)$$

定义变量的组合:

$$\eta = \cos \frac{\phi}{2}, \quad \boldsymbol{\varepsilon} = \mathbf{a} \sin \frac{\phi}{2} = \begin{bmatrix} a_1 \sin(\phi/2) \\ a_2 \sin(\phi/2) \\ a_3 \sin(\phi/2) \end{bmatrix} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \end{bmatrix} \quad (6.14)$$

这一形式非常有用。这四个参数 $\{\boldsymbol{\varepsilon}, \eta\}$ 被称作旋转运动对应的**欧拉参数** (Euler parameters)^[1]。它们并非独立变量, 因为它们之间存在约束:

$$\eta^2 + \varepsilon_1^2 + \varepsilon_2^2 + \varepsilon_3^2 = 1$$

我们可以用欧拉参数表示旋转矩阵:

$$\begin{aligned} C_{21} &= (\eta^2 - \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon}) \mathbf{1} + 2 \boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^T - 2 \eta \boldsymbol{\varepsilon}^\times \\ &= \begin{bmatrix} 1 - 2(\varepsilon_2^2 + \varepsilon_3^2) & 2(\varepsilon_1 \varepsilon_2 + \varepsilon_3 \eta) & 2(\varepsilon_1 \varepsilon_3 - \varepsilon_2 \eta) \\ 2(\varepsilon_2 \varepsilon_1 - \varepsilon_3 \eta) & 1 - 2(\varepsilon_3^2 + \varepsilon_1^2) & 2(\varepsilon_2 \varepsilon_3 + \varepsilon_1 \eta) \\ 2(\varepsilon_3 \varepsilon_1 + \varepsilon_2 \eta) & 2(\varepsilon_3 \varepsilon_2 - \varepsilon_1 \eta) & 1 - 2(\varepsilon_1^2 + \varepsilon_2^2) \end{bmatrix} \end{aligned} \quad (6.15)$$

• 四元数

在这一小节中，我们使用文献[50]采用的符号标识方法。四元数（quaternion）是一个 4×1 的列向量，记为：

$$\mathbf{q} = \begin{bmatrix} \boldsymbol{\varepsilon} \\ \eta \end{bmatrix} \quad (6.16)$$

其中 $\boldsymbol{\varepsilon}$ 是 3×1 的列向量， η 是标量。我们定义四元数的左手形式的复合算子 $+$ 和右手形式的复合算子 $\oplus$ ，满足：

$$\mathbf{q}^+ = \begin{bmatrix} \eta \mathbf{1} - \boldsymbol{\varepsilon}^\times & \boldsymbol{\varepsilon} \\ -\boldsymbol{\varepsilon}^\mathrm{T} & \eta \end{bmatrix}, \quad \mathbf{q}^\oplus = \begin{bmatrix} \eta \mathbf{1} + \boldsymbol{\varepsilon}^\times & \boldsymbol{\varepsilon} \\ -\boldsymbol{\varepsilon}^\mathrm{T} & \eta \end{bmatrix} \quad (6.17)$$

四元数的逆定义为：

$$\mathbf{q}^{-1} = \begin{bmatrix} -\boldsymbol{\varepsilon} \\ \eta \end{bmatrix} \quad (6.18)$$

一些四元数恒等式

为了介绍四元数中一些有用的恒等式，我们假设 $\mathbf{u}$ 、 $\mathbf{v}$ 和 $\mathbf{w}$ 为四元数，那么有

$$\mathbf{u}^+ \mathbf{v} \equiv \mathbf{v}^\oplus \mathbf{u} \quad (6.19)$$

以及

$$\begin{aligned} (\mathbf{u}^+)^{\mathrm{T}} &\equiv (\mathbf{u}^+)^{-1} \equiv (\mathbf{u}^{-1})^+, & (\mathbf{u}^\oplus)^{\mathrm{T}} &\equiv (\mathbf{u}^\oplus)^{-1} \equiv (\mathbf{u}^{-1})^\oplus \\ (\mathbf{u}^+ \mathbf{v})^{-1} &\equiv \mathbf{v}^{-1+} \mathbf{u}^{-1}, & (\mathbf{u}^\oplus \mathbf{v})^{-1} &\equiv \mathbf{v}^{-1\oplus} \mathbf{u}^{-1} \\ (\mathbf{u}^+ \mathbf{v})^+ \mathbf{w} &\equiv \mathbf{u}^+ (\mathbf{v}^+ \mathbf{w}) \equiv \mathbf{u}^+ \mathbf{v}^+ \mathbf{w}, & (\mathbf{u}^\oplus \mathbf{v})^\oplus \mathbf{w} &\equiv \mathbf{u}^\oplus (\mathbf{v}^\oplus \mathbf{w}) \equiv \mathbf{u}^\oplus \mathbf{v}^\oplus \mathbf{w} \\ \alpha \mathbf{u}^+ + \beta \mathbf{v}^+ &\equiv (\alpha \mathbf{u} + \beta \mathbf{v})^+, & \alpha \mathbf{u}^\oplus + \beta \mathbf{v}^\oplus &\equiv (\alpha \mathbf{u} + \beta \mathbf{v})^\oplus \end{aligned} \quad (6.20)$$

其中 α 和 β 是标量。我们也有

$$\mathbf{u}^+ \mathbf{v}^\oplus \equiv \mathbf{v}^\oplus \mathbf{u}^+ \quad (6.21)$$

我们自然可以用四元数 $\mathbf{q}$ 来旋转某个点。记点的齐次坐标为：

$$\mathbf{v} = \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} \quad (6.24)$$

那么旋转的计算如下：

$$\mathbf{u} = \mathbf{q}^+ \mathbf{v}^+ \mathbf{q}^{-1} = \mathbf{q}^+ \mathbf{q}^{-1\oplus} \mathbf{v} = \mathbf{R} \mathbf{v} \quad (6.25)$$

其中

$$\mathbf{R} = \mathbf{q}^+ \mathbf{q}^{-1\oplus} = \mathbf{q}^{-1\oplus} \mathbf{q}^+ = \mathbf{q}^{\oplus\mathrm{T}} \mathbf{q}^+ = \begin{bmatrix} \mathbf{C} & \mathbf{0} \\ \mathbf{0}^\mathrm{T} & 1 \end{bmatrix} \quad (6.26)$$

• Gibbs向量


省略。。。

3. 旋转运动学

在不同的坐标系下看一个相同的运动是不同的

• 角速度

设参考系 $\mathcal{F}_2$ 相对着参考系 $\mathcal{F}_1$ 旋转。 $\mathcal{F}_2$ 相对于 $\mathcal{F}_1$ 的旋转速度记为 ω_{21} ， $\mathcal{F}_1$ 相对于 $\mathcal{F}_2$ 旋转的速度记为 $\omega_{12} = -\omega_{21}$ 。



坐标系的角速度

我们想要得到任意向量在两个参考系下的向量时间导数，那么可以写成：

$$\underline{r}_{\rightarrow} = \underline{\mathcal{F}}_1^T \underline{r}_1 = \underline{\mathcal{F}}_2^T \underline{r}_2$$

所以，处在参考系 $\mathcal{F}_1$ 上所看到运动的时间导数为：

$$\dot{\underline{r}}_{\rightarrow} = \underline{\mathcal{F}}_1^T \dot{\underline{r}}_1 + \underline{\mathcal{F}}_1^T \dot{\underline{\mathcal{F}}}_1 \underline{r}_1 = \underline{\mathcal{F}}_1^T \dot{\underline{r}}_1$$

同理，我们可以得到处在参考系 $\mathcal{F}_2$ 上所看到运动的时间导数：

$$\dot{\underline{r}}_{\rightarrow} = \underline{\mathcal{F}}_2^T \dot{\underline{r}}_2 + \underline{\mathcal{F}}_2^T \dot{\underline{\mathcal{F}}}_2 \underline{r}_2 = \underline{\mathcal{F}}_2^T \dot{\underline{r}}_2$$

• 加速度

这里的加速度角速度怎么看不懂啊。。。

4. 加上扰动的旋转

我们想对与旋转有关的运动方程和观测模型进行线性化时，会遇到一个麻烦：旋转并不属于向量空间！因此很多向量空间的性质不能用了。

• 一些重要等式

欧拉旋转定理告诉了我们如何用旋转轴 $\underline{a}$ 和旋转角度 ϕ 来表示旋转矩阵 $\underline{C}$ ：

$$\underline{C} = \cos \phi \underline{1} + (1 - \cos \phi) \underline{a} \underline{a}^T - \sin \phi \underline{a}^\times$$

旋转矩阵对旋转角求导可以得到：

$$\frac{\partial C}{\partial \phi} = -\sin \phi \mathbf{1} + \sin \phi \mathbf{a} \mathbf{a}^T - \cos \phi \mathbf{a}^\times \quad (6.57a)$$

$$= \sin \phi \underbrace{(-\mathbf{1} + \mathbf{a} \mathbf{a}^T)}_{\mathbf{a}^\times \mathbf{a}^\times} - \cos \phi \mathbf{a}^\times \quad (6.57b)$$

$$= -\cos \phi \mathbf{a}^\times + (1 - \cos \phi) \underbrace{\mathbf{a}^\times \mathbf{a} \mathbf{a}^T}_{\mathbf{0}} + \sin \phi \mathbf{a}^\times \mathbf{a}^\times \quad (6.57c)$$

$$= -\mathbf{a}^\times \underbrace{(\cos \phi \mathbf{1} + (1 - \cos \phi) \mathbf{a} \mathbf{a}^T - \sin \phi \mathbf{a}^\times)}_{C} \quad (6.57d)$$

因此，我们得到了第一个重要等式：

$$\frac{\partial C}{\partial \phi} \equiv -\mathbf{a}^\times C \quad (6.58)$$

因此我们得到了又一个重要的等式：

$$\frac{\partial (C(\theta) \mathbf{v})}{\partial \theta} \equiv (C(\theta) \mathbf{v})^\times S(\theta_2, \theta_3)$$

• 对旋转矩阵施加扰动

现在我们回到如何对旋转进行线性化的问题。假设有一个关于 $\mathbf{x}$ 的函数 $f(\mathbf{x})$ ，我们把 $\mathbf{x}$ 等价为标称量 $\bar{\mathbf{x}}$ 与扰动量 $\delta \mathbf{x}$ 的和，那么可以得到 f 关于 $\bar{\mathbf{x}}$ 的泰勒展开式。

$$f(\bar{\mathbf{x}} + \delta \mathbf{x}) = f(\bar{\mathbf{x}}) + \left. \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right|_{\bar{\mathbf{x}}} \delta \mathbf{x} + (\text{高阶项}) \quad (6.65)$$

在 $\delta \mathbf{x}$ 非常小的情况下，可以求得 f 的一阶泰勒展开式：

$$f(\bar{\mathbf{x}} + \delta \mathbf{x}) \approx f(\bar{\mathbf{x}}) + \left. \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right|_{\bar{\mathbf{x}}} \delta \mathbf{x} \quad (6.66)$$

在上面的展开操作中默认了 $\mathbf{x}$ 是一个无约束的量。但是大部分的旋转表达式是有约束的，因此不能像上面一样进行简单的泰勒展开。但是欧拉角表达式并没有约束限制。这是因为欧拉角表示法只有三个参数，所以各个参数之间是相互独立的，不存在参数间的约束。

$$C(\bar{\theta} + \delta \theta) \approx \underbrace{\left(\mathbf{1} - (S(\bar{\theta}_2, \bar{\theta}_3) \delta \theta)^\times \right)}_{\text{无穷小旋转矩阵}} C(\bar{\theta}) \quad (6.68)$$

上式可以理解成是极小角旋转矩阵与未被扰动的旋转矩阵 $C(\bar{\theta})$ 相乘（而不是相加）。为了简化，我们写成

$$C(\bar{\theta} + \delta \theta) \approx (\mathbf{1} - \delta \phi^\times) C(\bar{\theta}) \quad (6.69)$$

其中 $\delta \phi = S(\bar{\theta}_2, \bar{\theta}_3) \delta \theta$ 。式 (6.68) 非常重要。当旋转矩阵作为某个函数的变量时，我们可以用这个方法对一个旋转矩阵施加扰动（也就是对欧拉角施加扰动）。

3、姿态

我们还可以把式 (6.75) 写成以下形式

$$\begin{bmatrix} r_i^{pi} \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} C_{iv} & r_i^{vi} \\ 0^T & 1 \end{bmatrix}}_{T_{iv}} \begin{bmatrix} r_v^{pv} \\ 1 \end{bmatrix} \tag{6.77}$$

我们把上式中 4×4 的矩阵 T_{iv} 称作变换矩阵 (transformation matrix)。

为使用变换矩阵，需要在原本的坐标上加一个 1：

$$\begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} \tag{6.78}$$

我们称这种坐标形式为齐次坐标 (homogeneous point representation)。它的特点是：在它各项上同乘以一个尺度因子 (scale factor)，表示的还是同一个点：

$$\begin{bmatrix} sx \\ sy \\ sz \\ s \end{bmatrix} \tag{6.79}$$

弗莱纳参考系





图 6-4 这是经典的 Frenet-Serret 移动坐标系，它可以用来描述一个运动的点。这种参考系的三个坐标分别指向当前点所处曲线的正切方向，法线方向和副法线方向。这种参考系和它的移动方程以它的发现者的名字命名，他们是两个法国的数学家 Jean Frédéric Frenet (在他 1847 发表的文章中提出) 和 Joseph Alfred Serret (在他 1851 年发表的文章中提出)

经典的弗莱纳参考系 (Frenet-Serret) ^[1] 可以认为是姿态变量 (变换矩阵) 的一种特例。图 6-4 表示一个点 V 在空间中进行平滑的移动。其中弗莱纳参考系的第一个坐标轴的方向指向点 V 运动的切线方向，第二个坐标轴指向是弧长的切线导数 (也就是曲线的法向量)，然后第三个坐标轴的方向由右手定则得到，又称为副法线。

4、传感器模型

1. 透视相机

归一化图像坐标



• 本质矩阵




图 6-7 两个相机观测同一个点 P

本质矩阵

假设相机在某个位置观测到了点 P ，然后相机移动一定距离后，又对同一个点 P 进行了观测，这两次观测分别得到的投影坐标为 p_a 和 p_b 。它们之间有以下约束：

$$p_a^T E_{ab} p_b = 0 \quad (6.107)$$

上式的 E_{ab} 被称为本质矩阵 (essential matrix)。它有如下定义：

$$E_{ab} = C_{ba}^T r_b^{ab\wedge} \quad (6.108)$$

从上面看出，它与相机的姿态变化密切相关，因为

$$T_{ba} = \begin{bmatrix} C_{ba} & r_b^{ab} \\ 0^T & 1 \end{bmatrix} \quad (6.109)$$

证明可以看slam14讲

- 相机内参

相机内参数

归一化图像坐标可看成是焦距为 1、图像中心位于光轴上的理想相机。我们可以把归一化图像坐标的点 (x_n, y_n) 映射到的像素坐标系 (pixel coordinates) (u, v) 中:

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} f_u & 0 & c_u \\ 0 & f_v & c_v \\ 0 & 0 & 1 \end{bmatrix}}_K \begin{bmatrix} x_n \\ y_n \\ 1 \end{bmatrix} \tag{6.113}$$

- 基本矩阵

基本矩阵

与本质矩阵的约束条件类似，同一个点投影到不同位置的相机（也可以是不同的两个相机）得到的两个齐次像素坐标之间也存在约束条件。令：

$$q_i = K_i p_i \tag{6.114}$$

其中 $i = a, b$ 分别代表是从两个内部参数不同的相机观测到的。它们有如下约束条件：

$$q_a^T F_{ab} q_b = 0 \tag{6.115}$$

其中

$$F_{ab} = K_a^{-T} E_{ab} K_b^{-1} \tag{6.116}$$

上面的矩阵被称作基本矩阵 (fundamental matrix)。易证约束条件：

$$q_a^T F_{ab} q_b = p_b^T \underbrace{K_a^T K_a^{-T}}_1 E_{ab} \underbrace{K_b^{-1} K_b}_1 p_b = 0 \tag{6.117}$$

其中最后一步推导中应用了本质矩阵的约束条件。




图 6-9 如果一个点在图像中的投影坐标为 q_a ，且基础矩阵 F_{ab} 已知，那么在第二个图像中定义一条线，该点在图像二中的投影必在这条线上

- 完整的相机投影模型

把上面讨论的所有模型结合起来，可以得到透视相机的模型：

$$\begin{bmatrix} u \\ v \end{bmatrix} = s(\rho) = PK \frac{1}{z} \rho \quad (6.118)$$

其中

$$P = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad K = \begin{bmatrix} f_x & 0 & c_u \\ 0 & f_y & c_v \\ 0 & 0 & 1 \end{bmatrix}, \quad \rho = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad (6.119)$$

乘以矩阵 P 的目的是去掉齐次坐标的最后一行。从模型中我们可以更加清晰地观察到，我们将三个参数的坐标 ρ 转换成只有两个参数的坐标 (u, v) ，从而丢失了一个维度的信息；所以我们不能用二维的像素坐标还原出三维坐标。也就是说，我们无法从单个相机测到图像的深度信息。

- 单应矩阵

单应性




图 6-10 如果相机观测到了一个点，且这个点所在的平面的几何方程已知。那么利用单应变换，我们可以推测出在相机姿态变化后，这个点对应的新的投影位置

相关的推导和证明都可以看slam14讲

本质矩阵、基础矩阵、单应矩阵：<https://blog.csdn.net/LittleEmperor/article/details/105196825>

2. 立体相机

立体相机的优点是可以测量观测点的深度信息。




图 6-11 这是一个立体相机模型。两个相机都指向相同的方向，它们只在 x 轴方向间隔一个已知的距离。我们在这里取两个相机之间的中点作为坐标系的原点

由于这种相机排布方式的特性，不难看出两个相机观测值的垂直坐标总是一样的。此时两个相机的极线与相机平面保持水平。所以，当一个相机观测到一个观测点时，我们想要知道另一个相机上关于这个测量点的观测值，那么只需要沿着这条极线找到另一个相机中，垂直方向上像素坐标相同的那个点，就是我们想要找的点。

3. 距离-方位角-俯仰角模型

激光雷达就是使用这个模型建模。




图 6-13 这是一个距离-方位-俯仰模型，在球面坐标中，它观测到了点 P

4. IMU




图 6-14 这是一个惯性测量单元，它有三个线性的加速度计和三个速率陀螺仪，通常惯性传感器参考系和载体坐标系不是同一个参考系

为了对 IMU 进行建模，我们假设载具的状态可以用以下量表示：

$$\underbrace{r_i^{vi}, C_{vi}}_{\text{位姿}}, \underbrace{\omega_v^{vi}}_{\text{角速度}}, \underbrace{\dot{\omega}_v^{vi}}_{\text{角加速度}}$$

第七章 矩阵李群

1、几何学

2、运动学

3、概率与统计

三、应用

第八章 位姿估计问题

1、点云配准

通过最小二乘解决三维点云对准问题，常用于迭代最近点算法ICP。

第九章 位姿和点的估计问题

第十章 连续时间的估计