

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

拿下IMU!

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

这两本书看完基本上imu在卡尔曼滤波中就通透了!

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

Wenhao Zhong | 钟文豪
wenhao.zhong

IMU Preintegration on Manifold for Efficient Visual-Inertial Maximum-a-Posteriori Estimation

Christian Forster*, Luca Carlone[†], Frank Dellaert[†], and Davide Scaramuzza*

*Robotics and Perception Group, University of Zurich, Switzerland. Email: {forster, sdavide}@ifi.uzh.ch

[†]School of Interactive Computing, Georgia Institute of Technology, Atlanta, GA, USA.

Email: luca.carlone@gatech.edu, frank@cc.gatech.edu

Abstract—Recent results in monocular visual-inertial navigation (VIN) have shown that optimization-based approaches outperform filtering methods in terms of accuracy due to their capability to relinearize past states. However, the improvement comes at the cost of increased computational complexity. In this paper, we address this issue by preintegrating inertial measurements between selected keyframes. The preintegration allows us to accurately summarize hundreds of inertial measurements into a single relative motion constraint. Our first contribution is a *preintegration theory* that properly addresses the manifold structure of the rotation group and carefully deals with uncertainty propagation. The measurements are integrated in a *local frame*, which eliminates the need to repeat the integration when the linearization point changes while leaving the opportunity for belated bias corrections. The second contribution is to show that the preintegrated IMU model can be seamlessly integrated in a visual-inertial pipeline under the unifying framework of factor graphs. This enables the use of a *structureless* model for visual measurements, further accelerating the computation. The third contribution is an extensive evaluation of our monocular VIN pipeline: experimental results confirm that our system is very fast and demonstrates superior accuracy with respect to competitive state-of-the-art filtering and optimization algorithms, including off-the-shelf systems such as *Google Tango* [1].

I. INTRODUCTION

The fusion of cameras and inertial sensors for three-dimensional structure and motion estimation has received considerable interest in the robotics community. Both sensor types are cheap, ubiquitous, and complementary. A single moving camera is an exteroceptive sensor that allows us to measure appearance and geometry of a three-dimensional scene, up to an unknown metric scale; an inertial measurement unit (IMU) is a proprioceptive sensor that renders metric scale of monocular vision and gravity observable [2] and provides robust and accurate inter-frame motion estimates. Applications of VIN range from autonomous navigation in GPS-denied environments, to 3D reconstruction, and augmented reality.

Although impressive results have been achieved in VIN, state-of-the-art algorithms require trading-off computational efficiency with accuracy. Batch non-linear optimization, which has become popular for visual-inertial fusion [3–15], allows computing an optimal estimate; however, real-time operation

This research was partially funded by the Swiss National Foundation (project number 200021-143607, “Swarm of Flying Cameras”), the National Center of Competence in Research Robotics (NCCR), the UZH Forschungskredit, the NSF Award 11115678, and the USDA NIFA Award GEOW-2014-09160.




Fig. 1: Real test comparing the proposed VIN approach against Google Tango. The 160m-long trajectory starts at (0, 0, 0) (ground floor), goes up till the 3rd floor of a building, and returns to the initial point. The figure shows a side view (left) and a top view (right) of the trajectory estimates for our approach (blue) and Tango (red). Google Tango accumulates 1.4m error, while the proposed approach only has 0.5m drift. 3D points triangulated from our trajectory estimate are shown in green for visualization purposes.

quickly becomes infeasible as the trajectory and the map grow over time. Therefore, it has been proposed to discard frames except selected *keyframes* [9, 16–18] or to run the optimization in a parallel thread, using a tracking and mapping dual architecture [5, 19]. Another approach is to maintain a local map of fixed size and to marginalize old states [6, 7, 9], which is also termed *fixed-lag smoothing*. To that extreme, if only the latest sensor state is maintained, we speak of *filtering*, which amounts the vast majority of related work in VIN [20, 21]. Although filtering and fixed-lag smoothing enable fast computation, they commit to a linearization point when marginalizing; the gradual build-up of linearization errors leads to drift and possible inconsistencies [22]. A breakthrough in the direction of reconciling filtering and batch optimization has been the development of *incremental smoothing techniques* (iSAM [23], iSAM2 [24]), which leverage the expressiveness of *factor graphs* to identify and update only the typically small subset of variables affected by a new measurement. Although this results in constant update time in odometry problems, previous VIN applications still work at low frame rates [25].

In this work, we present a system that uses incremental smoothing for fast computation of the optimal *maximum a posteriori* (MAP) estimate. The first step towards this goal is the development of a novel preintegration theory. The use of *preintegrated IMU measurements* was first proposed in [26] and consists of combining many inertial measurements between two keyframes into a single relative motion constraint.

Quaternion kinematics for the error-state Kalman filter

Joan Solà

November 8, 2017

Contents

1	Quaternion definition and properties	4
1.1	Definition of quaternion	4
1.1.1	Alternative representations of the quaternion	5
1.2	Main quaternion properties	6
1.2.1	Sum	6
1.2.2	Product	6
1.2.3	Identity	8
1.2.4	Conjugate	8
1.2.5	Norm	8
1.2.6	Inverse	9
1.2.7	Unit or normalized quaternion	9
1.3	Additional quaternion properties	9
1.3.1	Quaternion commutator	9
1.3.2	Product of pure quaternions	9
1.3.3	Natural powers of pure quaternions	10
1.3.4	Exponential of pure quaternions	10
1.3.5	Exponential of general quaternions	11
1.3.6	Logarithm of unit quaternions	11
1.3.7	Logarithm of general quaternions	12
1.3.8	Exponential forms of the type $\mathbf{q}^t$	12
2	Rotations and cross-relations	12
2.1	The 3D vector rotation formula	12
2.2	The rotation group $SO(3)$	13
2.3	The rotation group and the rotation matrix	14
2.3.1	The exponential map	16
2.3.2	The capitalized exponential map	18
2.3.3	Rotation matrix and rotation vector: the Rodrigues rotation formula	18
2.3.4	The logarithmic maps	19
2.3.5	The rotation action	19

一、IMU Preintegration on Manifold for Efficient Visual-Inertial Maximum-a-Posteriori Estimation

流形上的imu预积分（其实就是imu预积分的推导和证明，以及如何动态的修正预积分值避免重复计算）

论文讲解博客：[https://so.csdn.net/so/search?](https://so.csdn.net/so/search?q=%E6%B5%81%E5%BD%A2&t=blog&u=qq_37394634)

[q=%E6%B5%81%E5%BD%A2&t=blog&u=qq_37394634](https://so.csdn.net/so/search?q=%E6%B5%81%E5%BD%A2&t=blog&u=qq_37394634)

有很多简化版的imu预积分理论介绍，不那么依赖严格数学推导

例如高翔：<https://zhuanlan.zhihu.com/p/388859808>

1、前置知识

流形

流形的直观解释：

1. 局部欧几里得性质：

流形在小范围内看起来像普通的欧几里得空间。例如，地球表面（球面）是一个流形。如果你站在地球表面的一小块区域上（比如你脚下的地面），它看起来是平的。然而，地球整体是一个球形结构，这与平坦的欧几里得空间不同。

2. 维度的定义：

流形的维度是指它在局部看起来像几维的欧几里得空间。例如：

- 一条线是**1维流形**，因为它在局部看起来像一维空间。
- 一个平面是**2维流形**，因为它在局部看起来像二维空间。
- 一个球面是**2维流形**，尽管它是三维空间中的曲面，但在球面上的每个小区域都与二维平面类似。

3. 全局复杂性：

尽管流形在局部看起来像平坦的欧几里得空间，但它们的整体结构可能非常复杂。例如，一个圆环（环面）是一个二维流形，但它的全局形状并不是平面。

更正式的定义：

一个 **n 维流形** 是一个在局部上类似于 n 维欧几里得空间 $\mathbb{R}^n$ 的空间。这意味着，在流形的每一个小区域（邻域）内，都可以找到一个与 $\mathbb{R}^n$ 有一一对应关系的映射（称为“坐标图”）。

具体例子：

1. 二维球面 (S^2)：

地球的表面就是一个典型的二维流形。虽然地球的表面在三维空间中是弯曲的，但如果我们只看很小的一部分，它看起来是二维的平面。

2. 圆 (S^1)：

一个圆是一个一维流形。尽管它在平面上有曲率，但在圆上任意一点的局部区域看起来像一条直线段（即一维空间）。

3. 三维流形：

我们生活的三维空间本身就是一个三维流形。在局部，每一个小区域都看起来像一个普通的三维欧几里得空间。

在控制论和机器人学中，流形用于表示旋转和位姿。例如， $SO(3)$ 流形描述了三维空间中的旋转，而 $SE(3)$ 描述了物体在三维空间中的位姿。

流形的切空间是指流形上每个点的局部线性空间，就是一小块的局部近似

具体定义

设 M 是一个 n 维流形，切空间 $T_p M$ 是附加在 M 的某一点 p 的一个 n 维向量空间。该向量空间的每个元素表示通过点 p 的某个“方向”，即从点 p 出发沿着流形移动的可能方向。

- 点 p ：在流形 M 上的一个具体点。
- 切空间 $T_p M$ ：在点 p 处流形的局部线性空间。

换句话说，流形本身可能是曲面或更复杂的几何对象，而切空间是一个局部平坦的线性空间，它可以用来近似流形在该点附近的几何特性。

特殊正交群 $SO(3)$

表示三维的旋转矩阵，

$$SO(3) \equiv \{\mathbf{R} \in \mathbb{R}^{3 \times 3} : \mathbf{R}^T \mathbf{R} = \mathbf{I}, \det(\mathbf{R}) = 1\}$$

$SO(3)$ 也形成光滑流形，流形在局部的切空间（tangent space）表示为 $\mathfrak{so}(3)$ ，这也称为**李代数**

1. 李群和李代数的基本概念

- **李群**：李群是同时具有**群结构**和**光滑流形结构**的集合。它的元素代表了连续的变换，比如旋转、平移等。李群中的操作（乘法、逆等）是光滑的，即可微的。
 - 一个常见的李群例子是三维空间中的**旋转群** $SO(3)$ ，它代表了三维空间中的所有旋转。
- **李代数**：李代数是与李群相关联的向量空间，描述了李群在**单位元**附近的局部结构。更具体地，李代数可以理解李群的**切空间**，通常位于群的单位元处。李代数的元素代表无穷小的变换，它们可以通过矩阵来表示。

在无穷小情况，可以将一个反对称矩阵与三维向量等同（也就是无穷小旋转等同于一个反对称矩阵），与 $SO(3)$ 的李代数形式相对应。

$$\omega^\wedge = \begin{bmatrix} \omega_1 \\ \omega_2 \\ \omega_3 \end{bmatrix}^\wedge = \begin{bmatrix} 0 & -\omega_3 & \omega_2 \\ \omega_3 & 0 & -\omega_1 \\ -\omega_2 & \omega_1 & 0 \end{bmatrix} \in \mathfrak{so}(3)$$

可以用vee运算符将反对称矩阵映射到 $\mathbb{R}^3$ 中的向量：对于反对称矩阵 $\mathbf{S} = \omega^\wedge$ ，有： $\mathbf{S}^\vee = \omega$ 。反对称矩阵的一个性质是：

$$\mathbf{a}^\wedge \mathbf{b} = -\mathbf{b}^\wedge \mathbf{a}, \quad \forall \mathbf{a}, \mathbf{b} \in \mathbb{R}^3$$

证明推导：给定一个R，可以知道一个向量能够描述旋转矩阵R在局部的导数性质（这可以方便进行优化），之间存在一种指数对应关系，这个向量就是对应到 $SO(3)$ 的李代数 $\mathfrak{so}(3)$

旋转矩阵 R 性质: $R \cdot R^T = I$

写成时间函数: $R(t) R^T(t) = I$

两边求导: $\dot{R}(t) R^T(t) + R(t) \dot{R}^T(t) = 0 \Rightarrow \dot{R}(t) R^T(t) = -[\dot{R}(t) R^T(t)]^T$

可以得到 $\dot{R}(t) R^T(t)$ 是一个反对称矩阵 与一个向量对应

$$\dot{R}(t) R^T(t) = \hat{\phi(t)}$$

$$\Rightarrow \dot{R}(t) = \hat{\phi(t)} R(t) = \begin{bmatrix} 0 & -\phi_3 & \phi_2 \\ \phi_3 & 0 & -\phi_1 \\ -\phi_2 & \phi_1 & 0 \end{bmatrix} R(t)$$

☆ 可以看作每次对旋转矩阵求导, 需要直方乘一个反对称 $\hat{\phi(t)}$

假设 $t=0$ 时, $R(0)=I$, 在 $t=0$ 附近一阶泰勒展开:

$$R(t) \approx R(t_0) + \dot{R}(t_0)(t-t_0) = I + \hat{\phi(t_0)} t$$

看出 $\hat{\phi}$ 可以反应 R 的导数性质, 称为 $SO(3)$ 附近正切空间

$\therefore \hat{\phi(t_0)} = \hat{\phi_0}$ 为常数

$$\therefore \dot{R}(t) = \hat{\phi(t_0)} R(t) = \hat{\phi_0} R(t) \Rightarrow \text{微分方程}$$

$$\Rightarrow R(t) = \exp(\hat{\phi_0} t)$$

对数指数映射

$SO(3) \rightarrow so(3)$: 对数映射, 旋转对应到一个反对称矩阵, 从而对应一个李代数

对数映射将一个 $SO(3)$ 旋转矩阵关联到一个反对称矩阵:

$$\log(R) = \frac{\varphi \cdot (R - R^T)}{2 \sin(\varphi)} \quad \text{with } \varphi = \cos^{-1} \left(\frac{\text{tr}(R) - 1}{2} \right)$$

注意有 $\log(R)^V = \mathbf{a} \varphi$, $\mathbf{a}$ 是旋转轴, φ 是旋转角。

$so(3) \rightarrow SO(3)$: 指数映射, 将一个李代数关联到一个旋转

指数映射exp: $\mathfrak{so}(3) \rightarrow \text{SO}(3)$ 将一个李代数元素关联到一个旋转:

$$\exp(\phi^\wedge) = \mathbf{I} + \frac{\sin(\|\phi\|)}{\|\phi\|} \phi^\wedge + \frac{1 - \cos(\|\phi\|)}{\|\phi\|^2} (\phi^\wedge)^2$$

指数映射的一阶近似为:

$$\exp(\phi^\wedge) \approx \mathbf{I} + \phi^\wedge$$

实际上就是指数映射把一个R向量映射到了SO(3)，对数映射则相反

为了便于标记，采用指数和对数映射的“向量化”版本:

$$\begin{aligned} \text{Exp} : \mathbb{R}^3 &\ni \phi \rightarrow \exp(\phi^\wedge) \in \text{SO}(3) \\ \log : \text{SO}(3) &\ni R \rightarrow \log(R)^\vee \in \mathbb{R}^3 \end{aligned}$$

BCH近似（右雅各比）:

$$\log(\text{Exp}(\phi) \text{Exp}(\delta\phi)) \approx \phi + J_r^{-1}(\phi) \delta\phi$$

总结以下BCH的意义为：假定一个旋转R,对应的李代数为 ϕ 。我们左乘一个微小旋转记作 ΔR ，对应的李代数为 $\Delta \phi$ 。李群的表示为 $R\Delta R$ ，而在李代数上由于BCH近似表达为 $J_l^{-1}(\phi) \Delta\phi + \phi$

合并起来写就是：

$$\exp(\Delta\phi^\wedge) \exp(\phi^\wedge) = \exp\left((\phi + J_l^{-1}(\phi) \Delta\phi)^\wedge\right).$$

反之如果是在李代数上做加法：

$$\exp((\phi + \Delta\phi)^\wedge) = \exp((J_l \Delta\phi)^\wedge) \exp(\phi^\wedge) = \exp(\phi^\wedge) \exp((J_r \Delta\phi)^\wedge).$$

扰动模型：使用近似，省去求解雅各比

$$\begin{aligned}
\frac{\partial (Rp)}{\partial \varphi} &= \lim_{\varphi \rightarrow 0} \frac{\exp(\varphi^\wedge) \exp(\phi^\wedge) p - \exp(\phi^\wedge) p}{\varphi} \\
&\approx \lim_{\varphi \rightarrow 0} \frac{(1 + \varphi^\wedge) \exp(\phi^\wedge) p - \exp(\phi^\wedge) p}{\varphi} \\
&= \lim_{\varphi \rightarrow 0} \frac{\varphi^\wedge Rp}{\varphi} = \lim_{\varphi \rightarrow 0} \frac{-(Rp)^\wedge \varphi}{\varphi} = -(Rp)^\wedge.
\end{aligned}$$

指数映射的另一个有用的性质是关于伴随矩阵的：

$$\begin{aligned}
R \text{Exp}(\phi) R^\top &= \exp(R\phi^\wedge R^\top) = \text{Exp}(R\phi) \\
\Leftrightarrow \text{Exp}(\phi) R &= R \text{Exp}(R^\top \phi)
\end{aligned} \tag{11}$$




Fig. 2: The right Jacobian J_r relates an additive perturbation $\delta\phi$ in the tangent space to a multiplicative perturbation on the manifold $SO(3)$, as per Eq. (7).

SE(3)

$$SE(3) \equiv \{(\mathbf{R}, \mathbf{p}) : \mathbf{R} \in SO(3), \mathbf{p} \in \mathbb{R}^3\}$$

SO(3)的不确定性描述

可以将SO(3)描述为一个分布：

$$\tilde{\mathbf{R}} = \mathbf{R} \text{Exp}(\epsilon), \quad \epsilon \sim \mathcal{N}(0, \Sigma)$$

随机变量R的概率密度函数可以写成：

随机变量 $\tilde{\mathbf{R}} \in \text{SO}(3)$ 的分布可以被显式计算，如[33]一样，得到：

$$p(\tilde{\mathbf{R}}) = \beta(\tilde{\mathbf{R}})e^{-\frac{1}{2} \|\text{Log}(\mathbf{R}^{-1}\tilde{\mathbf{R}})\|_{\Sigma}^2}$$

然后就可以把旋转R的负对数似然函数写成：

其中 $\beta(\tilde{\mathbf{R}})$ 是归一化因子，近似计算： $\beta(\tilde{\mathbf{R}}) \simeq 1/\sqrt{2\pi\det(\Sigma)}$ ，其中 Σ 很小。如果将 β 近似为一个常数，那么给定一个测量 $\tilde{\mathbf{R}}$ ，旋转 $\mathbf{R}$ 的负对数似然为：

$$\mathcal{L}(\mathbf{R}) = \frac{1}{2} \|\text{Log}(\mathbf{R}^{-1}\tilde{\mathbf{R}})\|_{\Sigma}^2 + \text{const} = \frac{1}{2} \|\text{Log}(\tilde{\mathbf{R}}^{-1}\mathbf{R})\|_{\Sigma}^2 + \text{const} \tag{14}$$

流形优化

流形优化讲解：https://blog.csdn.net/weixin_39274659/article/details/115735867

问题定义：

$$\min_{\mathbf{x} \in \mathcal{M}} f(\mathbf{x})$$

其中， $f : \mathcal{M} \rightarrow \mathbb{R}$ 是一个光滑(smooth)的函数。 $\mathcal{M}$ 则是一个光滑的，很可能非线性的空间。

流形优化就是旨在解决 被定义在 某些非线性空间上 的优化问题 的一套成熟的优化框架。

线性空间：是一种满足特定代数结构的集合，最重要的是在这个空间中可以进行**向量加法**和**标量乘法**，并且这些运算满足一些线性性质。线性空间的一个核心特性是：任意两个向量的线性组合仍然在这个空间内。

非线性空间：元素之间不一定可以简单地通过加法或标量乘法得到新的元素。这种非线性的本质意味着在这些空间中，常见的线性工具（如向量加法、线性变换等）不再适用，需要用更复杂的非线性方法处理。例如曲面、李群和流形，状态空间

3. 线性空间与非线性空间的比较

特性	线性空间	非线性空间
向量加法	满足封闭性	不一定封闭
标量乘法	满足封闭性	不一定封闭
线性组合	任意向量的线性组合仍然在空间内	线性组合不一定在空间内
例子	$\mathbb{R}^n$ 、矩阵空间、函数空间	曲面、流形、状态空间、李群
几何形状	平坦，直线	弯曲，非平坦
应用场景	线性代数，物理学中的经典问题	微分几何、非线性系统、复杂网络、控制

以一个简单的非线性空间介绍： n 维空间的球面

$$\mathcal{M} = S^{n-1} = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| = 1\}$$

在线性空间中有一套成熟的基于梯度的优化方法，但是在非线性空间中不能直接使用，因为梯度下降后的结果很可能不在流形中（沿着欧式梯度更新后的结果远离了流形），但是可以将流形上的优化近似为一个线性空间的优化：

给定流形上的某一点，我们希望我们设计的迭代算法让该点沿着某一方向更新，且仍留在流形上。

在当前的例子中，流形的函数可以写成

$$h(\mathbf{x}) = \mathbf{x}^T \mathbf{x} - 1$$

当 $h(\mathbf{x})=0$ 时，点 $\mathbf{x}$ 位于流形上，所以希望更新方向 $\mathbf{v}$ 满足

$$h(\mathbf{x} + \mathbf{v}) = 0$$

$$h(\mathbf{x} + \mathbf{v}) = (\mathbf{x} + \mathbf{v})^T (\mathbf{x} + \mathbf{v}) - 1 = \mathbf{x}^T \mathbf{x} + \mathbf{v}^T \mathbf{x} + \mathbf{x}^T \mathbf{v} + \mathbf{v}^T \mathbf{v}$$


注意到由于 $\mathbf{x}$ 在流形上，所以 $\mathbf{x}^T \mathbf{x} = 1$ ，而更新量 $\mathbf{v}$ 非常小时（即步长极小的情况下）， $\mathbf{v}^T \mathbf{v} = 0$ ，也就是说，我们要找的 $\mathbf{v}$ 其实就是满足： $\mathbf{v}^T \mathbf{x} + \mathbf{x}^T \mathbf{v} = 0$ 的 $\mathbf{v}$ 。我们将所有满足这个条件的 $\mathbf{v}$ 组成的集合，写为：

$$T_{\mathbf{x}} S^{n-1} = \{\mathbf{v} \in \mathbb{R}^n : \mathbf{v}^T \mathbf{x} + \mathbf{x}^T \mathbf{v} = 0\} = \{\mathbf{v} \in \mathbb{R}^n : \mathbf{x}^T \mathbf{v} = 0\}$$

这就是所谓的切空间（tangent space）。

满足条件的所有 $\mathbf{v}$ 构成了切空间

实际使用中，会有一个retraction将更新后偏离流形的点重新映射回流形



Retraction $R_x(v) = \frac{x+v}{\|x+v\|}$ on the sphere.

可以推导：切空间上的 $f(x)$ 的最快下降方向为欧式梯度在切空间上的投影。

现在，有了确定的 优化方向 后 优化之后的 Retraction 步骤，流形优化的整体框架也呼之欲出：

Input: $x_0 \in \mathcal{M}$

For $k = 0, 1, 2, \dots$

Pick a step-size $\alpha_k > 0$

$x_{k+1} = R_{x_k}(s_k)$, with step $s_k = -\alpha_k \text{grad} f(x_k)$

其中 α_k 是用某种方式选定的步长。而：

$$\text{grad} f(x) = (I_n - xx^T) \text{grad} \bar{f}(x), \quad R_x(v) = \frac{x+v}{\|x+v\|}.$$

至此，定义在流形 S^{n-1} 上的对 $f(x)$ 的优化算法就叙述完成了。

总结：先求解欧式梯度，然后投影到切平面上，然后映射到流形上，就得到了流形上的优化方向

2、VI状态估计中的最大后验概率

给定一个VI系统

状态：系统在 i 时刻的状态用IMU的方向、位置、速度和bias来描述： $\mathbf{x}_i \equiv [\mathbf{R}_i, \mathbf{p}_i, \mathbf{v}_i, \mathbf{b}_i]$ ，其中 $(\mathbf{R}_i, \mathbf{p}_i) \in \text{SE}(3)$ ，速度在向量空间中即 $\mathbf{v}_i \in \mathbb{R}^3$ ，IMU bias可以写成 $\mathbf{b}_i = [\mathbf{b}_i^g, \mathbf{b}_i^a] \in \mathbb{R}^6$ ，其中 $\mathbf{b}_i^g, \mathbf{b}_i^a \in \mathbb{R}^3$ 是陀螺仪和加速度计的bias。

记 $\mathcal{K}_k$ 为到时刻 k 为止的所有关键帧集合。这里估计所有关键帧的状态：

$$\mathcal{X}_k \doteq \{\mathbf{x}_i\}_{i \in \mathcal{K}_k} \quad (16)$$

这里采用了一种无结构的方法(参见第六节)，因此3D路标不属于待估计变量的一部分。

测量：系统输入是来自相机和IMU的测量值。 $\mathcal{C}_i$ 为在关键帧 i 的相机测量，在 i 时刻相机可以观察到多个路标 l ，因此 $\mathcal{C}_i$ 包含多个像素的观测 $\mathbf{z}_{il}$ 。用 $\mathcal{I}_{ij}$ 表示在两个连续关键帧 i 和 j 之间获得的IMU测量集合。通常每个 $\mathcal{I}_{ij}$ 包含数百个IMU测量。到时间 k 收集到的测量集合是

$$\mathcal{Z}_k \doteq \{\mathcal{C}_i, \mathcal{I}_{ij}\} (i, j) \in \mathcal{K}_k \quad (17)$$

因子图和MAP估计：给定可用测量 $\mathcal{Z}_k$ 和先验 $p(\mathcal{X}_0)$ ，因子图编码了变量 $\mathcal{X}_k$ 的后验概率：

$$\begin{aligned} p(\mathcal{X}_k | \mathcal{Z}_k) &\propto p(\mathcal{X}_0) p(\mathcal{Z}_k | \mathcal{X}_k) = p(\mathcal{X}_0) \prod_{(i,j) \in \mathcal{K}_k} p(\mathcal{C}_i, \mathcal{I}_{ij} | \mathcal{X}_k) \\ &= p(\mathcal{X}_0) \prod_{(i,j) \in \mathcal{K}_k} p(\mathcal{I}_{ij} | \mathbf{x}_i, \mathbf{x}_j) \prod_{i \in \mathcal{K}_k} \prod_{l \in \mathcal{C}_i} p(\mathbf{z}_{il} | \mathbf{x}_i) \end{aligned} \quad (18)$$

因式分解(18)中的项称为因子 (factors)。图4给出了问题的因子图的连通性示意图(无结构视觉因子的连通性将在第VI节中阐明)。




Fig. 4: Left: visual and inertial measurements in VIN. Right: factor graph in which several IMU measurements are summarized in a single preintegrated IMU factor and a structureless vision factor constraints keyframes observing the same landmark.

MAP估计对应于公式(18)的最大值，或者等价于负对数后验的最小值。在零均值高斯噪声的假设下，负对数后验可以写成残差平方和：

$$\begin{aligned} \mathcal{X}_k^* &\doteq \arg \min_{\mathcal{X}_k} -\log_e p(\mathcal{X}_k | \mathcal{Z}_k) \\ &= \arg \min_{\mathcal{X}_k} \|\mathbf{r}_0\|_{\Sigma_0}^2 + \sum_{(i,j) \in \mathcal{K}_k} \|\mathbf{r}_{\mathcal{I}_{ij}}\|_{\Sigma_{ij}}^2 + \sum_{i \in \mathcal{K}_k} \sum_{l \in \mathcal{C}_i} \|\mathbf{r}_{\mathcal{C}_{il}}\|_{\Sigma_C}^2 \end{aligned} \quad (19)$$

其中 $\mathbf{r}_0, \mathbf{r}_{\mathcal{I}_{ij}}, \mathbf{r}_{\mathcal{C}_{il}}$ 是关于测量的残差项， $\Sigma_0, \Sigma_{ij}, \Sigma_C$ 是对应的协方差矩阵。

3、imu模型和运动积分

IMU测量相对于惯性系的传感器的转速（rotate rate）和加速度。测量记为 ${}_B\tilde{\boldsymbol{\omega}}(t)$, ${}_B\tilde{\boldsymbol{\omega}}_{WB}(t)$ ，受到加性白噪声 $\boldsymbol{\eta}$ 和缓慢变化的传感器bias $\mathbf{b}$ 的影响。

$${}_B\tilde{\boldsymbol{\omega}}_{WB}(t) = {}_B\boldsymbol{\omega}_{WB}(t) + \mathbf{b}^g(t) + \boldsymbol{\eta}^g(t) \quad (20)$$

$${}_B\tilde{\mathbf{a}}(t) = \mathbf{R}_{WB}^\top(t) ({}_W\mathbf{a}(t) - {}_W\mathbf{g}) + \mathbf{b}^a(t) + \boldsymbol{\eta}^a(t) \quad (21)$$

前缀B表示对应的量在坐标系B中表示(c.f., 图3)。IMU的位姿由变换 $\mathbf{R}_{WB,W}$ 描述，它将一个点从传感器坐标系B映射到W。向量 ${}_B\tilde{\boldsymbol{\omega}}_{WB}(t) \in \mathbb{R}^3$ 为B相对于W的瞬时角速度，在坐标系B中表示； ${}_B\tilde{\mathbf{a}}(t) \in \mathbb{R}^3$ 传感器的加速度； ${}_W\mathbf{g}$ 是世界坐标中的重力向量。这里忽略了地球自转的影响，这相当于假设W是一个惯性系。

运动学模型

现在的目标是从IMU测量中推断系统的运动。为此，引入以下运动学模型[38,39]:

$$\dot{\mathbf{R}}_{WB} = \mathbf{R}_{WB} {}_B\boldsymbol{\omega}_{WB}^\wedge, \quad {}_W\dot{\mathbf{v}} = {}_W\mathbf{a}, \quad {}_W\dot{\mathbf{p}} = {}_W\mathbf{v} \quad (22)$$

这描述了B的姿态和速度的演变。

$t + \Delta t$ 时刻的状态由式(22)积分得到。应用欧拉积分，假设 ${}_W\mathbf{a}$ 和 ${}_B\boldsymbol{\omega}_{WB}$ 在区间 $[t, t + \Delta t]$ 中保持恒定，得到:

$$\begin{aligned} \mathbf{R}_{WB}(t + \Delta t) &= \mathbf{R}_{WB}(t) \text{Exp}({}_B\boldsymbol{\omega}_{WB}(t)\Delta t) \\ {}_W\mathbf{v}(t + \Delta t) &= {}_W\mathbf{v}(t) + {}_W\mathbf{a}(t)\Delta t \\ {}_W\mathbf{p}(t + \Delta t) &= {}_W\mathbf{p}(t) + {}_W\mathbf{v}(t)\Delta t + \frac{1}{2}{}_W\mathbf{a}(t)\Delta t^2. \end{aligned} \quad (23)$$

使用公式 (20)-(21)，根据IMU测量可以计算 ${}_W\mathbf{a}$ 和 ${}_B\boldsymbol{\omega}_{WB}$ ，因此(23)为:

$$\begin{aligned} \mathbf{R}(t + \Delta t) &= \mathbf{R}(t) \text{Exp}((\tilde{\boldsymbol{\omega}}(t) - \mathbf{b}^g(t) - \boldsymbol{\eta}^{gd}(t))\Delta t) \\ \mathbf{v}(t + \Delta t) &= \mathbf{v}(t) + \mathbf{g}\Delta t + \mathbf{R}(t) (\tilde{\mathbf{a}}(t) - \mathbf{b}^a(t) - \boldsymbol{\eta}^{ad}(t))\Delta t \\ \mathbf{p}(t + \Delta t) &= \mathbf{p}(t) + \mathbf{v}(t)\Delta t + \frac{1}{2}\mathbf{g}\Delta t^2 \\ &\quad + \frac{1}{2}\mathbf{R}(t) (\tilde{\mathbf{a}}(t) - \mathbf{b}^a(t) - \boldsymbol{\eta}^{ad}(t))\Delta t^2 \end{aligned} \quad (24)$$

4、在流形上的IMU预积分

本文贡献1

将i-j之间的所有imu测量合并为一个单一的复合测量




Fig. 5: Different rates for IMU and camera.

本文的目标是避免重复积分。为此定义了以下相对运动增量，它们与 t_i 时刻的位姿和速度无关：

$$\begin{aligned}
 \Delta \mathbf{R}_{ij} &\doteq \mathbf{R}_i^\top \mathbf{R}_j = \prod_{k=i}^{j-1} \text{Exp} \left((\tilde{\boldsymbol{\omega}}_k - \mathbf{b}_k^g - \boldsymbol{\eta}_k^{gd}) \Delta t \right) \\
 \Delta \mathbf{v}_{ij} &\doteq \mathbf{R}_i^\top (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) = \sum_{k=i}^{j-1} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^{ad}) \Delta t \\
 \Delta \mathbf{p}_{ij} &\doteq \mathbf{R}_i^\top \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right) \\
 &= \sum_{k=i}^{j-1} \left[\Delta \mathbf{v}_{ik} \Delta t + \frac{1}{2} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^{ad}) \Delta t^2 \right] \\
 &= \sum_{k=i}^{j-1} \left[\frac{3}{2} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^{ad}) \Delta t^2 \right]
 \end{aligned} \tag{26}$$

其中定义 $\Delta \mathbf{R}_{ik} \equiv \mathbf{R}_i^\top \mathbf{R}_k$ ， $\Delta \mathbf{v}_{ik} \equiv \mathbf{v}_k - \mathbf{v}_i$ 。

但是这样的公式中，每个都仍然是bias的函数，一旦bias变化就需要重新计算，为了解决这个问题，按照以下步骤一步步进行。

A. 预积分imu测量

假设 t_i 时刻的bias都是已知的，现在需要将bias从公式中分离：

$$\begin{aligned}
 \Delta \mathbf{R}_{ij} &\stackrel{(\text{eq.7})}{=} \prod_{k=i}^{j-1} \left[\text{Exp}((\tilde{\boldsymbol{\omega}}_k - \mathbf{b}_i^g) \Delta t) \text{Exp}(-\mathbf{J}_r^k \boldsymbol{\eta}_k^{gd} \Delta t) \right] \\
 &\stackrel{(\text{eq.11})}{=} \Delta \tilde{\mathbf{R}}_{ij} \prod_{k=i}^{j-1} \text{Exp}(-\Delta \tilde{\mathbf{R}}_{k+1j}^\top \mathbf{J}_r^k \boldsymbol{\eta}_k^{gd} \Delta t) \\
 &\doteq \Delta \tilde{\mathbf{R}}_{ij} \text{Exp}(-\delta \phi_{ij})
 \end{aligned} \tag{28}$$

其中 $\mathbf{J}_r^k \equiv \mathbf{J}_r^k(\tilde{\boldsymbol{\omega}}_k - \mathbf{b}_i^g)$ 。定义预积分旋转测量 $\Delta \tilde{\mathbf{R}}_{ij} \equiv \prod_{k=i}^{j-1} \text{Exp}((\tilde{\boldsymbol{\omega}}_k - \mathbf{b}_i^g) \Delta t)$ ，其噪声 $\delta \phi_{ij}$ 将在下一节中进一步分析。

将(28)带入到(26)，使用(4)对于 $\text{Exp}(-\delta\phi_{ij})$ 使用一阶近似，并扔掉高阶的噪声项，可以获得：

$$\begin{aligned}
 \Delta \mathbf{v}_{ij} &\doteq \mathbf{R}_i^\top (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) \\
 &= \sum_{k=i}^{j-1} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^{ad}) \Delta t \\
 &= \sum_{k=i}^{j-1} (\Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a) \Delta t - \Delta \mathbf{R}_{ik} \boldsymbol{\eta}_k^{ad} \Delta t) \\
 &\quad \text{代入(28)} \\
 &= \sum_{k=i}^{j-1} (\Delta \tilde{\mathbf{R}}_{ij} \text{Exp}(-\delta\phi_{ij}) (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a) \Delta t - \Delta \tilde{\mathbf{R}}_{ij} \text{Exp}(-\delta\phi_{ij}) \boldsymbol{\eta}_k^{ad} \Delta t)
 \end{aligned}$$

变形：

$$\begin{aligned}
 \Delta \mathbf{v}_{ij} &\stackrel{\text{eq.(4)}}{\simeq} \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\mathbf{I} - \delta\phi_{ik}^\wedge) (\tilde{\mathbf{a}}_k - \mathbf{b}_i^a) \Delta t - \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_k^{ad} \Delta t \\
 &\stackrel{\text{eq.(2)}}{=} \Delta \tilde{\mathbf{v}}_{ij} + \sum_{k=i}^{j-1} \left[\Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_i^a)^\wedge \delta\phi_{ik} \Delta t - \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_k^{ad} \Delta t \right] \\
 &\doteq \Delta \tilde{\mathbf{v}}_{ij} - \delta \mathbf{v}_{ij}
 \end{aligned}$$

其中定义了预积分速度测量 $\Delta \tilde{\mathbf{v}}_{ij} \equiv \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_i^a) \Delta t$ 和它的噪声 $\delta \mathbf{v}_{ij}$ 。

同理，将(28)代入(26)中 $\Delta \mathbf{p}_{ij}$ 的表达式中，利用一阶近似(4)可得：

$$\begin{aligned}
 \Delta \mathbf{p}_{ij} &= \sum_{k=i}^{j-1} \left[\frac{3}{2} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^{ad}) \Delta t^2 \right] \\
 &\quad \text{代入(28)} \\
 \Delta \mathbf{p}_{ij} &= \sum_{k=i}^{j-1} \left[\frac{3}{2} \Delta \tilde{\mathbf{R}}_{ij} \text{Exp}(-\delta\phi_{ij}) (\tilde{\mathbf{a}}_k - \mathbf{b}_k^a - \boldsymbol{\eta}_k^{ad}) \Delta t^2 \right]
 \end{aligned}$$

变形：

$$\begin{aligned}
 \Delta \mathbf{p}_{ij} &\stackrel{\text{eq.(4)}}{\simeq} \sum_{k=i}^{j-1} \frac{3}{2} \Delta \tilde{\mathbf{R}}_{ik} (\mathbf{I} - \delta\phi_{ik}^\wedge) (\tilde{\mathbf{a}}_k - \mathbf{b}_i^a) \Delta t^2 - \sum_{k=i}^{j-1} \frac{3}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_k^{ad} \Delta t^2 \\
 &\stackrel{\text{eq.(2)}}{=} \Delta \tilde{\mathbf{p}}_{ij} + \sum_{k=i}^{j-1} \left[\frac{3}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_i^a)^\wedge \delta\phi_{ik} \Delta t^2 - \frac{3}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_k^{ad} \Delta t^2 \right] \\
 &\doteq \Delta \tilde{\mathbf{p}}_{ij} - \delta \mathbf{p}_{ij}
 \end{aligned}$$

(30)

其中定义了预积分位置测量 $\Delta \tilde{\mathbf{p}}_{ij}$ 和它的噪声 $\delta \mathbf{p}_{ij}$ 。

将(28),(29),(30)代入(26)，最终得到预积分测量模型：

$$\begin{aligned}\Delta \tilde{\mathbf{R}}_{ij} &= \mathbf{R}_i^\top \mathbf{R}_j \text{Exp}(\delta \phi_{ij}) \\ \Delta \tilde{\mathbf{v}}_{ij} &= \mathbf{R}_i^\top (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) + \delta \mathbf{v}_{ij} \\ \Delta \tilde{\mathbf{p}}_{ij} &= \mathbf{R}_i^\top \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right) + \delta \mathbf{p}_{ij}\end{aligned}\quad (31)$$

其中复合测量被写成(待估计)状态“加上”随机噪声的函数，由随机向量描述 $[\delta \phi_{ij}^T, \delta \mathbf{v}_{ij}^T, \delta \mathbf{p}_{ij}^T]^T$ 。下一节将讨论噪声项的性质。

B. 噪声传播

- 旋转噪声

从旋转噪声开始：

$$\begin{aligned}\Delta \tilde{\mathbf{R}}_{ij} &= \mathbf{R}_i^\top \mathbf{R}_j \text{Exp}(\delta \phi_{ij}) \\ \Rightarrow \text{Exp}(-\delta \phi_{ij}) &\doteq \prod_{k=i}^{j-1} \text{Exp}\left(-\Delta \tilde{\mathbf{R}}_{k+1j}^\top \mathbf{J}_r^k \boldsymbol{\eta}_k^{gd} \Delta t\right)\end{aligned}\quad (32)$$

两边取Log并改变符号：

$$\delta \phi_{ij} = -\text{Log}\left(\prod_{k=i}^{j-1} \text{Exp}\left(-\Delta \tilde{\mathbf{R}}_{k+1j}^\top \mathbf{J}_r^k \boldsymbol{\eta}_k^{gd} \Delta t\right)\right)\quad (33)$$

重复应用一阶近似得到（回想一下 $\boldsymbol{\eta}^{gd}$ 和 $\delta \phi_{ij}$ 是小旋转噪声，因此右雅可比矩阵接近恒等）：

$$\delta \phi_{ij} \simeq \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{k+1j}^\top \mathbf{J}_r^k \boldsymbol{\eta}_k^{gd} \Delta t\quad (34)$$

在一阶范围内，因为噪声 $\delta \phi_{ij}$ 是零均值噪声项 $\boldsymbol{\eta}_k^{gd}$ 的线性组合，所以 $\delta \phi_{ij}$ 为零均值高斯分布。这是可取的，因为它将旋转测量模型(31)精确地转化为(12)的形式。

$$\tilde{\mathbf{R}} = \mathbf{R} \text{Exp}(\boldsymbol{\epsilon}), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \Sigma)\quad (12)$$

其中 $\mathbf{R}$ 是一个给定的无噪声旋转(均值), $\boldsymbol{\epsilon}$ 为均值为零的小的正态分布扰动。

C. bias更新

C.Bias更新

在上一节中假设用于计算预积分测量值的偏差 $\mathbf{b}_i$ 已经给出。然而另一种可能的是，bias估计在优化过程中发生了变化。一种解决方案是，当bias改变时，重新计算增量测量值；然而这在计算上是昂贵的。反之，给定bias更新 $\mathbf{b} \leftarrow \bar{\mathbf{b}} + \delta \mathbf{b}$ ，可以使用一阶展开来更新增量测量值：

$$\begin{aligned}\Delta \tilde{\mathbf{R}}_{ij}(\mathbf{b}_i^g) &\simeq \Delta \tilde{\mathbf{R}}_{ij}(\bar{\mathbf{b}}_i^g) \text{Exp}\left(\frac{\partial \Delta \tilde{\mathbf{R}}_{ij}}{\partial \mathbf{b}^g} \delta \mathbf{b}^g\right) \\ \Delta \tilde{\mathbf{v}}_{ij}(\mathbf{b}_i^g, \mathbf{b}_i^a) &\simeq \Delta \tilde{\mathbf{v}}_{ij}(\bar{\mathbf{b}}_i^g, \bar{\mathbf{b}}_i^a) + \frac{\partial \Delta \tilde{\mathbf{v}}_{ij}}{\partial \mathbf{b}^g} \delta \mathbf{b}_i^g + \frac{\partial \Delta \tilde{\mathbf{v}}_{ij}}{\partial \mathbf{b}^a} \delta \mathbf{b}_i^a \\ \Delta \tilde{\mathbf{p}}_{ij}(\mathbf{b}_i^g, \mathbf{b}_i^a) &\simeq \Delta \tilde{\mathbf{p}}_{ij}(\bar{\mathbf{b}}_i^g, \bar{\mathbf{b}}_i^a) + \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}^g} \delta \mathbf{b}_i^g + \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}^a} \delta \mathbf{b}_i^a\end{aligned}\quad (36)$$

D. 预积分imu因子

E. bias模型

5、简明预积分推导（gaoxiang）

<https://zhuanlan.zhihu.com/p/388859808>

1. 预积分定义

在一个IMU系统里，我们考虑它的五个变量：旋转 $\mathbf{R}$ 、平移 $\mathbf{p}$ 、角速度 $\boldsymbol{\omega}$ 、线速度 $\mathbf{v}$ 与加速度 $\mathbf{a}$ 。根据旋转运动学，这些变量的运动学关系可以写成[5]：

$$\begin{aligned}\dot{\mathbf{R}} &= \mathbf{R}\boldsymbol{\omega}^\wedge, \\ \dot{\mathbf{p}} &= \mathbf{v} \\ \dot{\mathbf{v}} &= \mathbf{a}\end{aligned}$$

这边的导数是对时间的倒数，需要记住R对时间的导数是上面的结果，是给定的运动学关系

在 t 到 $t + \Delta t$ 时间内，对上式进行欧拉积分，可得：

$$\begin{aligned} \mathbf{R}(t + \Delta t) &= \mathbf{R}(t) \text{Exp}(\boldsymbol{\omega}(t) \Delta t) \\ \mathbf{v}(t + \Delta t) &= \mathbf{v}(t) + \mathbf{a}(t) \Delta t \\ \mathbf{p}(t + \Delta t) &= \mathbf{p}(t) + \mathbf{v}(t) \Delta t + \frac{1}{2} \mathbf{a}(t) \Delta t^2 \end{aligned}$$

很直观，对于 $\mathbf{v}$ 和 $\mathbf{p}$ 这两个线性的函数来说，定义域内的变化可以线性地反映到值域上，但是对于旋转矩阵 $\mathbf{R}$ ，属于 $\text{SO}(3)$ 特殊正交群，线性的原则不适用，其与一个三维的旋转向量一一对应，因此时间上的微小变化可以反映为角度的变化，角度的变化可以通过指数变换转化为旋转矩阵的变化，体现形式就是右乘。

其中角速度和加速度可以被IMU测量到，但受到噪声与重力影响。令测量值为 $\tilde{\boldsymbol{\omega}}$ 和 $\tilde{\mathbf{a}}$ ，则：

$$\begin{aligned} \tilde{\boldsymbol{\omega}}(t) &= \boldsymbol{\omega}(t) + \mathbf{b}_g(t) + \boldsymbol{\eta}_g(t) \\ \tilde{\mathbf{a}}(t) &= \mathbf{R}^T(\mathbf{a}(t) - \mathbf{g}) + \mathbf{b}_a(t) + \boldsymbol{\eta}_a(t) \end{aligned}$$

其中 $\mathbf{b}_g, \mathbf{b}_a$ 为陀螺和加速度计零偏， $\boldsymbol{\eta}_a, \boldsymbol{\eta}_g$ 为测量的高斯噪声⁺。把该式代入上式，可得到测量值与状态变量的关系：

$$\begin{aligned} \mathbf{R}(t + \Delta t) &= \mathbf{R}(t) \text{Exp}((\tilde{\boldsymbol{\omega}} - \mathbf{b}_g(t) - \boldsymbol{\eta}_{gd}(t)) \Delta t) \\ \mathbf{v}(t + \Delta t) &= \mathbf{v}(t) + \mathbf{g} \Delta t + \mathbf{R}(t)(\tilde{\mathbf{a}} - \mathbf{b}_a(t) - \boldsymbol{\eta}_{ad}(t)) \Delta t \\ \mathbf{p}(t + \Delta t) &= \mathbf{p}(t) + \mathbf{v}(t) \Delta t + \frac{1}{2} \mathbf{g} \Delta t^2 + \frac{1}{2} \mathbf{R}(t)(\tilde{\mathbf{a}} - \mathbf{b}_a(t) - \boldsymbol{\eta}_{ad}(t)) \Delta t^2 \end{aligned}$$

其中 $\boldsymbol{\eta}_{gd}, \boldsymbol{\eta}_{ad}$ 是离散化⁺后的随机游走⁺噪声[6]：

$$\begin{aligned} \text{Cov}(\boldsymbol{\eta}_{gd}(t)) &= \frac{1}{\Delta t} \text{Cov}(\boldsymbol{\eta}_g(t)) \\ \text{Cov}(\boldsymbol{\eta}_{ad}(t)) &= \frac{1}{\Delta t} \text{Cov}(\boldsymbol{\eta}_a(t)) \end{aligned}$$

因此可以根据上面的约束来构建imu的图优化，但是imu频率太高，因此可以使用预积分将一段时间内的imu数据累计起来进行统一处理。

在 k 到 j 的过程中，将变量累计起来得到：

$$\mathbf{R}_j = \mathbf{R}_i \prod_{k=i}^{j-1} (\text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,k} - \boldsymbol{\eta}_{gd,k}) \Delta t))$$

$$\mathbf{v}_j = \mathbf{v}_i + \mathbf{g} \Delta t_{ij} + \sum_{k=i}^{j-1} \mathbf{R}_k (\tilde{\mathbf{a}} - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t$$

$$\mathbf{p}_j = \mathbf{p}_i + \sum_{k=i}^{j-1} \mathbf{v}_k \Delta t + \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 + \frac{1}{2} \sum_{k=i}^{j-1} \mathbf{R}_k (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t^2$$

这相当与传统意义上的直接积分，假如i时刻状态改变，那么后面所有时刻的积分结果就需要重新计算，可以修改为相对运动量：

$$\Delta \mathbf{R}_{ij} \doteq \mathbf{R}_i^T \mathbf{R}_j = \prod_{k=i}^{j-1} \text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,k} - \boldsymbol{\eta}_{gd,k}) \Delta t)$$

$$\Delta \mathbf{v}_{ij} \doteq \mathbf{R}_i^T (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) = \sum_{k=i}^{j-1} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t$$

$$\Delta \mathbf{p}_{ij} \doteq \mathbf{R}_i^T \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right)$$

$$= \sum_{k=i}^{j-1} \left[\Delta \mathbf{v}_{ik} \Delta t + \frac{1}{2} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t^2 \right]$$

那么无论i时刻状态如何变化，都不影响后续的累加计算，并且可以很轻松的得到不同时间间隔内的累加量。不过如果ba和bg变化了，还是需要重新计算预积分，但是这一点可以通过“修正”来进行规避。

2. 预积分测量模型

A. 预备知识（李代数）

指数对数映射：

1. 李代数到李群的映射为**指数映射⁺**，其中 $\mathfrak{so}(3)$ 至 $\text{SO}(3)$ 的为：

$$\exp(\phi^\wedge) = \text{Exp}(\phi) = \mathbf{R}, \text{ 反过来的为对数映射⁺: } \phi = \ln(\mathbf{R})^\vee = \text{Log}(\mathbf{R}).$$

bch近似：

$$\exp((\phi + \Delta\phi)^\wedge) = \exp((\mathbf{J}_l \Delta\phi)^\wedge) \exp(\phi^\wedge) = \exp(\phi^\wedge) \exp((\mathbf{J}_r \Delta\phi)^\wedge)$$

$J_l(\theta \mathbf{a}) = \frac{\sin \theta}{\theta} \mathbf{I} + (1 - \frac{\sin \theta}{\theta}) \mathbf{a} \mathbf{a}^T + \frac{1 - \cos \theta}{\theta} \mathbf{a}^\wedge$. 其中 $\phi = \theta \mathbf{a}$ 为模长和方向的分解。
 它的逆矩阵^{*}为: $J_l^{-1}(\theta \mathbf{a}) = \frac{\theta}{2} \cot \frac{\theta}{2} \mathbf{I} + (1 - \frac{\theta}{2} \cot \frac{\theta}{2}) \mathbf{a} \mathbf{a}^T - \frac{\theta}{2} \mathbf{a}^\wedge$. 而右雅可比和左雅可比的关系为: $J_r(\phi) = J_l(-\phi)$.

李群上的伴随关系:

$$\mathbf{R}^T \text{Exp}(\phi) \mathbf{R} = \text{Exp}(\mathbf{R}^T \phi)$$

B. 构建预积分测量模型

由前面的讨论可见, 预积分内部带有IMU的零偏量, 因此不可避免地会依赖此时的零偏量估计。为了处理这种依赖, 我们对预积分定义作一些工程上的调整:

1. 我们首先认为 **i 时刻的零偏是固定的**, 并且在整个预积分计算过程中也都是固定的。
2. 我们作出**预积分对零偏量的一阶线性化模型**, 即, 舍弃对零偏量的高阶项。
3. 当零偏估计发生改变时, 用这个线性模型来修正预积分。

对旋转矩阵 $\mathbf{R}$, 利用BCH近似将噪声项分离, 来定义预积分测量:

$$\begin{aligned} \Delta \mathbf{R}_{ij} &= \prod_{k=i}^{j-1} \underbrace{\text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,k} - \boldsymbol{\eta}_{gd,k}) \Delta t)}_{\text{利用BCH: } \approx \text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,i}) \Delta t) \text{Exp}(-\mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t)} \\ &\approx \prod_{k=i}^{j-1} [\text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,i}) \Delta t) \text{Exp}(-\mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t)] \\ \Delta \tilde{\mathbf{R}}_{ij} &= \prod_{k=i}^{j-1} \text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,i}) \Delta t) \end{aligned}$$

所以拆开累乘符号, 把i到j每一项写出来:

$$\begin{aligned} \Delta \tilde{\mathbf{R}}_{ij} &= \prod_{k=i}^{j-1} \text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,i}) \Delta t) \\ \Delta \mathbf{R}_{ij} &= \Delta \tilde{\mathbf{R}}_{ij} \prod_{k=i}^{j-1} \text{Exp}\left(-\Delta \tilde{\mathbf{R}}_{k+1,j}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t\right) \\ &\doteq \Delta \tilde{\mathbf{R}}_{ij} \text{Exp}(-\delta \phi_{ij}) \end{aligned}$$

$$\begin{aligned}
 \Delta R_{ij} &= \overbrace{\Delta R_{i,1:t}^T}^{\Delta R_{i,1:t}^T} \text{Exp}((w_i - b_i) \Delta t) \text{Exp}(-J_{r,i} J_{gd,i} \Delta t) \cdot \overbrace{\Delta R_{i,t+1}^T}^{\Delta R_{i,t+1}^T} \text{Exp}(-J_{r,i} J_{gd,i} \Delta t) \dots \\
 &= \Delta R_{i,1:t}^T \text{Exp}(-J_{r,i} J_{gd,i} \Delta t) \cdot \Delta R_{i,t+1}^T \text{Exp}(-J_{r,i} J_{gd,i} \Delta t) \dots \\
 &= \Delta R_{i,1:t}^T \text{Exp}(-\Delta R_{i,1:t}^T J_{r,i} J_{gd,i} \Delta t) \quad (\text{查群件数值表}) \\
 &= \Delta R_{i,1:t}^T \text{Exp}(-R_{i,1:t}^T J_{r,i} J_{gd,i} \Delta t) \text{Exp}(-J_{r,i} J_{gd,i} \Delta t) \Delta R_{i,t+1}^T \dots \\
 &\quad \text{不断累加, 观测到在观测, 噪声到在观测, 合并噪声为} \Delta R \\
 \Rightarrow \Delta R_{ij} &= \Delta R_{ij}^T \prod_{k=i}^j \text{Exp}(-\Delta R_{k,i}^T J_{r,k} J_{gd,k} \Delta t) \\
 \text{当前观测噪声项} &= \Delta R_{ij}^T \text{Exp}(-\delta \phi_{ij})
 \end{aligned}$$

对速度v，在之前的定义公式中加上刚定义的相对旋转：

$$\begin{aligned}
\Delta \mathbf{v}_{ij} &= \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t \\
&= \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} \underbrace{\text{Exp}(-\delta \phi_{ik})}_{\approx \mathbf{I} - \delta \phi_{ik}^{\wedge}} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t \\
&= \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\mathbf{I} - \delta \phi_{ik}^{\wedge}) (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t
\end{aligned}$$

我们舍掉上式中的噪声二阶小量，并且定义预积分速度观测量为：

$$\Delta \tilde{\mathbf{v}}_{ij} = \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i}) \Delta t$$

那么上式可以化简为：

$$\begin{aligned}
\Delta \mathbf{v}_{ij} &= \sum_{k=i}^{j-1} \underbrace{\Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i}) \Delta t}_{\text{累加此项}} + \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^{\wedge} \delta \phi_{ik} \Delta t - \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \Delta t \\
&= \Delta \tilde{\mathbf{v}}_{ij} + \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^{\wedge} \delta \phi_{ik} \Delta t - \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \Delta t \\
&= \Delta \tilde{\mathbf{v}}_{ij} - \delta \mathbf{v}_{ij}
\end{aligned}$$

注意，噪声的二阶小量指的是旋转的噪声和速度的二阶相乘的项，可以在此处忽略

对平移p，将旋转和速度的观测量带入可以得到：

最后，可以对平移部分定义类似的操作。按照平移部分的定义方式，将旋转和速度观测量代入，可得：

$$\begin{aligned}
 \Delta \mathbf{p}_{ij} &= \sum_{k=i}^{j-1} \left[\Delta \mathbf{v}_{ik} \Delta t + \frac{1}{2} \Delta \mathbf{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t^2 \right] \\
 &= \sum_{k=i}^{j-1} \left[(\Delta \tilde{\mathbf{v}}_{ij} - \delta \mathbf{v}_{ij}) \Delta t + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \underbrace{\text{Exp}(-\delta \phi_{ik})}_{\mathbf{I} - \delta \phi_{ik}^{\wedge}} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,k} - \boldsymbol{\eta}_{ad,k}) \Delta t^2 \right] \\
 &\approx \sum_{k=i}^{j-1} \left[(\Delta \tilde{\mathbf{v}}_{ik} - \delta \mathbf{v}_{ik}) \Delta t + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\mathbf{I} - \delta \phi_{ik}^{\wedge}) (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i}) \Delta t^2 - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \right] \\
 &\approx \sum_{k=i}^{j-1} \left[\Delta \tilde{\mathbf{v}}_{ik} \Delta t + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i}) \Delta t^2 - \delta \mathbf{v}_{ik} \Delta t + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^{\wedge} \delta \boldsymbol{\phi}_{ik} \right. \\
 &\quad \left. - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \Delta t^2 \right]
 \end{aligned}$$

在第三式至第四式中我们舍去了二阶噪声小量。同前，我们定义**预积分位移观测**⁺量为：

$$\Delta \tilde{\mathbf{p}}_{ij} = \sum_{k=i}^{j-1} [(\Delta \tilde{\mathbf{v}}_{ik} \Delta t) + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i}) \Delta t^2]$$

那么前面式子可以写成：

$$\begin{aligned}
 \Delta \mathbf{p}_{ij} &= \Delta \tilde{\mathbf{p}}_{ij} + \sum_{k=i}^{j-1} \left[-\delta \mathbf{v}_{ik} \Delta t + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^{\wedge} \delta \phi_{ik} \Delta t^2 - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \Delta t^2 \right] \\
 &\doteq \Delta \tilde{\mathbf{p}}_{ij} - \delta \mathbf{p}_{ij}
 \end{aligned}$$

Rvp最终的显示如下，预积分公式：

于是，此三式共同定义了预积分的三个观测量和它们的噪声。将它们代回最初的定义式，可以简单写为：

$$\begin{aligned}
 \Delta \tilde{\mathbf{R}}_{ij} &= \mathbf{R}_i^T \mathbf{R}_j \text{Exp}(\delta \phi_{ij}) \\
 \Delta \tilde{\mathbf{v}}_{ij} &= \mathbf{R}_i^T (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) + \delta \mathbf{v}_{ij} \\
 \Delta \tilde{\mathbf{p}}_{ij} &= \mathbf{R}_i^T \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right) + \delta \mathbf{p}_{ij}
 \end{aligned}$$

右侧可以很容易地根据i和j时刻的状态来估计预积分的测量，然后与实际的测量值写成误差公式，做最小二乘。还需要评估的是预积分的噪声情况。

3. 预积分噪声模型

复杂的噪声模型不利于处理，可以将其线性化然后保留一阶项系数，然后推导在线性模型下的协方差矩阵的变化。

A. 旋转的噪声项

$$\text{Exp}(\delta\phi_{ij}) = \prod_{k=i}^{j-1} \text{Exp}(-\Delta\tilde{R}_{k+1}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t)$$

R、J、t都是确定的观测量，作为随机变量只与白噪声（符合高斯分布的随机变量）相关，因此线性化取期望的时候，由于白噪声期望是0，所以旋转的噪声的期望也是0。

对两侧取log，然后bch线性近似

$$\delta\phi_{ij} = -\text{Log} \left(\prod_{k=i}^{j-1} \text{Exp}(-\Delta\tilde{R}_{k+1}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t) \right)$$

$$\delta\phi_{ij} \approx \sum_{k=i}^{j-1} \Delta\tilde{R}_{k+1,j}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t$$

此式是**高斯随机变量**的线性组合，它的结果依然是高斯的。同时，由于预积分的累加特性，预测分观测量的噪声也会随着时间不断累加。可以用j-1时刻的噪声来计算j时刻的噪声：

$$\begin{aligned} \delta\phi_{ij} &\approx \sum_{k=i}^{j-1} \Delta\tilde{R}_{k+1,j}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t \\ &= \sum_{k=i}^{j-2} \Delta\tilde{R}_{k+1,j}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t + \underbrace{\Delta\tilde{R}_{j,j}^T \mathbf{J}_{r,j-1} \boldsymbol{\eta}_{gd,j-1} \Delta t}_{=I} \\ &= \sum_{k=i}^{j-2} \underbrace{\Delta\tilde{R}_{k+1,j}^T}_{(\Delta\tilde{R}_{k+1,j-1} \Delta\tilde{R}_{j-1,j})^T} \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t + \mathbf{J}_{r,j-1} \boldsymbol{\eta}_{gd,j-1} \Delta t \\ &= \Delta\tilde{R}_{j-1,j}^T \sum_{k=i}^{j-2} \Delta\tilde{R}_{k+1,j-1}^T \mathbf{J}_{r,k} \boldsymbol{\eta}_{gd,k} \Delta t + \mathbf{J}_{r,j-1} \boldsymbol{\eta}_{gd,j-1} \Delta t \\ &= \Delta\tilde{R}_{j-1,j}^T \delta\phi_{i,j-1} + \mathbf{J}_{r,j-1} \boldsymbol{\eta}_{gd,j-1} \Delta t \end{aligned}$$

此时协方差分析为：

该式描述了如何从 $j-1$ 时刻的噪声推断至 j 时刻。显然，这是一个线性系统⁺。不妨设 $j-1$ 时刻 $\delta\phi_{i,j-1}$ 的协方差为 Σ_{j-1} ， η_{gd} 的协方差⁺为 $\Sigma_{\eta_{gd}}$ ，那么：

$$\Sigma_j = \Delta \tilde{R}_{j-1,j}^T \Sigma_{j-1} \Delta \tilde{R}_{j-1,j} + J_{r,j-1} \Sigma_{\eta_{gd}} J_{r,j-1}^T \Delta t^2$$

这表明预积分误差会随着累计变大，预积分观测量也会变得越来越不确定。这和实际情况是相符的。

B. 速度的噪声项

与旋转部分类似，速度部分也可以写成高斯噪声变量的线性组合形式：

$$\delta v_{ij} \approx \sum_{k=i}^{j-1} [-\Delta \tilde{R}_{ik} (\tilde{a}_k - b_{a,i})^\wedge \delta \phi_{ik} \Delta t + \Delta \tilde{R}_{ik} \eta_{ad,k} \Delta t]$$

累加形式：

$$\begin{aligned} \delta v_{ij} &= \sum_{k=i}^{j-1} [-\Delta \tilde{R}_{ik} (\tilde{a}_k - b_{a,i})^\wedge \delta \phi_{ik} \Delta t + \Delta \tilde{R}_{ik} \eta_{ad,k} \Delta t] \\ &= \sum_{k=i}^{j-2} [-\Delta \tilde{R}_{ik} (\tilde{a}_k - b_{a,i})^\wedge \delta \phi_{ik} \Delta t + \Delta \tilde{R}_{ik} \eta_{ad,k} \Delta t] \\ &\quad - \Delta \tilde{R}_{i,j-1} (\tilde{a}_{j-1} - b_{a,i})^\wedge \delta \phi_{i,j-1} \Delta t + \Delta \tilde{R}_{i,j-1} \eta_{ad,j-1} \Delta t \\ &= \delta v_{i,j-1} - \Delta \tilde{R}_{i,j-1} (\tilde{a}_{j-1} - b_{a,i})^\wedge \delta \phi_{i,j-1} \Delta t + \Delta \tilde{R}_{i,j-1} \eta_{ad,j-1} \Delta t \end{aligned}$$

于是 δv_{ij} 的协方差也可以根据累加系数来确定。

C. 平移的噪声项

$\delta p_{ij} =$

对于平移部分也可以做同样的处理。我们直接列写平移部分噪声的累加形式：

$$\begin{aligned} & \sum_{k=i}^{j-1} \left[\delta \mathbf{v}_{ik} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^\wedge \delta \phi_{ik} \Delta t^2 + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \Delta t^2 \right] \\ & \sum_{k=i}^{j-2} \left[\delta \mathbf{v}_{ik} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^\wedge \delta \phi_{ik} \Delta t^2 + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \boldsymbol{\eta}_{ad,k} \Delta t^2 \right] \\ & + \delta \mathbf{v}_{i,j-1} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{i,j-1} (\tilde{\mathbf{a}}_{j-1} - \mathbf{b}_{a,i})^\wedge \delta \phi_{i,j-1} \Delta t^2 + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{i,j-1} \boldsymbol{\eta}_{ad,j-1} \Delta t^2 \\ & \delta \mathbf{p}_{i,j-1} + \delta \mathbf{v}_{i,j-1} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{i,j-1} (\tilde{\mathbf{a}}_{j-1} - \mathbf{b}_{a,i})^\wedge \delta \phi_{i,j-1} \Delta t^2 + \frac{1}{2} \Delta \tilde{\mathbf{R}}_{i,j-1} \boldsymbol{\eta}_{ad,j-1} \Delta t^2 \end{aligned}$$

4. 零偏的更新

如果IMU零偏发生了变化，预积分应该重新计算，因为预积分的每一步都用到了 $\diamond$ 时刻的IMU零偏。但是实际操作过程中，我们也可以选用一种讨巧的做法：**假定预积分观测是随零偏线性变化的。**

修正。具体来说，我们把预积分观测量看成 $\mathbf{b}_{g,i}$, $\mathbf{b}_{a,i}$ 的函数，那么，当 $\mathbf{b}_{g,i}$, $\mathbf{b}_{a,i}$ 更新了 $\delta \mathbf{b}_{g,i}$, $\delta \mathbf{b}_{a,i}$ 之后，预积分观测应作如下的修正：

$$\begin{aligned} \Delta \tilde{\mathbf{R}}_{ij}(\mathbf{b}_{g,i} + \delta \mathbf{b}_{g,i}) &= \Delta \tilde{\mathbf{R}}_{ij}(\mathbf{b}_{g,i}) \text{Exp} \left(\frac{\partial \Delta \tilde{\mathbf{R}}_{ij}}{\partial \mathbf{b}_g} \delta \mathbf{b}_{g,i} \right) \\ \Delta \tilde{\mathbf{v}}_{ij}(\mathbf{b}_{g,i} + \delta \mathbf{b}_{g,i}, \mathbf{b}_{a,i} + \delta \mathbf{b}_{a,i}) &= \Delta \tilde{\mathbf{v}}_{ij}(\mathbf{b}_{g,i}, \mathbf{b}_{a,i}) + \frac{\partial \Delta \tilde{\mathbf{v}}_{ij}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i} + \frac{\partial \Delta \tilde{\mathbf{v}}_{ij}}{\partial \mathbf{b}_{a,i}} \delta \mathbf{b}_{a,i} \\ \Delta \tilde{\mathbf{p}}_{ij}(\mathbf{b}_{g,i} + \delta \mathbf{b}_{g,i}, \mathbf{b}_{a,i} + \delta \mathbf{b}_{a,i}) &= \Delta \tilde{\mathbf{p}}_{ij}(\mathbf{b}_{g,i}, \mathbf{b}_{a,i}) + \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i} + \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}_{a,i}} \delta \mathbf{b}_{a,i} \end{aligned}$$

于是问题变成了，如何计算上述的几个偏导数（这些偏导数在整个系统过程中是不发生变化的），然后就可以根据偏导数进行预积分值的修正。

A. 旋转

$$\begin{aligned}
\Delta \tilde{R}_{ij}(\mathbf{b}_{g,i} + \delta \mathbf{b}_{g,i}) &= \prod_{k=i}^{j-1} \text{Exp}((\tilde{\omega}_k - (\mathbf{b}_{g,i} + \delta \mathbf{b}_{g,i}))\Delta t) \\
&= \prod_{k=i}^{j-1} \text{Exp}((\tilde{\omega}_k - \mathbf{b}_{g,i})\Delta t) \text{Exp}(-\mathbf{J}_{r,k} \delta \mathbf{b}_{g,i} \Delta t) \\
&= \underbrace{\text{Exp}((\tilde{\omega}_i - \mathbf{b}_{g,i})\Delta t)}_{\Delta \tilde{R}_{i,i+1}} \text{Exp}(-\mathbf{J}_{r,i} \delta \mathbf{b}_{g,i} \Delta t) \underbrace{\text{Exp}((\tilde{\omega}_{i+1} - \mathbf{b}_{g,i})\Delta t)}_{\Delta \tilde{R}_{i+1,i+2}} \\
&\quad \text{Exp}(-\mathbf{J}_{r,i+1} \delta \mathbf{b}_{g,i} \Delta t) \dots \\
&= \Delta \tilde{R}_{i,i+1} \Delta \tilde{R}_{i+1,i+2} \text{Exp}(-\Delta \tilde{R}_{i+1,i+2}^T \mathbf{J}_{r,i} \delta \mathbf{b}_{g,i} \Delta t) \dots \\
&= \Delta \tilde{R}_{ij} \prod_{k=i}^{j-1} \text{Exp}\left(-\Delta \tilde{R}_{k+1,j}^T \mathbf{J}_{r,k} \delta \mathbf{b}_{g,i} \Delta t\right) \\
&\approx \Delta \tilde{R}_{ij} \text{Exp}\left(-\sum_{k=i}^{j-1} \Delta \tilde{R}_{k+1,j}^T \mathbf{J}_{r,k} \Delta t \delta \mathbf{b}_{g,i}\right)
\end{aligned}$$

最后一行用到了BCH在 $\delta \mathbf{b}_{g,i}$ 为小量时雅可比接近单位阵的性质。通过这种方式我们可以算出 $\Delta \tilde{R}_{ij}$ 相对于 $\mathbf{b}_{g,i}$ 的雅可比矩阵，记为 $\frac{\partial \Delta \tilde{R}_{ij}}{\partial \mathbf{b}_g}$ 。

BCH近似将exp上累乘的结果近似为内部累加结果（右雅各比在小量时接近单位阵可以忽略）

B. 速度

接下来考虑速度测量⁺：

$$\begin{aligned}
\Delta \tilde{\mathbf{v}}(\mathbf{b}_i + \delta \mathbf{b}_i) &= \sum_{k=i}^{j-1} \Delta \tilde{R}_{ik}(\mathbf{b}_{g,i} + \delta \mathbf{b}_{g,i})(\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i} - \delta \mathbf{b}_{a,i})\Delta t \\
&= \sum_{k=i}^{j-1} \Delta \tilde{R}_{ik} \text{Exp}\left(\frac{\partial \Delta \tilde{R}_{ik}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i}\right)(\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i} - \delta \mathbf{b}_{a,i})\Delta t \\
&= \sum_{k=i}^{j-1} \Delta \tilde{R}_{ik} \left(\mathbf{I} + \left(\frac{\partial \Delta \tilde{R}_{ik}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i} \right)^\wedge \right) (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i} - \delta \mathbf{b}_{a,i})\Delta t \\
&\approx \Delta \mathbf{v}_{ij} - \sum_{k=i}^{j-1} \Delta \tilde{R}_{ik} \Delta t \delta \mathbf{b}_{a,i} - \sum_{k=i}^{j-1} \Delta \tilde{R}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^\wedge \frac{\partial \Delta \tilde{R}_{ik}}{\partial \mathbf{b}_{g,i}} \Delta t \delta \mathbf{b}_{g,i} \\
&= \Delta \mathbf{v}_{ij} + \frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{a,i}} \delta \mathbf{b}_{a,i} + \frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i}
\end{aligned}$$

可见速度相对于零偏的导数可以部分地由旋转导数的结果计算出来。

C. 平移

最后是平移部分：

$$\begin{aligned}
 \Delta \tilde{\mathbf{p}}_{ij}(\mathbf{b}_i + \delta \mathbf{b}_i) &= \sum_{k=i}^{j-1} \left[\left(\Delta \tilde{\mathbf{v}}_{ik} + \frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{a,i}} \delta \mathbf{b}_{a,i} + \frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i} \right) \Delta t + \right. \\
 &\quad \left. \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \left(\mathbf{I} + \left(\frac{\partial \Delta \tilde{\mathbf{R}}_{ik}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i} \right)^\wedge \right) (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i} - \delta \mathbf{b}_{a,i}) \Delta t^2 \right] \\
 &= \delta \tilde{\mathbf{p}}_{ij} + \sum_{k=i}^{j-1} \left[\frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{a,i}} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \Delta t^2 \right] \delta \mathbf{b}_{a,i} + \\
 &\quad \sum_{k=i}^{j-1} \left[\frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{g,i}} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^\wedge \frac{\partial \Delta \tilde{\mathbf{R}}_{ik}}{\partial \mathbf{b}_{g,i}} \Delta t^2 \right] \delta \mathbf{b}_{g,i} \\
 &= \delta \tilde{\mathbf{p}}_{ij} + \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}_{a,i}} \delta \mathbf{b}_{a,i} + \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}_{g,i}} \delta \mathbf{b}_{g,i}
 \end{aligned}$$

总结

$$\begin{aligned}
 \frac{\partial \Delta \tilde{\mathbf{R}}_{ij}}{\partial \mathbf{b}_{g,i}} &= - \sum_{k=i}^{j-1} \left[\Delta \tilde{\mathbf{R}}_{k+1,j}^\top \mathbf{J}_{k,r} \Delta t \right] \\
 \frac{\partial \Delta \tilde{\mathbf{v}}_{ij}}{\partial \mathbf{b}_{a,i}} &= - \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} \Delta t \\
 \frac{\partial \Delta \tilde{\mathbf{v}}_{ij}}{\partial \mathbf{b}_{g,i}} &= - \sum_{k=i}^{j-1} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^\wedge \frac{\partial \Delta \tilde{\mathbf{R}}_{ij}}{\partial \mathbf{b}_{g,i}} \Delta t \\
 \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}_{a,i}} &= \sum_{k=i}^{j-1} \frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{a,i}} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} \Delta t^2 \\
 \frac{\partial \Delta \tilde{\mathbf{p}}_{ij}}{\partial \mathbf{b}_{g,i}} &= \sum_{k=i}^{j-1} \frac{\partial \Delta \mathbf{v}_{ij}}{\partial \mathbf{b}_{g,i}} \Delta t - \frac{1}{2} \Delta \tilde{\mathbf{R}}_{ik} (\tilde{\mathbf{a}}_k - \mathbf{b}_{a,i})^\wedge \frac{\partial \Delta \tilde{\mathbf{R}}_{ik}}{\partial \mathbf{b}_{g,i}} \Delta t^2
 \end{aligned}$$

5. 预积分构建残差

$$\mathbf{x}_k = [\mathbf{R}, \mathbf{p}, \mathbf{v}, \mathbf{b}_a, \mathbf{b}_g]_k \in \mathcal{X}$$

而预积分模型构建了关键帧 i 与关键帧 k 之间的一种约束，它的残差可以写成：

$$\begin{aligned} \mathbf{r}_{\Delta \mathbf{R}_{ij}} &= \text{Log} \left(\Delta \tilde{\mathbf{R}}_{ij}^T (\mathbf{R}_i^T \mathbf{R}_j) \right) \\ \mathbf{r}_{\Delta \mathbf{v}_{ij}} &= \mathbf{R}_i^T (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) - \Delta \tilde{\mathbf{v}}_{ij} \\ \mathbf{r}_{\Delta \mathbf{p}_{ij}} &= \mathbf{R}_i^T \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right) - \Delta \tilde{\mathbf{p}}_{ij} \end{aligned}$$

残差的雅各比：

deltaR对i、j时刻旋转的导数

$$\begin{aligned} \mathbf{r}_{\Delta \mathbf{R}_{ij}} (\mathbf{R}_i \text{Exp}(\boldsymbol{\phi}_i)) &= \text{Log} \left(\Delta \tilde{\mathbf{R}}_{ij}^T (\mathbf{R}_i \text{Exp}(\boldsymbol{\phi}_i))^T \mathbf{R}_j \right) \\ &= \text{Log} \left(\Delta \tilde{\mathbf{R}}_{ij}^T \text{Exp}(-\boldsymbol{\phi}_i) \mathbf{R}_i^T \mathbf{R}_j \right) \\ &= \text{Log} \left(\Delta \tilde{\mathbf{R}}_{ij}^T \mathbf{R}_i^T \mathbf{R}_j \text{Exp}(-\mathbf{R}_j^T \mathbf{R}_i \boldsymbol{\phi}_i) \right) \\ &= \mathbf{r}_{\Delta \mathbf{R}_{ij}} - \mathbf{J}_r^{-1}(\mathbf{r}_{\Delta \mathbf{R}_{ij}}) \mathbf{R}_j^T \mathbf{R}_i \boldsymbol{\phi}_i \end{aligned}$$

对 $\boldsymbol{\phi}_j$ 的导数为：

$$\begin{aligned} \mathbf{r}_{\Delta \mathbf{R}_{ij}} (\mathbf{R}_j \text{Exp}(\boldsymbol{\phi}_j)) &= \text{Log} \left(\Delta \tilde{\mathbf{R}}_{ij}^T \mathbf{R}_j^T \mathbf{R}_j \text{Exp}(\boldsymbol{\phi}_j) \right) \\ &= \mathbf{r}_{\Delta \mathbf{R}_{ij}} + \mathbf{J}_r^{-1}(\mathbf{r}_{\Delta \mathbf{R}_{ij}}) \boldsymbol{\phi}_j \end{aligned}$$

deltaR对陀螺仪零偏bg的导数

$$\frac{\partial \mathbf{r}_{\Delta \mathbf{R}_{ij}}}{\partial \mathbf{b}_{g,i}} = -\mathbf{J}_r^{-1}(\mathbf{r}'_{\Delta \mathbf{R}_{ij}}) \text{Exp}(\mathbf{r}'_{\Delta \mathbf{R}_{ij}})^T \mathbf{J}_{b,r} \frac{\partial \Delta \hat{\mathbf{R}}_{ij}}{\partial \mathbf{b}_{g,i}} \tilde{\delta} \mathbf{b}_{g,i}$$

接下来考虑速度项的雅可比。速度项更为简单，它与 $\mathbf{v}_i, \mathbf{v}_j$ 呈线性关系，不难得到：

$$\frac{\partial \mathbf{r}_{\Delta \mathbf{v}_{ij}}}{\partial \mathbf{v}_i} = -\mathbf{R}_i^T, \quad \frac{\partial \mathbf{r}_{\Delta \mathbf{v}_{ij}}}{\partial \mathbf{v}_j} = \mathbf{R}_i^T$$

对旋转部分只需要做一阶泰勒展开⁺即可：

$$\begin{aligned} \mathbf{r}_{\Delta \mathbf{v}_{ij}}(\mathbf{R}_i \text{Exp}(\delta \phi_i)) &= (\mathbf{R}_i \text{Exp}(\Delta \phi_i))^T (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) - \Delta \tilde{\mathbf{v}}_{ij} \\ &= (\mathbf{I} - \Delta \phi_i^\wedge) \mathbf{R}_i^T (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}) - \Delta \tilde{\mathbf{v}}_{ij} \\ &= \mathbf{r}_{\Delta \mathbf{v}_{ij}}(\mathbf{R}_i) + (\mathbf{R}_i^T (\mathbf{v}_j - \mathbf{v}_i - \mathbf{g} \Delta t_{ij}))^\wedge \Delta \phi_i \end{aligned}$$

而速度残差相对 $\mathbf{b}_{g,i}, \mathbf{b}_{a,i}$ 的雅可比只和 $\delta \tilde{\mathbf{v}}_{ij}$ 相关。由于速度的残差项与它只相差一个负号，所以我们只需要在前面推导的零偏雅可比的前面添加一个负号即可。

最后来看平移部分。平移部分和 $\mathbf{p}_i, \mathbf{p}_j, \mathbf{v}_i, \mathbf{R}_i$ 以及两个零偏有关。然而，它们的关系大多为线性关系，雅可比很容易推出。

$$\frac{\partial \mathbf{r}_{\Delta \mathbf{p}_{ij}}}{\partial \mathbf{p}_i} = -\mathbf{R}_i^T$$

$$\frac{\partial \mathbf{r}_{\Delta \mathbf{p}_{ij}}}{\partial \mathbf{p}_j} = \mathbf{R}_i^T$$

$$\frac{\partial \mathbf{r}_{\Delta \mathbf{p}_{ij}}}{\partial \mathbf{v}_i} = -\mathbf{R}_i^T \Delta t_{ij}$$

$$\frac{\partial \mathbf{r}_{\Delta \mathbf{p}_{ij}}}{\partial \phi_i} = \left(\mathbf{R}_i^T \left(\mathbf{p}_j - \mathbf{p}_i - \mathbf{v}_i \Delta t_{ij} - \frac{1}{2} \mathbf{g} \Delta t_{ij}^2 \right) \right)^\wedge$$

零偏⁺的残差也只需在零偏雅可比基础上添加负号即可。

二、Quaternion kinematics for the error-state Kalman filter

(好长的文章。。。算是书了已经)

